

NEUROSCI 366

Lecture 7

神经编码 II——Population Decoding, Fisher Information, and Bayes

Source-aligned · Static · Searchable · Printable

Source files

- Lecture7-NeuralCoding2.pdf

Production version: 2026-08-22

Reader profile: neuroscience undergraduate education; mathematics scaffolded from high-school algebra/trigonometry to the formal computational-neuroscience level.

This companion preserves source-page order, distinguishes source material from necessary scaffolding and extensions, and places hints/answers after the lesson. It is a static PDF: no forms, JavaScript, hidden-answer widgets, passwords, or DRM.

Contents

1	How to use this companion	2
2	Learning objectives and prerequisite dependency map	2
3	Five-minute prerequisite diagnostic	2
4	Source-aligned lesson / 按原笔记页序	3
4.1	Lecture7-NeuralCoding2.pdf · p. 1	3
4.2	Lecture7-NeuralCoding2.pdf · p. 2	4
4.3	Lecture7-NeuralCoding2.pdf · p. 3	5
4.4	Lecture7-NeuralCoding2.pdf · p. 4	6
4.5	Lecture7-NeuralCoding2.pdf · p. 5	7
4.6	Lecture7-NeuralCoding2.pdf · p. 6	8
5	补全推导与数学支架 / Derivations	9
5.1	independent Poisson population 的 Fisher information	9
5.2	Cramér–Rao bound 的条件	10
5.3	correlated Gaussian code 与 Mahalanobis geometry	10
5.4	bias–variance 与 Bayesian regularization	11
6	Cross-page synthesis / 跨页因果与数学链	12
7	Worked examples and transfer	12
7.1	N/T scaling	12
7.2	相关方向反例	12
8	Formula and notation sheet	14
9	Bilingual glossary	14
10	Common traps, assumptions, and limitations	15
11	Cumulative Knowledge Check	16
12	Hint Bank	18
13	Complete Answer Key with reasoning	20
14	Source-page concordance and coverage audit	21

15 Errata, uncertainty log, and external endnotes	21
15.1 Errata / source cautions	21
15.2 Uncertainty log	21
15.3 External endnotes	21
15.4 Final self-audit	22

1 How to use this companion

1. 先用 5-minute diagnostic 暴露前置缺口；不要立即翻答案。
2. 按原笔记页序阅读 source-page units：先看原页，再读 clean reconstruction 与补全逻辑。
3. 遇到公式按“问题 → 符号/shape/units → assumptions → 一行一步推导 → intuition → biological meaning → sanity check → failure”阅读。
4. 完成 Cumulative Knowledge Check；只在需要时依次打开 Hint 1、2、3。
5. 至少隔一个 page break 后再核对 Answer Key，并记录错误类型：concept、symbol、algebra、assumption、correlation/causation。

Source hierarchy. 原笔记是内容权威；本书中的“【必要前置】/【补全推导】/【跨课连接】/【延伸】”是为了补齐数学或迁移，不替代源材料。无法确认的内容必须进入 Uncertainty Log。

2 Learning objectives and prerequisite dependency map

- 定义并区分：population likelihood。
- 从第一原则推导：Fisher information。
- 解释几何/计算直觉：CRLB。
- 连接生物学解释：noise covariance。
- 诊断 assumptions 与 failure modes：information limiting。
- 把概念迁移到新神经科学问题：bias-variance。

Dependency map

population likelihood → Fisher information → CRLB → noise covariance → information limiting → bias-variance

Core question

population code 的 Fisher information 如何随 neuron 数和观察时间增长，相关噪声、bias 与 prior 又如何改变可解码精度？

3 Five-minute prerequisite diagnostic

1. ideal independent code 中 J 如何随 N 、 T 变化？（卡住时先看 Source-page unit 1，再看补全推导。）
2. 若 J 加倍，SD lower bound 如何变？（卡住时先看 Source-page unit 2，再看补全推导。）
3. CRLB 对何种 estimator 的基本形式最直接？（卡住时先看 Source-page unit 3，再看补全推导。）
4. noise correlation 与 signal correlation 区别？（卡住时先看 Source-page unit 4，再看补全推导。）
5. 为什么 C^{-1} 出现在 Gaussian decoder？（卡住时先看 Source-page unit 5，再看补全推导。）


Scoring guide: 4–5 confident answers → proceed; 2–3 → use the prerequisite labels; 0–1 → read the formula/notation sheet once before the source-aligned lesson.

4 Source-aligned lesson / 按原笔记页序

4.1 Lecture7-NeuralCoding2.pdf • p. 1

Neural population decoding

Back to MT: single neurons are ambiguous.



$$P_i(k|\theta) = \frac{(S_i(\theta)\Delta t)^k e^{-S_i(\theta)\Delta t}}{k!}$$

$$P_i(k|\alpha) = P_i(k|\beta)$$

Population breaks degeneracy

$$P(k_i, k_j|\alpha) \neq P(k_i, k_j|\beta)$$

Population of $N \gg 1$ independent Poisson neurons

$$\theta_i = \frac{2\pi i}{N}; \quad S_i(\theta) = S(\theta - \theta_i); \quad P(k_1, \dots, k_N|\theta) = \prod_{i=1}^N P_i(k_i|\theta)$$

Uniformly spaced preferred directions
Same tuning curve shape, different θ_i
Independent neurons

Likelihood function:

$$L(\theta) = P(k_1, \dots, k_N|\theta) = \prod_{i=1}^N \frac{(S_i(\theta)T)^{k_i} e^{-S_i(\theta)T}}{k_i!}; \quad T: \text{trial duration}$$

Log-likelihood function:

$$\ell(\theta) = \log L(\theta) = \sum_{i=1}^N \left(\underbrace{k_i \log(S_i(\theta)T)}_{\text{Linear in } k_i} - \underbrace{S_i(\theta)T - \log k_i!}_{\theta\text{-independent}} \right)$$

Asymptotic decoding performance of maximum likelihood is set by Fisher information. Need to calculate second derivative.

$$\begin{aligned} \frac{d\ell(\theta)}{d\theta} &= \sum_{i=1}^N \left(\frac{k_i}{S_i(\theta)T} \frac{dS_i(\theta)}{d\theta} T - \frac{dS_i(\theta)}{d\theta} T \right) \\ &= \sum_{i=1}^N \frac{dS_i(\theta)}{d\theta} T \left(\frac{k_i}{S_i(\theta)T} - 1 \right) \end{aligned}$$

Original-note anchor. [Source: Lecture7-NeuralCoding2.pdf, p. 1]

Clean reconstruction. Page 1: single-neuron ambiguity, population likelihood, uniform preferred directions, log-likelihood derivatives.

What the note is saying. 本页的中心对象是 population likelihood 与 Fisher information。原笔记将它们放进以下链条: single-neuron ambiguity, population likelihood, uniform preferred directions, log-likelihood derivatives.

Why it follows. 解释 population code 如何打破单神经元 tuning ambiguity; 逐步构建 independent Poisson joint likelihood。其逻辑后果是: 完整推导 first/second derivative、在 true stimulus 处取 expectation、Fisher information, 并说明 uniform preferred-direction sum 如何近似积分。后面的正式推导会逐项写出 assumptions, shape/units, limiting cases 与 failure conditions.

Figure reading. 先明确横纵轴、单位、归一化与每条曲线改变的唯一参数; 区分示意趋势、模型预测和真正测得的数据点。

Stop & Predict

ideal independent code 中 J 如何随 N、T 变化?

4.2 Lecture7-NeuralCoding2.pdf • p. 2

$$\begin{aligned}\frac{d^2 \mathcal{L}(\theta)}{d\theta^2} &= \sum_{i=1}^N \left(\frac{d^2 \mathcal{S}_i(\theta)}{d\theta^2} T \left(\frac{k_i}{\mathcal{S}_i(\theta)T} - 1 \right) + \frac{d\mathcal{S}_i(\theta)}{d\theta} T \left(-\frac{k_i}{(\mathcal{S}_i(\theta)T)^2} \right) \right) \\ &= \sum_{i=1}^N \left(\frac{d^2 \mathcal{S}_i(\theta)}{d\theta^2} T \left(\frac{k_i}{\mathcal{S}_i(\theta)T} - 1 \right) - \left(\frac{d\mathcal{S}_i(\theta)}{d\theta} \right)^2 \frac{k_i}{(\mathcal{S}_i(\theta))^2} \right)\end{aligned}$$

Recall that

$$\langle k_i \rangle_{k|\theta} = \mathcal{S}_i(\theta)T$$

Thus,

$$\mathcal{J}(\theta) = - \left\langle \frac{d^2 \mathcal{L}(\theta)}{d\theta^2} \right\rangle_{k|\theta} = \sum_{i=1}^N \frac{(d\mathcal{S}_i(\theta)/d\theta)^2}{\mathcal{S}_i(\theta)} T$$


For large N , we can approximate sum with integral.

$$\sum_{i=1}^N F(\theta_i) = \sum_{i=1}^N \frac{\Delta\theta_i}{2\pi/N} F(\theta_i) \xrightarrow{N \gg 1} N \int_0^{2\pi} \frac{d\theta_i}{2\pi} F(\theta_i)$$

The Fisher information becomes

$$\begin{aligned}\mathcal{J}(\theta) &= NT \int_0^{2\pi} \frac{d\theta_i}{2\pi} \frac{(d\mathcal{S}(\theta-\theta_i)/d\theta)^2}{\mathcal{S}(\theta-\theta_i)} \\ &= NT \int_0^{2\pi} \underbrace{\frac{d\theta'}{2\pi}}_{\text{Scaling}} \underbrace{\frac{(d\mathcal{S}(\theta')/d\theta)^2}{\mathcal{S}(\theta')}}_{\text{Tuning curve dependence}}\end{aligned}$$

The decoder works arbitrarily well for large systems.



Original-note anchor. [Source: Lecture7-NeuralCoding2.pdf, p. 2]

Clean reconstruction. Page 2: Fisher information 的 population derivation、sum-to-integral、N/T scaling。

What the note is saying. 本页的中心对象是 CRLB 与 noise covariance。原笔记将它们放进以下链条：Fisher information 的 population derivation、sum-to-integral、N/T scaling。

Why it follows. 完整推导 first/second derivative、在 true stimulus 处取 expectation、Fisher information, 并说明 uniform preferred-direction sum 如何近似积分。其逻辑后果是：解释 population code 如何打破单神经元 tuning ambiguity；逐步构建 independent Poisson joint likelihood。后面的正式推导会逐项写出 assumptions、shape/units、limiting cases 与 failure conditions。

Figure reading. 先识别图中对象、箭头、参数和坐标系，再问它表达的是定义、推导、模型预测还是经验观察；示意图不提供未标注的定量精度。

Stop & Predict

若 J 加倍，SD lower bound 如何变？


4.3 Lecture7-NeuralCoding2.pdf • p. 3

Why is this issue important?


1. Fisher information limits any decoder, not just maximum likelihood. For unbiased decoders,

$$\underbrace{\langle \hat{\theta} \rangle = \theta_0}_{\text{unbiased}}, \quad \underbrace{\text{Var}(\hat{\theta}) \geq \frac{1}{\mathcal{I}(\theta)}}_{\text{Cramer-Rao Lower Bound}}$$

2. Perceptual errors are substantial




L or R?




3. Neurons are not independent

$$C_{ij} = \frac{\langle (k_i - \bar{k}_i)(k_j - \bar{k}_j) \rangle}{\sigma_i \sigma_j} \quad \text{Pearson correlation coefficient}$$


lower case c



Independence assumption (Uncorrelated)



MT neurons are positively correlated



Negative correlation

Shadlen and Newsome hypothesized in 1994 that neural correlations may be the root cause of perceptual errors. Suppose the monkey makes

Original-note anchor. [Source: Lecture7-NeuralCoding2.pdf, p. 3]

Clean reconstruction. Page 3: Cramér–Rao bound、perceptual error、noise correlations.

What the note is saying. 本页的中心对象是 information limiting 与 bias-variance。原笔记将它们放进以下链条：Cramér–Rao bound、perceptual error、noise correlations。

Why it follows. 准确陈述 Cramér–Rao lower bound 的 unbiased/regularity assumptions；不要把 bound 说成任何有限样本 decoder 都必然达到。其逻辑后果是：解释 Pearson noise correlation、positive/negative/zero correlation 和 shared variability；区分 signal correlation。后面的正式推导会逐项写出 assumptions、shape/units、limiting cases 与 failure conditions。

Figure reading. 先识别图中对象、箭头、参数和坐标系，再问它表达的是定义、推导、模型预测还是经验观察；示意图不提供未标注的定量精度。

Stop & Predict

CRLB 对何种 estimator 的基本形式最直接？

4.4 Lecture7-NeuralCoding2.pdf • p. 4

its decision by pooling over left and right selective neurons in MT.

$$R = \frac{1}{N_R} \sum_{i=1}^{N_R} h_i^{(R)}, \quad L = \frac{1}{N_L} \sum_{i=1}^{N_L} h_i^{(L)}, \quad \begin{matrix} L > R \\ \text{or} \\ R > L \end{matrix} ?$$

What are the statistics of these pooled signals?

$$\begin{aligned} \langle R \rangle &= \frac{1}{N_R} \sum_{i=1}^{N_R} \langle h_i^{(R)} \rangle = S_R(\theta) T \\ \text{Var}(R) &= \left\langle \left(\frac{1}{N_R} \sum_{i=1}^{N_R} h_i^{(R)} - S_R(\theta) T \right)^2 \right\rangle \\ &= \left\langle \left(\frac{1}{N_R} \sum_{i=1}^{N_R} \underbrace{(h_i^{(R)} - S_R(\theta) T)}_{S h_i^{(R)}} \right)^2 \right\rangle \\ &= \frac{1}{N_R^2} \sum_{i=1}^{N_R} \sum_{j=1}^{N_R} \langle S h_i^{(R)} S h_j^{(R)} \rangle \\ &= \frac{1}{N_R^2} (N_R \sigma_R^2 + N_R(N_R-1) C_R \sigma_R^2) \\ &= C_R \sigma_R^2 + \frac{(1-C_R) \sigma_R^2}{N_R} \end{aligned}$$

Nonzero if $C_R \neq 0$ ~Zero for $N_R \gg 1$

Both R and L are noisy; a nonzero error rate remains.

Correlated Gaussian noise model of neural encoding

$$\begin{aligned} \begin{bmatrix} h_1 \\ \vdots \\ h_N \end{bmatrix} &\sim \mathcal{N} \left(\underbrace{\begin{bmatrix} S_1(\theta) T \\ \vdots \\ S_N(\theta) T \end{bmatrix}}_{\substack{\text{mean vector} \\ \mu_i = S_i(\theta) T}}, \underbrace{C(\theta)}_{\substack{\text{covariance matrix} \\ C_{ij} = \langle S h_i S h_j \rangle}} \right) \\ &\quad \text{joint sampling} \quad \text{upper case C} \\ P(k_1, \dots, k_N | \theta) &= \frac{1}{\sqrt{(2\pi)^N \det C}} e^{-\frac{1}{2} \sum_{i=1}^N \sum_{j=1}^N (k_i - \mu_i) C_{ij}^{-1} (k_j - \mu_j)} \\ &\quad \det(C): \text{determinant of } C \\ &\quad C_{ij}^{-1}: \text{matrix inverse of } C \text{ (i,j component)} \end{aligned}$$

Original-note anchor. [Source: Lecture7-NeuralCoding2.pdf, p. 4]

Clean reconstruction. Page 4: left/right pooling statistics; correlated Gaussian encoding model, covariance matrix/inverse.

What the note is saying. 本页的中心对象是 Bayes prior 与 population likelihood。原笔记将它们放进以下链条: left/right pooling statistics; correlated Gaussian encoding model, covariance matrix/inverse。

Why it follows. 逐步推导 left/right pooled-count mean/variance, 并引入 multivariate Gaussian, covariance inverse 与 Mahalanobis geometry。其逻辑后果是: 准确陈述 Cramér–Rao lower bound 的 unbiased/regularity assumptions; 不要把 bound 说成任何有限样本 decoder 都必然达到。后面的正式推导会逐项写出 assumptions、shape/units、limiting cases 与 failure conditions。

Figure reading. 把图与矩阵 shape 对齐: 轴代表变量或 mode, 椭圆方向对应 eigenvectors, 轴长/曲率对应 eigenvalues; 不要把统计轴自动解释为因果通路。

Stop & Predict

noise correlation 与 signal correlation 区别?

4.5 Lecture7-NeuralCoding2.pdf • p. 5

The Fisher information of this model has been analyzed for many choices of C . Lessons:

1. $J(\theta)$ scales with N for some models and saturates for others. Saturation implies "information limiting correlations."
2. State-of-the art models only saturate at very high values, and accurate decoding of neural activity can exceed animal behavior.
3. The performance of suboptimal decoders can saturate, even if $J(\theta)$ scales. Example of uniform correlations

$$C_{ij} = \sigma^2 \delta_{ij} + C\sigma^2(1 - \delta_{ij})$$

Here $J(\theta)$ scales, pooling saturates in performance (as argued before), optimal linear decoding does not. Behavioral limits may result from suboptimal decoders and correlated noise.

Original-note anchor. [Source: Lecture7-NeuralCoding2.pdf, p. 5]

Clean reconstruction. Page 5: information-limiting correlations、biological saturation、sub-optimal decoder。

What the note is saying. 本页的中心对象是 Fisher information 与 CRLB。原笔记将它们放进以下链条：information-limiting correlations、biological saturation、suboptimal decoder。

Why it follows. 解释 information-limiting correlations 与 decoder mismatch/suboptimality；避免把所有 saturation 都归因于单一机制。其逻辑后果是：准确陈述 Cramér–Rao lower bound 的 unbiased/regularity assumptions；不要把 bound 说成任何有限样本 decoder 都必然达到。后面的正式推导会逐项写出 assumptions、shape/units、limiting cases 与 failure conditions。

Figure reading. 先识别图中对象、箭头、参数和坐标系，再问它表达的是定义、推导、模型预测还是经验观察；示意图不提供未标注的定量精度。

Stop & Predict

为什么 C^{-1} 出现在 Gaussian decoder?

4.6 Lecture7-NeuralCoding2.pdf • p. 6

Biased decoding

Decoders can be biased.

$$b = \langle \hat{s} \rangle - s_o = \underbrace{s_e - s_o}_{\text{generally nonzero}}$$


Bias-variance decomposition of error:

$$\underbrace{\langle (\hat{s} - s_o)^2 \rangle}_{\text{Mean squared error}} = \underbrace{\langle (\hat{s} - s_e + s_e - s_o)^2 \rangle}_{\text{crossterm averages to zero}} = \text{Var}(\hat{s}) + b^2$$

Bias can improve performance by reducing variance.

$$\text{Var}(\hat{s}) \geq \frac{(1 + db(s)/ds)^2}{J(s)}$$

Modified Cramer-Rao Lower Bound



The Bayesian decoder is an important example

$$P(s|n) = \frac{P(n|s)P(s)}{P(n)}$$

$$\begin{aligned} \hat{s} &= \arg \max_s \log P(s|n) \\ &= \arg \max_s \left(\underbrace{\lambda(s)}_{\text{log-likelihood}} + \underbrace{\log P(s)}_{\text{prior probability}} \right) \end{aligned}$$

It is biased to favor stimuli that are a priori common. The prior "regularizes" the decoding problem.

Original-note anchor. [Source: Lecture7-NeuralCoding2.pdf, p. 6]**Clean reconstruction.** Page 6: biased decoding, bias-variance decomposition, modified CRLB, Bayesian decoder.**What the note is saying.** 本页的中心对象是 noise covariance 与 information limiting。原笔记将它们放进以下链条: biased decoding、bias-variance decomposition、modified CRLB、Bayesian decoder。**Why it follows.** 推导 bias-variance decomposition, 解释 modified CRLB; 将 Bayesian prior 视为 regularization, 并区分 likelihood 与 posterior。其逻辑后果是: 解释 information-limiting correlations 与 decoder mismatch/suboptimality; 避免把所有 saturation 都归因于单一机制。后面的正式推导会逐项写出 assumptions、shape/units、limiting cases 与 failure conditions。**Figure reading.** 先识别图中对象、箭头、参数和坐标系, 再问它表达的是定义、推导、模型预测还是经验观察; 示意图不提供未标注的定量精度。**Stop & Predict**

positive correlation 是否必然降低 information?

5 补全推导与数学支架 / Derivations

5.1 independent Poisson population 的 Fisher information

【必要前置】 从 log-likelihood 二阶导数得到 $J(\theta)$ 。

$$\ell(\theta) = \sum_i [k_i \log(f_i T) - f_i T - \log k_i!]$$

$$J(\theta) = T \sum_i \frac{[f'_i(\theta)]^2}{f_i(\theta)}$$

$$J(\theta) \approx NT \int \frac{d\phi}{2\pi} \frac{[f'(\phi)]^2}{f(\phi)}$$

1. 一阶导数含 f'_i ($k_i/f_i - T$)。
2. 二阶导数取 true stimulus 下期望，使用 $E[k_i] = f_i T$ 。
3. 均匀 preferred directions 使离散 sum 在大 N 时近似 circular integral。
4. 若 tuning shape 固定，则 $J \propto NT$ 。

Geometric/computational intuition. 更多 independent neurons 或更长观察时间相当于累积更多局部 evidence。

Biological interpretation / failure condition. 非独立 noise、heterogeneous tuning、有限 N 或 information-limiting covariance 可破坏 scaling。

Micro-check

noise correlation 与 signal correlation 区别？

5.2 Cramér–Rao bound 的条件

【补全推导】 Fisher information 如何限制 unbiased decoder?

$$\text{Var}(\hat{\theta}) \geq \frac{1}{J(\theta)}$$

1. 估计量需在局部 unbiased, 并满足可交换微分与积分等 regularity。
2. bound 是下界, 不保证任意 decoder 达到。
3. MLE 常在大样本接近 bound, 但有限样本、多峰/边界问题可偏离。
4. behavioral error 还包含 downstream computation、motor noise 与 lapse。

Geometric/computational intuition. encoding distribution 本身设定了任何 unbiased read-out 都无法跨越的局部精度极限。

Biological interpretation / failure condition. 对 biased estimator 直接使用 $1/J$ 会得到错误结论。

Micro-check

为什么 C^{-1} 出现在 Gaussian decoder?

5.3 correlated Gaussian code 与 Mahalanobis geometry

【跨页连接】 noise covariance 如何改变 stimulus discrimination?

$$\mathbf{r} \mid \theta \sim \mathcal{N}(\boldsymbol{\mu}(\theta), C(\theta))$$

$$-2\ell = (\mathbf{r} - \boldsymbol{\mu})^T C^{-1}(\mathbf{r} - \boldsymbol{\mu}) + \log \det C + \text{const}$$

$$J \approx \boldsymbol{\mu}'(\theta)^T C^{-1} \boldsymbol{\mu}'(\theta) \quad (C \text{ independent of } \theta)$$

1. C 的 off-diagonal 元素表示 shared trial-to-trial variability。
2. C^{-1} 对高噪声方向降低权重、低噪声方向提高权重。
3. 若 noise 沿 signal derivative 方向增长, 会严重限制 information。
4. decoder 若忽略 C , 即使 code 含信息也可能表现 suboptimal。

Geometric/computational intuition. 可分辨性由 mean shift 相对 noise ellipse 的方向决定, 而不只由单 neuron variance。

Biological interpretation / failure condition. 把 signal correlation (tuning 相似) 与 noise correlation (同 trial residual 共变) 混淆。

Micro-check

positive correlation 是否必然降低 information?

5.4 bias-variance 与 Bayesian regularization

【模型边界】 biased decoder 为什么可能有更低 MSE?

$$E[(\hat{s} - s)^2] = \text{Var}(\hat{s}) + b(s)^2$$

$$\text{Var}(\hat{s}) \geq \frac{[1 + b'(s)]^2}{J(s)}$$

$$P(s | \mathbf{n}) \propto P(\mathbf{n} | s)P(s)$$

1. MSE 分解为 variance 与 squared bias。
2. prior 拉估计向常见 stimulus, 增加 bias 但可降低 variance。
3. modified CRLB 显式包含 bias derivative。
4. MAP decoder 最大化 log-likelihood+log-prior。

Geometric/computational intuition. regularization 用一些系统性偏移换取对噪声不敏感。
Biological interpretation / failure condition. prior 与环境不匹配时 bias 会恶化性能。

Micro-check

information-limiting correlation 的核心特征是什么?

6 Cross-page synthesis / 跨页因果与数学链

单个 tuning curve 常对多个 stimulus 给出相似 rate, population pattern 可打破 ambiguity。在 independent Poisson 与均匀 preferred direction 的理想条件下, Fisher information 对 N 和 T 线性增长。真实群体的 noise correlations、decoder mismatch 与 behavioral constraints 使性能可能饱和; Bayesian prior 以可控 bias 换取 variance reduction。




Figure note: schematic reconstruction; it encodes qualitative relations from the lesson and does not invent precise empirical data points.

7 Worked examples and transfer

7.1 N/T scaling

【原课/核心例题】 Prompt. 若每个 neuron/秒贡献同样 Fisher information j_0 , $N=100$, $T=0.5$ s。

Worked solution. $J=NTj_0=50j_0$; 理想 SD 下界为 $1/\sqrt{J}$ 。把 N 或 T 加倍只把 SD 降低 $\sqrt{2}$ 倍。

Check. variance $\propto 1/(NT)$, standard deviation $\propto 1/\sqrt{NT}$ 。

7.2 相关方向反例

【跨课连接】 Prompt. 两维 mean 随 stimulus 沿 (1,1) 变化。

Worked solution. 若 noise ellipse 也沿 (1,1) 极度拉长, positive correlation 会损害 discrimination; 若 noise 沿 (1,-1), 可能影响较小。

Check. 相关系数的正负本身不足以判断 information; 必须比较 covariance eigenvectors 与 signal

direction。

Micro-check

Explain in your own words. 用不超过 120 字解释：本课从 source page 1 到最后一页，究竟把哪一个输入、状态、统计量或学习规则变成了可检验 prediction？

Self-reflection. 你最可能犯的是 concept、symbol、algebra、assumption 还是 causality error？写出一个具体例子。

8 Formula and notation sheet

1. independent Poisson population Fisher

$$J = T \sum_i (f'_i)^2 / f_i$$

Conditions / conventions: counts independent

2. unbiased CRLB

$$\text{Var}(\hat{\theta}) \geq 1/J$$

Conditions / conventions: regularity/unbiased

3. noise covariance

$$C_{ij} = \text{Cov}(r_i, r_j)$$

Conditions / conventions: 同 stimulus、跨 trial residual

4. Pearson noise correlation

$$\rho_{ij} = C_{ij} / (\sigma_i \sigma_j)$$

Conditions / conventions: 非零 variances

5. Mahalanobis separation

$$d_M^2 = \Delta\mu^T C^{-1} \Delta\mu$$

Conditions / conventions: C 正定

6. bias-variance decomposition

$$MSE = \text{Var} + b^2$$

Conditions / conventions: 标量 estimator

7. Bayesian decoding

$$P(s|n) \propto P(n|s)P(s)$$

Conditions / conventions: posterior properly normalized

9 Bilingual glossary

中文	English / symbol	Operational meaning
群体编码	population code	多个 neurons 的联合 response pattern。
Cramér–Rao 下界	Cramér–Rao lower bound	unbiased estimator variance 的信息论下界。
噪声相关	noise correlation	固定 stimulus 时 trial residual 的相关性。
信号相关	signal correlation	tuning curves across stimuli 的相似性。
协方差矩阵	covariance matrix	各维 variance 与 pairwise covariance 的矩阵。
Mahalanobis 距离	Mahalanobis distance	按 noise covariance 归一化的距离。
信息限制相关	information-limiting correlation	沿 stimulus signal direction 留下不可平均掉的 shared noise。
次优解码器	suboptimal decoder	未充分利用 encoding information 的 readout。
偏差	bias	估计均值与真值之差。
正则化	regularization	通过约束或 prior 降低 variance/复杂度。

10 Common traps, assumptions, and limitations

1. 把 CRLB 当作所有 decoder 的实际误差，而非有条件的下界。
2. 认为正相关总是有害、负相关总是有利。
3. 混淆 encoding distribution、decoder algorithm 与 behavior 三个层级。
4. 把 Fisher information saturation 自动归因于唯一生物机制。
5. 忽略 biased decoder 的 modified bound。
6. 把 prior 当作额外数据而非对 stimulus frequency/structure 的假设。

Course-specific risk boundary. 明确区分 three levels: neural encoding distribution、decoder algorithm、behavioral performance；相关性存在不等于某个 decoder 一定使用或不使用它。

11 Cumulative Knowledge Check

Do not turn to the Hint Bank until you have written a first attempt.

1. ideal independent code 中 J 如何随 N 、 T 变化?

2. 若 J 加倍, SD lower bound 如何变?

3. CRLB 对何种 estimator 的基本形式最直接?

4. noise correlation 与 signal correlation 区别?

5. 为什么 C^{-1} 出现在 Gaussian decoder?

6. positive correlation 是否必然降低 information?

7. information-limiting correlation 的核心特征是什么?

8. behavior 比 CRLB 差能证明 brain decoder suboptimal 吗?

9. MSE 的两项是什么?

10. Bayesian prior 如何 regularize?

11. modified CRLB 为什么含 $b'(s)$?

12. uniform preferred direction sum 为什么能近似积分?

13. 公式表中的 “independent Poisson population Fisher” 解决什么问题? 写出适用条件与一个 sanity check。

14. 公式表中的 “unbiased CRLB” 解决什么问题? 写出适用条件与一个 sanity check。

15. 公式表中的 “noise covariance” 解决什么问题？写出适用条件与一个 sanity check。

16. 公式表中的 “Pearson noise correlation” 解决什么问题？写出适用条件与一个 sanity check。

17. 公式表中的 “Mahalanobis separation” 解决什么问题？写出适用条件与一个 sanity check。

18. 公式表中的 “bias-variance decomposition” 解决什么问题？写出适用条件与一个 sanity check。

12 Hint Bank

1. **Hint 1.** 先识别对象、变量与假设。
Hint 2. 写出最相关的定义或方程，再代入。
Hint 3. 检查单位、shape、符号与极限情况。
2. **Hint 1.** 先识别对象、变量与假设。
Hint 2. 写出最相关的定义或方程，再代入。
Hint 3. 检查单位、shape、符号与极限情况。
3. **Hint 1.** 先识别对象、变量与假设。
Hint 2. 写出最相关的定义或方程，再代入。
Hint 3. 检查单位、shape、符号与极限情况。
4. **Hint 1.** 先识别对象、变量与假设。
Hint 2. 写出最相关的定义或方程，再代入。
Hint 3. 检查单位、shape、符号与极限情况。
5. **Hint 1.** 先识别对象、变量与假设。
Hint 2. 写出最相关的定义或方程，再代入。
Hint 3. 检查单位、shape、符号与极限情况。
6. **Hint 1.** 先识别对象、变量与假设。
Hint 2. 写出最相关的定义或方程，再代入。
Hint 3. 检查单位、shape、符号与极限情况。
7. **Hint 1.** 先识别对象、变量与假设。
Hint 2. 写出最相关的定义或方程，再代入。
Hint 3. 检查单位、shape、符号与极限情况。
8. **Hint 1.** 先识别对象、变量与假设。
Hint 2. 写出最相关的定义或方程，再代入。
Hint 3. 检查单位、shape、符号与极限情况。
9. **Hint 1.** 先识别对象、变量与假设。
Hint 2. 写出最相关的定义或方程，再代入。
Hint 3. 检查单位、shape、符号与极限情况。
10. **Hint 1.** 先识别对象、变量与假设。
Hint 2. 写出最相关的定义或方程，再代入。
Hint 3. 检查单位、shape、符号与极限情况。
11. **Hint 1.** 先识别对象、变量与假设。
Hint 2. 写出最相关的定义或方程，再代入。
Hint 3. 检查单位、shape、符号与极限情况。
12. **Hint 1.** 先识别对象、变量与假设。
Hint 2. 写出最相关的定义或方程，再代入。
Hint 3. 检查单位、shape、符号与极限情况。
13. **Hint 1.** 先从 “independent Poisson population Fisher” 对应的变量关系入手。
Hint 2. 把条件 “counts independent” 逐字转换为 assumption。
Hint 3. 写公式，再检查至少一种极端参数或单位。
14. **Hint 1.** 先从 “unbiased CRLB” 对应的变量关系入手。
Hint 2. 把条件 “regularity/unbiased” 逐字转换为 assumption。
Hint 3. 写公式，再检查至少一种极端参数或单位。

15. **Hint 1.** 先从 “noise covariance” 对应的变量关系入手。
Hint 2. 把条件 “同 stimulus、跨 trial residual” 逐字转换为 assumption。
Hint 3. 写公式, 再检查至少一种极端参数或单位。
16. **Hint 1.** 先从 “Pearson noise correlation” 对应的变量关系入手。
Hint 2. 把条件 “非零 variances” 逐字转换为 assumption。
Hint 3. 写公式, 再检查至少一种极端参数或单位。
17. **Hint 1.** 先从 “Mahalanobis separation” 对应的变量关系入手。
Hint 2. 把条件 “C 正定” 逐字转换为 assumption。
Hint 3. 写公式, 再检查至少一种极端参数或单位。
18. **Hint 1.** 先从 “bias-variance decomposition” 对应的变量关系入手。
Hint 2. 把条件 “标量 estimator” 逐字转换为 assumption。
Hint 3. 写公式, 再检查至少一种极端参数或单位。

13 Complete Answer Key with reasoning

1. $J \propto NT$ 。
2. 乘 $1/\sqrt{2}$ 。
3. unbiased、满足 regularity 的 estimator。
4. 前者是固定 stimulus 的 trial residual 共变；后者是 tuning means 的相似。
5. 它按各 noise direction 的可靠性加权 residual。
6. 否，取决于 correlation eigenmode 与 stimulus-induced mean shift 的相对方向。
7. shared noise 沿 stimulus signal direction，不能靠增加相似 neurons 平均掉。
8. 不能单独证明；还可能有 model mismatch、downstream/motor noise、lapses。
9. variance+bias²。
10. 把 posterior/MAP 拉向先验常见值，通常降低 variance 但引入 bias。
11. bias 随 stimulus 的局部变化会改变 estimator 对参数变化的响应。
12. 当 preferred angles 密集均匀时，Riemann sum 收敛到 circular integral。
13. 适用条件/约定：counts independent。sanity check 应检查单位、符号、极限或 shape 是否与定义一致。

$$J = T \sum_i (f'_i)^2 / f_i$$

14. 适用条件/约定：regularity/unbiased。sanity check 应检查单位、符号、极限或 shape 是否与定义一致。

$$\text{Var}(\hat{\theta}) \geq 1/J$$

15. 适用条件/约定：同 stimulus、跨 trial residual。sanity check 应检查单位、符号、极限或 shape 是否与定义一致。

$$C_{ij} = \text{Cov}(r_i, r_j)$$

16. 适用条件/约定：非零 variances。sanity check 应检查单位、符号、极限或 shape 是否与定义一致。

$$\rho_{ij} = C_{ij} / (\sigma_i \sigma_j)$$

17. 适用条件/约定：C 正定。sanity check 应检查单位、符号、极限或 shape 是否与定义一致。

$$d_M^2 = \Delta\mu^T C^{-1} \Delta\mu$$

18. 适用条件/约定：标量 estimator。sanity check 应检查单位、符号、极限或 shape 是否与定义一致。

$$MSE = \text{Var} + b^2$$

14 Source-page concordance and coverage audit

Source file	Page	Coverage status
Lecture7-NeuralCoding2.pdf	1	Main source-page unit: thumbnail, reconstruction, explanation, prediction question.
Lecture7-NeuralCoding2.pdf	2	Main source-page unit: thumbnail, reconstruction, explanation, prediction question.
Lecture7-NeuralCoding2.pdf	3	Main source-page unit: thumbnail, reconstruction, explanation, prediction question.
Lecture7-NeuralCoding2.pdf	4	Main source-page unit: thumbnail, reconstruction, explanation, prediction question.
Lecture7-NeuralCoding2.pdf	5	Main source-page unit: thumbnail, reconstruction, explanation, prediction question.
Lecture7-NeuralCoding2.pdf	6	Main source-page unit: thumbnail, reconstruction, explanation, prediction question.

15 Errata, uncertainty log, and external endnotes

15.1 Errata / source cautions

- 1. Page 2 的 sum-to-integral 需要大 N 、均匀 preferred directions 与共同 tuning shape。
- 2. Page 3 的 CRLB 必须附 unbiased/regularity 条件。
- 3. Page 5 的 performance saturation 有多种可能来源；笔记明确不应只归因于 correlations。

15.2 Uncertainty log

No unresolved handwriting uncertainty changes a core definition, equation, figure interpretation, or answer in this companion. Where handwriting was potentially ambiguous, the source-page image is preserved and the reconstruction avoids claiming unverified detail.

15.3 External endnotes

No external web or textbook source was used to replace the uploaded notes. Added material is limited to necessary mathematical scaffolding, explicit assumptions, standard sanity checks, and clearly labeled transfer examples.

15.4 Final self-audit

All source pages listed above were visually inspected. Equations were checked for symbol definitions, units/shapes, assumptions, algebraic transitions, limiting cases, and failure conditions. The PDF is static and contains no interactive form fields or scripts.