

NEUROSCI 366

Lecture 8

神经网络 I——Spikes, Convolution, and E/I Balance

Source-aligned · Static · Searchable · Printable

Source files

- Lecture8-NeuralNetworks1.pdf

Production version: 2026-08-22

Reader profile: neuroscience undergraduate education; mathematics scaffolded from high-school algebra/trigonometry to the formal computational-neuroscience level.

This companion preserves source-page order, distinguishes source material from necessary scaffolding and extensions, and places hints/answers after the lesson. It is a static PDF: no forms, JavaScript, hidden-answer widgets, passwords, or DRM.

Contents

1	How to use this companion	2
2	Learning objectives and prerequisite dependency map	2
3	Five-minute prerequisite diagnostic	2
4	Source-aligned lesson / 按原笔记页序	3
4.1	Lecture8-NeuralNetworks1.pdf · p. 1	3
4.2	Lecture8-NeuralNetworks1.pdf · p. 2	4
4.3	Lecture8-NeuralNetworks1.pdf · p. 3	5
4.4	Lecture8-NeuralNetworks1.pdf · p. 4	6
4.5	Lecture8-NeuralNetworks1.pdf · p. 5	7
4.6	Lecture8-NeuralNetworks1.pdf · p. 6	8
5	补全推导与数学支架 / Derivations	9
5.1	spike-time sum 等于 convolution	9
5.2	independent Poisson inputs 的 mean 与 variance	10
5.3	为什么 1/N scaling 消灭 fluctuations	11
5.4	balanced $1/\sqrt{N}$ scaling	11
6	Cross-page synthesis / 跨页因果与数学链	12
7	Worked examples and transfer	12
7.1	finite-bin scaling 数值	12
7.2	kernel sum	12
8	Formula and notation sheet	14
9	Bilingual glossary	14
10	Common traps, assumptions, and limitations	15
11	Cumulative Knowledge Check	16
12	Hint Bank	18
13	Complete Answer Key with reasoning	20
14	Source-page concordance and coverage audit	21

15 Errata, uncertainty log, and external endnotes	21
15.1 Errata / source cautions	21
15.2 Uncertainty log	21
15.3 External endnotes	21
15.4 Final self-audit	22

1 How to use this companion

1. 先用 5-minute diagnostic 暴露前置缺口；不要立即翻答案。
2. 按原笔记页序阅读 source-page units：先看原页，再读 clean reconstruction 与补全逻辑。
3. 遇到公式按“问题 → 符号/shape/units → assumptions → 一行一步推导 → intuition → biological meaning → sanity check → failure”阅读。
4. 完成 Cumulative Knowledge Check；只在需要时依次打开 Hint 1、2、3。
5. 至少隔一个 page break 后再核对 Answer Key，并记录错误类型：concept、symbol、algebra、assumption、correlation/causation。

Source hierarchy. 原笔记是内容权威；本书中的“【必要前置】/【补全推导】/【跨课连接】/【延伸】”是为了补齐数学或迁移，不替代源材料。无法确认的内容必须进入 Uncertainty Log。

2 Learning objectives and prerequisite dependency map

- 定义并区分：spike train δ -sum。
- 从第一原则推导：kernel/convolution。
- 解释几何/计算直觉：coupled network。
- 连接生物学解释：Poisson E/I input。
- 诊断 assumptions 与 failure modes：mean vs variance。
- 把概念迁移到新神经科学问题：1/N failure。

Dependency map

spike train δ -sum → kernel/convolution → coupled network → Poisson E/I input → mean vs variance → 1/N failure

Core question

如何把离散 spike times 变成 synaptic currents, 并理解大规模网络中 mean、variance 与 E/I balance 的不同 scaling?

3 Five-minute prerequisite diagnostic

1. δ 的核心积分性质是什么？（卡住时先看 Source-page unit 1，再看补全推导。）
2. 为什么 $K \cdot \Delta$ 等于每个 spike-triggered kernel 的和？（卡住时先看 Source-page unit 2，再看补全推导。）
3. W_{ij} 的方向 convention 是什么？（卡住时先看 Source-page unit 3，再看补全推导。）
4. 独立 Poisson inputs 的 variance 为什么相加？（卡住时先看 Source-page unit 4，再看补全推导。）
5. 抑制项为什么对 variance 为正？（卡住时先看 Source-page unit 5，再看补全推导。）

Scoring guide: 4–5 confident answers → proceed; 2–3 → use the prerequisite labels; 0–1 → read the formula/notation sheet once before the source-aligned lesson.

4 Source-aligned lesson / 按原笔记页序

4.1 Lecture8-NeuralNetworks1.pdf • p. 1

Neural networks:

How a neuron integrates its inputs:

$$C \frac{dV}{dt} = -G_L(V - E_L) + \sum_{i=1}^N W_{ij} \sum_{k=1}^{n_i} K_s(t - t_k^{(i)})$$


Consider a population of N neurons connected to each other through a synaptic weight matrix, W :

W_{ij} : synaptic weight $j \rightarrow i$ (recurrent);

and driven by M input neurons through a matrix, U :

U_{ij} : synaptic weight $j \rightarrow i$ (input)

Diagram:



Coupled equations for neural network, $i=1, \dots, N$

$$C \frac{dV_i}{dt} = -G_L(V_i - E_L) + \sum_{j=1}^N W_{ij} \sum_{k=1}^{n_j} K_s(t - t_k^{(j)}) + \sum_{j=1}^M U_{ij} \sum_{k=1}^{m_j} K_s(t - t_k^{(j)})$$

Generate spiking by integrate-and-fire.

Original-note anchor. [Source: Lecture8-NeuralNetworks1.pdf, p. 1]

Clean reconstruction. Page 1: recurrent/input weights, population architecture, coupled spiking-network equations.

What the note is saying. 本页的中心对象是 spike train δ -sum 与 kernel/convolution。原笔记将它们放进以下链条: recurrent/input weights, population architecture, coupled spiking-network equations。

Why it follows. 将原始 spike-time sum 改写为 compact network equations, 并解释每一项如何从 presynaptic spikes 产生 current。其逻辑后果是: 逐项定义 recurrent weight W_{ij} 与 input weight U_{ij} 的方向 convention、matrix shape 和 biological meaning。后面的正式推导会逐项写出 assumptions、shape/units、limiting cases 与 failure conditions。

Figure reading. 逐条追踪箭头方向、兴奋/抑制符号、状态变量与外部输入; 结构图说明允许的依赖关系, 不自动证明生物实现。

Stop & Predict

δ 的核心积分性质是什么?

4.2 Lecture8-NeuralNetworks1.pdf • p. 2

Representing spike trains:

$$\Delta_i(t) = \sum_{j=1}^{n_i} \delta(t - t_j^{(i)})$$

 $\underbrace{\Delta_i(t)}_{\text{spike train}} = \underbrace{\sum_{j=1}^{n_i}}_{\text{sum over spikes}} \underbrace{\delta(t - t_j^{(i)})}_{\text{"\delta-function" spike}}$

What is a δ -Function:

- $\delta(t)$ is zero if $t \neq 0$ (infinitely sharp)
- Integrates to 1; $\int_{-\infty}^{\infty} dt \delta(t) = 1$
 $\Rightarrow$ " $\delta(0)$ is infinite"
 $\Rightarrow$ only precisely defined within integrals
- $\int_{-\infty}^{\infty} dt \delta(t) f(t) = f(0)$
- $\int_{-\infty}^{\infty} dt' \delta(t - t') f(t') = f(t) = \int_{-\infty}^{\infty} dt' \delta(t') f(t - t')$

This is convenient because

$$\begin{aligned} \sum_{j=1}^{n_i} K_s(t - t_j^{(i)}) &= \sum_{j=1}^{n_i} \int_{-\infty}^{\infty} dt' K_s(t - t_j^{(i)} - t') \delta(t') \\ &= \int_{-\infty}^{\infty} dt' \left(\sum_{j=1}^{n_i} \delta(t - t_j^{(i)} - t') \right) K_s(t') \\ &= \int_{-\infty}^{\infty} dt' \Delta_i(t - t') K_s(t') \\ &= (K_s * \Delta_i)(t) \end{aligned}$$

where the convolution of two functions is defined as

$$\begin{aligned} (f * g)(t) &= \int_{-\infty}^{\infty} dt' f(t - t') g(t') \\ &= \int_{-\infty}^{\infty} dt' f(t') g(t - t') = (g * f)(t) \end{aligned}$$

Original-note anchor. [Source: Lecture8-NeuralNetworks1.pdf, p. 2]

Clean reconstruction. Page 2: spike-train delta representation, Dirac delta, kernel sum, convolution.

What the note is saying. 本页的中心对象是 coupled network 与 Poisson E/I input。原笔记将它们放进以下链条: spike-train delta representation、Dirac delta、kernel sum、convolution。

Why it follows. 解释 spike train 作为 Dirac-delta sum; 强调 delta 不是普通函数; 逐步证明 kernel sum 等于 convolution。其逻辑后果是: 将原始 spike-time sum 改写为 compact network equations, 并解释每一项如何从 presynaptic spikes 产生 current。后面的正式推导会逐项写出 assumptions、shape/units、limiting cases 与 failure conditions。

Figure reading. 先识别图中对象、箭头、参数和坐标系, 再问它表达的是定义、推导、模型预测还是经验观察; 示意图不提供未标注的定量精度。

Stop & Predict

为什么 $K * \Delta$ 等于每个 spike-triggered kernel 的和?

4.3 Lecture8-NeuralNetworks1.pdf • p. 3

The coupled equations thereby become

$$C \frac{dV_i}{dt} = -G_L (V_i - E_L) + \sum_{j=1}^N W_{ij} (K_s * \Delta_j) + \sum_{j=1}^M \mathcal{U}_{ij} (K_s * x_j)$$

where M is the number of input neurons, x_j is the spike train of the j^{th} input neuron, and the spike trains of the N recurrently connected neurons are computed from V_i by an integrate-and-fire mechanism.

Original-note anchor. [Source: Lecture8-NeuralNetworks1.pdf, p. 3]

Clean reconstruction. Page 3: compact convolution form 的 coupled equations.

What the note is saying. 本页的中心对象是 mean vs variance 与 $1/N$ failure。原笔记将它们放进以下链条: compact convolution form 的 coupled equations。


Why it follows. 将原始 spike-time sum 改写为 compact network equations, 并解释每一项如何从 presynaptic spikes 产生 current。其逻辑后果是: 解释 spike train 作为 Dirac-delta sum; 强调 delta 不是普通函数; 逐步证明 kernel sum 等于 convolution。后面的正式推导会逐项写出 assumptions、shape/units、limiting cases 与 failure conditions。

Figure reading. 先识别图中对象、箭头、参数和坐标系, 再问它表达的是定义、推导、模型预测还是经验观察; 示意图不提供未标注的定量精度。

Stop & Predict

W_{ij} 的方向 convention 是什么?

4.4 Lecture8-NeuralNetworks1.pdf • p. 4



If inputs have Poisson variability, how does output respond? Its input current is

$$I_i(t) = \sum_{j=1}^M \mathcal{U}_{ij}(X_j * K_s) = K_s * \left(\sum_{j=1}^M \mathcal{U}_{ij} X_j \right)$$

The temporal Kernel, K_s , smooths the Poisson variability.

We ignore it for now and set

$$K_s(t) = \delta(t) \Rightarrow I_i(t) = \sum_{j=1}^M \mathcal{U}_{ij} X_j(t)$$

As above, we assume excitatory (inhibitory) neurons have firing rate r_E (r_I) and weights W_E ($-W_I$). The total current received in t to $t+\Delta t$ is

$$Q_{\Delta t,i}(t) = \int_t^{t+\Delta t} dt' I_i(t') = \sum_{j=1}^M \mathcal{U}_{ij} \int_t^{t+\Delta t} dt' X_j(t')$$

It's average over Poisson variability is

$$\begin{aligned} \langle Q_{\Delta t,i}(t) \rangle &= \sum_{j=1}^{N_E} W_E r_E \Delta t - \sum_{j=N_E+1}^{N_E+N_I} W_I r_I \Delta t \\ &= N_E W_E r_E \Delta t - N_I W_I r_I \Delta t \end{aligned}$$

Original-note anchor. [Source: Lecture8-NeuralNetworks1.pdf, p. 4]

Clean reconstruction. Page 4: stochastic E/I Poisson inputs; total charge/current mean.

What the note is saying. 本页的中心对象是 $1/\sqrt{N}$ balance 与 spike train δ -sum。原笔记将它们放进以下链条: stochastic E/I Poisson inputs; total charge/current mean.

Why it follows. 对 E/I Poisson input 逐步计算 finite-bin total charge 的 mean 与 variance。其逻辑后果是: 严格推导 $W \propto 1/N$ 时 mean finite 但 $\text{variance} \rightarrow 0$, 为何网络趋于规则/静默而失去 Poisson-like fluctuations。后面的正式推导会逐项写出 assumptions、shape/units、limiting cases 与 failure conditions。

Figure reading. 先识别图中对象、箭头、参数和坐标系, 再问它表达的是定义、推导、模型预测还是经验观察; 示意图不提供未标注的定量精度。

Stop & Predict

独立 Poisson inputs 的 variance 为什么相加?

4.5 Lecture8-NeuralNetworks1.pdf • p. 5

The variances of independent random variables sum, $\text{Var}(aX+bY) = a^2 \text{Var}(X) + b^2 \text{Var}(Y)$, so

$$\begin{aligned}\text{Var}(Q_{\Delta t, i}(t)) &= \sum_{j=1}^M \alpha_{ij}^2 \text{Var}\left(\sum_t^{t+\Delta t} dt' x_j(t')\right) \\ &= \sum_{j=1}^{N_E} W_E^2 h_E \Delta t + \sum_{j=N_E+1}^{N_E+N_I} W_I^2 h_I \Delta t \\ &= N_E W_E^2 h_E \Delta t + N_I W_I^2 h_I \Delta t\end{aligned}$$

Limit of large networks:

For the mean to stay finite as N_E and N_I get large (go to infinity), we scale the weights,

$$W_E = \frac{\bar{W}_E}{N_E}, \quad W_I = \frac{\bar{W}_I}{N_I}$$

Then,

$$\begin{aligned}\langle Q_{\Delta t, i}(t) \rangle &= \bar{W}_E h_E \Delta t - \bar{W}_I h_I \Delta t \\ \text{Var}(Q_{\Delta t, i}(t)) &= \frac{1}{N_E} \bar{W}_E^2 h_E \Delta t + \frac{1}{N_I} \bar{W}_I^2 h_I \Delta t\end{aligned}$$

The variance goes to zero in an (infinitely) large system, and the Poisson variability has no effect. The downstream neuron acts like it would with $I_E = \bar{W}_E h_E - \bar{W}_I h_I$. It ~~either~~ either spikes regularly or is silent.

E/I balance:

The way out is to balance excitation and inhibition and achieve a zero mean.

$$\langle Q_{\Delta t, i}(t) \rangle = 0 \Rightarrow h_I = \frac{N_E W_E}{N_I W_I} h_E$$

Original-note anchor. [Source: Lecture8-NeuralNetworks1.pdf, p. 5]

Clean reconstruction. Page 5: variance of independent inputs; large- N /Nscaling 的 failure; E/I balance.

What the note is saying. 本页的中心对象是 kernel/convolution 与 coupled network。原笔记将它们放进以下链条: variance of independent inputs; large- N /Nscaling 的 failure; E/I balance。

Why it follows. 对 E/I Poisson input 逐步计算 finite-bin total charge 的 mean 与 variance。其逻辑后果是: 推导 excitation-inhibition cancellation 和 $W \propto 1/\sqrt{N}$ scaling, 说明大 excitatory/inhibitory currents 如何相减留下 $O(1)$ mean 与 $O(1)$ variance。后面的正式推导会逐项写出 assumptions、shape/units、limiting cases 与 failure conditions。

Figure reading. 先识别图中对象、箭头、参数和坐标系, 再问它表达的是定义、推导、模型预测还是经验观察; 示意图不提供未标注的定量精度。

Stop & Predict

抑制项为什么对 variance 为正?

4.6 Lecture8-NeuralNetworks1.pdf • p. 6

Since the mean is already finite, we scale weights to maintain finite variance and trial-to-trial variability


$$W_E = \frac{\bar{W}_E}{\sqrt{N_E}}, \quad W_I = \frac{\bar{W}_I}{\sqrt{N_I}}$$

In this balanced regime

$$\langle Q_{\Delta t, i}(t) \rangle = 0, \quad \text{Var}(Q_{\Delta t, i}(t)) = \bar{W}_E^2 h_E \Delta t + \bar{W}_I^2 h_I \Delta t$$


for large systems.

Response of LIF to many random Poisson inputs:



Dynamical balance:

Remarkably, van Vreeswijk and Sompolinsky showed that the balance condition is dynamically generated by recurrent neural networks



This is a candidate mechanism for the origin of Poisson-like variability.

Original-note anchor. [Source: Lecture8-NeuralNetworks1.pdf, p. 6]

Clean reconstruction. Page 6: $1/\sqrt{N}$ balanced scaling, irregular spiking, dynamically balanced recurrent networks.

What the note is saying. 本页的中心对象是 Poisson E/I input 与 mean vs variance。原笔记将它们放进以下链条: $1/\sqrt{N}$ balanced scaling, irregular spiking, dynamically balanced recurrent networks。

Why it follows. 推导 excitation-inhibition cancellation 和 $W \propto 1/\sqrt{N}$ scaling, 说明大 excitatory/inhibitory currents 如何相减留下 $O(1)$ mean 与 $O(1)$ variance。其逻辑后果是: 解释 balanced state 与 dynamically generated balance; 不要把“平均 $E=I$ ”误写成每个时刻完全相等。后面的正式推导会逐项写出 assumptions、shape/units、limiting cases 与 failure conditions。

Figure reading. 逐条追踪箭头方向、兴奋/抑制符号、状态变量与外部输入; 结构图说明允许的依赖关系, 不自动证明生物实现。

Stop & Predict

$W \sim 1/N$ 时 mean 和 variance 如何缩放?

5 补全推导与数学支架 / Derivations

5.1 spike-time sum 等于 convolution

【必要前置】 证明一串 kernel responses 可写成 $K * \Delta$ 。

$$\Delta_j(t) = \sum_k \delta(t - t_j^{(k)})$$

$$(K * \Delta_j)(t) = \int dt' K(t - t') \Delta_j(t') = \sum_k K(t - t_j^{(k)})$$

1. Dirac delta 不是普通有限高度函数，而由积分取样性质定义。
2. 把 delta sum 代入 convolution integral。
3. 交换有限/可收敛求和与积分。
4. 每个 delta 把 integrand 取样在 $t' = t_j^{(k)}$ 。

Geometric/computational intuition. 每个 spike 在其时间点“触发”一份相同 kernel，convolution 只是把所有触发响应相加。

Biological interpretation / failure condition. $\delta(0)$ 本身不是可作为普通数计算的有限值；离散代码需用 bin/impulse normalization。

Micro-check

独立 Poisson inputs 的 variance 为什么相加？

5.2 independent Poisson inputs 的 mean 与 variance

【补全推导】 长度 Δt 内总 synaptic charge 如何缩放?

$$Q = \sum_{j=1}^{N_E} W_E K_j - \sum_{j=1}^{N_I} W_I K_j$$

$$E[Q] = (N_E W_E r_E - N_I W_I r_I) \Delta t$$

$$\text{Var}(Q) = (N_E W_E^2 r_E + N_I W_I^2 r_I) \Delta t$$

1. 每个 K_j 是 Poisson count, mean=variance= $r\Delta t$ 。
2. 期望线性相加; independent variables 的 variances 相加。
3. inhibitory sign 在 mean 中为负, 但平方后对 variance 为正。
4. 共享输入/相关 spikes 会额外产生 covariance terms。

Geometric/computational intuition. mean 关心带符号总和, variance 关心随机振幅平方。

Biological interpretation / failure condition. 忽略 independent assumption 会低估 network fluctuations。

Micro-check

抑制项为什么对 variance 为正?

5.3 为什么 1/N scaling 消灭 fluctuations

【跨页连接】 令每个 weight 为 $\bar{W}/N$ 。

$$E[Q] \sim N \frac{1}{N} = O(1)$$

$$\text{Var}(Q) \sim N \frac{1}{N^2} = O(1/N) \rightarrow 0$$

1. N 个输入各贡献 $O(1/N)$, mean 是 N 项之和。
2. variance 使用 weight squared, 所以每项 $O(1/N^2)$ 。
3. standard deviation $O(1/\sqrt{N})$ 消失。
4. 网络变得近 deterministic, 难以产生 Poisson-like irregularity。

Geometric/computational intuition. 平均很多极小、独立输入会洗掉随机波动。
Biological interpretation / failure condition. 若输入强相关, variance 不一定按 $1/N$ 消失。

Micro-check

$W \sim 1/N$ 时 mean 和 variance 如何缩放?

5.4 balanced $1/\sqrt{N}$ scaling

【模型边界】 如何同时保留 finite mean 与 finite variance?

$$W_E = \bar{W}_E / \sqrt{N_E}, \quad W_I = \bar{W}_I / \sqrt{N_I}$$

$$\text{Var}(Q) = \bar{W}_E^2 r_E \Delta t + \bar{W}_I^2 r_I \Delta t = O(1)$$

$$E[Q] = O(\sqrt{N}) - O(\sqrt{N}) = O(1) \text{ after balance}$$

1. $1/\sqrt{N}$ 使 variance 的 $N \times W^2$ 项保持 $O(1)$ 。
2. 单独的 excitatory/inhibitory mean 各为 $O(\sqrt{N})$ 。
3. 网络必须动态调节 rates/feedback, 使两大 mean 相消到 $O(1)$ 。
4. balance 指统计/动态抵消, 不是每时刻 $E=I$ 。

Geometric/computational intuition. 巨大的 E 和 I 背景彼此抵消, 留下小 mean 但可观 fluctuations。
Biological interpretation / failure condition. 连接结构、delays、nonlinearities 或 strong correlations 可能改变 scaling。

Micro-check

$W \sim 1/\sqrt{N}$ 时 variance 如何缩放?

6 Cross-page synthesis / 跨页因果与数学链

Dirac delta 让每个 spike time 成为可积分的事件，synaptic kernel 与 spike train 的 convolution 产生连续 current。在大 N limit 中，权重 scaling 必须同时检查 mean 与 variance: $1/N$ 保持 mean 有限却把 fluctuations 压到零；balanced $1/\sqrt{N}$ 让大的 excitation 与 inhibition 在 mean 上相消，同时保留 $O(1)$ fluctuations。




Figure note: schematic reconstruction; it encodes qualitative relations from the lesson and does not invent precise empirical data points.

7 Worked examples and transfer

7.1 finite-bin scaling 数值

【原课/核心例题】 Prompt. $N=10,000$ ，独立输入；比较 $W=1/N$ 与 $W=1/\sqrt{N}$ 。

Worked solution. $1/N$ 时 $\text{mean} \sim 1$ 、 $\text{variance} \sim 10^{-4}$ ； $1/\sqrt{N}$ 时未经 balance 的 $\text{mean} \sim 100$ 、 $\text{variance} \sim 1$ 。若 E/I mean 相消，净 mean 可回到 $O(1)$ 。

Check. 必须分别写 mean、variance；只说“总输入有限”会遗漏 fluctuation。

7.2 kernel sum

【跨课连接】 Prompt. spikes 在 1、3 ms， $K(t)=e^{-t/\tau}H(t)$ 。

Worked solution. $\text{current} \propto e^{-(t-1)/\tau}H(t-1)+e^{-(t-3)/\tau}H(t-3)$ 。

Check. 第二个 spike 在 $t < 3$ ms 不应贡献。

Micro-check

Explain in your own words. 用不超过 120 字解释：本课从 source page 1 到最后一页，究竟把哪一个输入、状态、统计量或学习规则变成了可检验 prediction?

Self-reflection. 你最可能犯的是 concept、symbol、algebra、assumption 还是 causality error? 写出一个具体例子。

8 Formula and notation sheet

1. spike train 的 distribution 表示

$$\Delta(t) = \sum_k \delta(t - t_k)$$

Conditions / conventions: 通过积分定义

2. synaptic filtering

$$(K * \Delta)(t) = \int K(t - t') \Delta(t') dt'$$

Conditions / conventions: causal K 时只依赖过去

3. independent sum variance

$$\text{Var}(\sum a_i X_i) = \sum a_i^2 \text{Var}(X_i)$$

Conditions / conventions: X_i independent

4. mean-field weak weights

$$W \sim 1/N$$

Conditions / conventions: variance $\rightarrow 0$ under independence

5. balanced-network scaling

$$W \sim 1/\sqrt{N}$$

Conditions / conventions: E/I cancellation required

6. balanced net mean

$$E[Q_E + Q_I] = O(1)$$

Conditions / conventions: large signed currents cancel

9 Bilingual glossary

中文	English / symbol	Operational meaning
Dirac delta	Dirac delta	在积分中取样的 generalized function/distribution。
卷积	convolution	把输入历史按 kernel 平移加权的运算。
突触核	synaptic kernel	单个 presynaptic spike 引起的时间响应。
循环权重	recurrent weight	网络内部 neuron $j \rightarrow i$ 的连接强度。
输入权重	input weight	外部输入 neuron $\rightarrow$ recurrent neuron 的连接。
激发-抑制平衡	excitation-inhibition balance	大 E/I currents 在 mean 上近似抵消的 regime。
动态平衡	dynamic balance	balance 由 recurrent feedback 在线产生, 而非预先逐时刻相等。
数量级	order of magnitude	随 N 增长的主导 scaling, 如 $O(1)$ 、 $O(\sqrt{N})$ 。
不规则放电	irregular spiking	ISI 高变异、近 Poisson-like 的 spike timing。

10 Common traps, assumptions, and limitations

1. 把 $\delta(t)$ 当作 $t=0$ 时的普通无限数。
2. convolution 中把 $K(t-t')$ 与 $K(t')$ 的时间方向写反。
3. variance 计算忘记 weight 要平方。
4. inhibition 对 mean 为负，但对 variance 的贡献仍为正。
5. 只检查 mean scaling, 不检查 variance。
6. 把 E/I balance 误写成每个瞬间 excitation 与 inhibition 完全相等。

Course-specific risk boundary. 这是全课程最容易因 scaling 跳步而失真的一课。禁止只报结论；必须把 mean 与 variance 分别计算，并明确独立性假设。

11 Cumulative Knowledge Check

Do not turn to the Hint Bank until you have written a first attempt.

1. δ 的核心积分性质是什么？

2. 为什么 $K \cdot \Delta$ 等于每个 spike-triggered kernel 的和？

3. W_{ij} 的方向 convention 是什么？

4. 独立 Poisson inputs 的 variance 为什么相加？

5. 抑制项为什么对 variance 为正？

6. $W \sim 1/N$ 时 mean 和 variance 如何缩放？

7. $W \sim 1/\sqrt{N}$ 时 variance 如何缩放？

8. $1/\sqrt{N}$ 时为什么还需要 balance？

9. dynamic balance 与静态设置 $E=I$ 的区别？

10. shared input 会如何改变 variance scaling？

11. causal kernel 的含义？

12. 为何 balanced network 可产生 irregular spiking？

13. 公式表中的“spike train 的 distribution 表示”解决什么问题？写出适用条件与一个 sanity check。

14. 公式表中的“synaptic filtering”解决什么问题？写出适用条件与一个 sanity check。

15. 公式表中的“independent sum variance”解决什么问题？写出适用条件与一个 sanity check。

16. 公式表中的 “mean-field weak weights” 解决什么问题？ 写出适用条件与一个 sanity check。

12 Hint Bank

1. **Hint 1.** 先识别对象、变量与假设。
Hint 2. 写出最相关的定义或方程，再代入。
Hint 3. 检查单位、shape、符号与极限情况。
2. **Hint 1.** 先识别对象、变量与假设。
Hint 2. 写出最相关的定义或方程，再代入。
Hint 3. 检查单位、shape、符号与极限情况。
3. **Hint 1.** 先识别对象、变量与假设。
Hint 2. 写出最相关的定义或方程，再代入。
Hint 3. 检查单位、shape、符号与极限情况。
4. **Hint 1.** 先识别对象、变量与假设。
Hint 2. 写出最相关的定义或方程，再代入。
Hint 3. 检查单位、shape、符号与极限情况。
5. **Hint 1.** 先识别对象、变量与假设。
Hint 2. 写出最相关的定义或方程，再代入。
Hint 3. 检查单位、shape、符号与极限情况。
6. **Hint 1.** 先识别对象、变量与假设。
Hint 2. 写出最相关的定义或方程，再代入。
Hint 3. 检查单位、shape、符号与极限情况。
7. **Hint 1.** 先识别对象、变量与假设。
Hint 2. 写出最相关的定义或方程，再代入。
Hint 3. 检查单位、shape、符号与极限情况。
8. **Hint 1.** 先识别对象、变量与假设。
Hint 2. 写出最相关的定义或方程，再代入。
Hint 3. 检查单位、shape、符号与极限情况。
9. **Hint 1.** 先识别对象、变量与假设。
Hint 2. 写出最相关的定义或方程，再代入。
Hint 3. 检查单位、shape、符号与极限情况。
10. **Hint 1.** 先识别对象、变量与假设。
Hint 2. 写出最相关的定义或方程，再代入。
Hint 3. 检查单位、shape、符号与极限情况。
11. **Hint 1.** 先识别对象、变量与假设。
Hint 2. 写出最相关的定义或方程，再代入。
Hint 3. 检查单位、shape、符号与极限情况。
12. **Hint 1.** 先识别对象、变量与假设。
Hint 2. 写出最相关的定义或方程，再代入。
Hint 3. 检查单位、shape、符号与极限情况。
13. **Hint 1.** 先从“spike train 的 distribution 表示”对应的变量关系入手。
Hint 2. 把条件“通过积分定义”逐字转换为 assumption。
Hint 3. 写公式，再检查至少一种极端参数或单位。
14. **Hint 1.** 先从“synaptic filtering”对应的变量关系入手。
Hint 2. 把条件“causal K 时只依赖过去”逐字转换为 assumption。
Hint 3. 写公式，再检查至少一种极端参数或单位。

15. **Hint 1.** 先从 “independent sum variance” 对应的变量关系入手。
Hint 2. 把条件 “ X_i independent” 逐字转换为 assumption。
Hint 3. 写公式, 再检查至少一种极端参数或单位。
16. **Hint 1.** 先从 “mean-field weak weights” 对应的变量关系入手。
Hint 2. 把条件 “variance $\rightarrow 0$ under independence” 逐字转换为 assumption。
Hint 3. 写公式, 再检查至少一种极端参数或单位。

13 Complete Answer Key with reasoning

1. $\int f(t)\delta(t-t_0)dt=f(t_0)$ 。
2. delta 在每个 spike time 对 $K(t-t')$ 取样。
3. j 是 presynaptic/source, i 是 postsynaptic/target。
4. covariance terms 为零。
5. variance 中 coefficient 被平方。
6. mean $O(1)$, variance $O(1/N)\rightarrow 0$ 。
7. $O(1)$ 。
8. E/I mean 各自 $O(\sqrt{N})$, 不相消会使净输入发散。
9. 前者由 recurrent dynamics 随时间调节, 允许瞬时差异和 fluctuations。
10. 引入正 covariance terms, 波动可能不随 N 平均掉。
11. $K(t<0)=0$, 当前 response 只由过去 spikes 决定。
12. 有限 $O(1)$ fluctuations 持续推动膜电位随机接近 threshold。
13. 适用条件/约定: 通过积分定义。sanity check 应检查单位、符号、极限或 shape 是否与定义一致。

$$\Delta(t) = \sum_k \delta(t - t_k)$$

14. 适用条件/约定: causal K 时只依赖过去。sanity check 应检查单位、符号、极限或 shape 是否与定义一致。

$$(K * \Delta)(t) = \int K(t - t')\Delta(t')dt'$$

15. 适用条件/约定: X_i independent。sanity check 应检查单位、符号、极限或 shape 是否与定义一致。

$$\text{Var}(\sum a_i X_i) = \sum a_i^2 \text{Var}(X_i)$$

16. 适用条件/约定: variance $\rightarrow 0$ under independence。sanity check 应检查单位、符号、极限或 shape 是否与定义一致。

$$W \sim 1/N$$

14 Source-page concordance and coverage audit

Source file	Page	Coverage status
Lecture8-NeuralNetworks1.pdf	1	Main source-page unit: thumbnail, reconstruction, explanation, prediction question.
Lecture8-NeuralNetworks1.pdf	2	Main source-page unit: thumbnail, reconstruction, explanation, prediction question.
Lecture8-NeuralNetworks1.pdf	3	Main source-page unit: thumbnail, reconstruction, explanation, prediction question.
Lecture8-NeuralNetworks1.pdf	4	Main source-page unit: thumbnail, reconstruction, explanation, prediction question.
Lecture8-NeuralNetworks1.pdf	5	Main source-page unit: thumbnail, reconstruction, explanation, prediction question.
Lecture8-NeuralNetworks1.pdf	6	Main source-page unit: thumbnail, reconstruction, explanation, prediction question.

15 Errata, uncertainty log, and external endnotes

15.1 Errata / source cautions

1. Page 2 的 crossed-out 手写不影响 delta/convolution 核心推导。
2. Page 5 的 $1/N$ conclusion 依赖独立 Poisson inputs; 相关输入需加入 covariance terms.
3. Page 6 的 balanced state 是候选机制, 不应写成所有 cortical irregularity 的唯一来源。

15.2 Uncertainty log

No unresolved handwriting uncertainty changes a core definition, equation, figure interpretation, or answer in this companion. Where handwriting was potentially ambiguous, the source-page image is preserved and the reconstruction avoids claiming unverified detail.

15.3 External endnotes

No external web or textbook source was used to replace the uploaded notes. Added material is limited to necessary mathematical scaffolding, explicit assumptions, standard sanity checks, and clearly labeled transfer examples.

15.4 Final self-audit

All source pages listed above were visually inspected. Equations were checked for symbol definitions, units/shapes, assumptions, algebraic transitions, limiting cases, and failure conditions. The PDF is static and contains no interactive form fields or scripts.