

NEUROSCI 366

Lecture 9

神经网络 II——Synaptic Dynamics and Firing-Rate Models

Source-aligned · Static · Searchable · Printable

Source files

- Lecture9-NeuralNetworks2.pdf

Production version: 2026-08-22

Reader profile: neuroscience undergraduate education; mathematics scaffolded from high-school algebra/trigonometry to the formal computational-neuroscience level.

This companion preserves source-page order, distinguishes source material from necessary scaffolding and extensions, and places hints/answers after the lesson. It is a static PDF: no forms, JavaScript, hidden-answer widgets, passwords, or DRM.

Contents

1	How to use this companion	2
2	Learning objectives and prerequisite dependency map	2
3	Five-minute prerequisite diagnostic	2
4	Source-aligned lesson / 按原笔记页序	3
4.1	Lecture9-NeuralNetworks2.pdf · p. 1	3
4.2	Lecture9-NeuralNetworks2.pdf · p. 2	4
4.3	Lecture9-NeuralNetworks2.pdf · p. 3	5
4.4	Lecture9-NeuralNetworks2.pdf · p. 4	6
4.5	Lecture9-NeuralNetworks2.pdf · p. 5	7
5	补全推导与数学支架 / Derivations	8
5.1	integrating factor 与 causal kernel	8
5.2	exponential convolution $\leftrightarrow$ synaptic-current ODE	9
5.3	从 spike averages 到 rate model	10
5.4	feedforward layer composition	11
6	Cross-page synthesis / 跨页因果与数学链	12
7	Worked examples and transfer	12
7.1	exponential kernel normalization	12
7.2	选择 rate approximation	12
8	Formula and notation sheet	14
9	Bilingual glossary	14
10	Common traps, assumptions, and limitations	14
11	Cumulative Knowledge Check	16
12	Hint Bank	17
13	Complete Answer Key with reasoning	18
14	Source-page concordance and coverage audit	19
15	Errata, uncertainty log, and external endnotes	19
15.1	Errata / source cautions	19
15.2	Uncertainty log	19
15.3	External endnotes	19
15.4	Final self-audit	19

1 How to use this companion

1. 先用 5-minute diagnostic 暴露前置缺口；不要立即翻答案。
2. 按原笔记页序阅读 source-page units：先看原页，再读 clean reconstruction 与补全逻辑。
3. 遇到公式按“问题 → 符号/shape/units → assumptions → 一行一步推导 → intuition → biological meaning → sanity check → failure”阅读。
4. 完成 Cumulative Knowledge Check；只在需要时依次打开 Hint 1、2、3。
5. 至少隔一个 page break 后再核对 Answer Key，并记录错误类型：concept、symbol、algebra、assumption、correlation/causation。

Source hierarchy. 原笔记是内容权威；本书中的“【必要前置】/【补全推导】/【跨课连接】/【延伸】”是为了补齐数学或迁移，不替代源材料。无法确认的内容必须进入 Uncertainty Log。

2 Learning objectives and prerequisite dependency map

- 定义并区分：integrating factor。
- 从第一原则推导：causal exponential kernel。
- 解释几何/计算直觉：synaptic-current ODE。
- 连接生物学解释：spike averaging。
- 诊断 assumptions 与 failure modes：F-I nonlinearity。
- 把概念迁移到新神经科学问题：rate dynamics。

Dependency map

integrating factor → causal exponential kernel → synaptic-current ODE → spike averaging → F-I nonlinearity → rate dynamics

Core question

线性系统的 exponential memory 如何等价于 synaptic ODE, 并在时间尺度分离下从 spiking network 过渡到 firing-rate model?

3 Five-minute prerequisite diagnostic

1. integrating factor 为什么选 $e^{t/\tau}$? (卡住时先看 Source-page unit 1, 再看补全推导。)
2. causal exponential kernel 在 $t < 0$ 的值? (卡住时先看 Source-page unit 2, 再看补全推导。)
3. kernel area 为 1 有什么意义? (卡住时先看 Source-page unit 3, 再看补全推导。)
4. 如何把 $K \cdot \text{input}$ 改写为 ODE? (卡住时先看 Source-page unit 4, 再看补全推导。)
5. N neurons 的 voltage+synaptic-current model 有多少连续 ODE states? (卡住时先看 Source-page unit 5, 再看补全推导。)

Scoring guide: 4–5 confident answers → proceed; 2–3 → use the prerequisite labels; 0–1 → read the formula/notation sheet once before the source-aligned lesson.

4 Source-aligned lesson / 按原笔记页序

4.1 Lecture9-NeuralNetworks2.pdf • p. 1

Detour back into differential equations:

Let's explicitly solve

$$\tau \frac{dx}{dt} = -x + \underbrace{I(t)}_{\text{Time dependent}}$$

The trick is to multiply by $e^{t/\tau}$ and rearrange

$$\tau \frac{dx}{dt} e^{t/\tau} = -x e^{t/\tau} + I e^{t/\tau}$$

$$\tau \left(\frac{dx}{dt} e^{t/\tau} + \frac{1}{\tau} x e^{t/\tau} \right) = I e^{t/\tau}$$

$$\frac{d}{dt} (x e^{t/\tau}) = \frac{1}{\tau} I e^{t/\tau}$$

Integrate both sides from $-\infty$ to t .

$$x(t) e^{t/\tau} = \int_{-\infty}^t dt' \frac{1}{\tau} I(t') e^{t'/\tau}$$

$$x(t) = \int_{-\infty}^t dt' \frac{1}{\tau} e^{-(t-t')/\tau} I(t')$$

Let $K_s^{(e)}(t)$ denote the exponential kernel

$$K_s^{(e)}(t) = \begin{cases} \frac{1}{\tau} e^{-t/\tau}, & t \geq 0 \\ 0, & t < 0 \end{cases}$$

Then

$$x(t) = \int_{-\infty}^{\infty} dt' K_s^{(e)}(t-t') I(t') = (K_s^{(e)} * I)(t)$$

Original-note anchor. [Source: Lecture9-NeuralNetworks2.pdf, p. 1]

Clean reconstruction. Page 1: time-dependent linear ODE 的 integrating-factor solution; exponential kernel 与 convolution.

What the note is saying. 本页的中心对象是 integrating factor 与 causal exponential kernel。原笔记将它们放进以下链条: time-dependent linear ODE 的 integrating-factor solution; exponential kernel 与 convolution.

Why it follows. 完整推导 $\tau dx/dt = -x + I(t)$ 的 integrating-factor solution 和 causal exponential kernel; 解释过去输入的加权记忆。其逻辑后果是: 证明 exponential convolution 可等价写成 first-order synaptic-current ODE, 并区分 membrane time constant、synaptic time constant、rate-response time constant。后面的正式推导会逐项写出 assumptions、shape/units、limiting cases 与 failure conditions.

Figure reading. 先识别图中对象、箭头、参数和坐标系, 再问它表达的是定义、推导、模型预测还是经验观察; 示意图不提供未标注的定量精度。

Stop & Predict

integrating factor 为什么选 $e^{t/\tau}$?

4.2 Lecture9-NeuralNetworks2.pdf • p. 2

Exponential synapses:

Recall the sub-threshold dynamics of a spiking neural network.

$$C \frac{dV_i}{dt} = -G_L (V_i - E_L) + I_i(t)$$

$$I_i(t) = \sum_{j=1}^N \underbrace{W_{ij}}_{\text{weights}} \underbrace{(K_s * \Delta_j)}_{\text{spike train}}(t) + \sum_{j=1}^M \underbrace{u_{ij}}_{\text{weights}} \underbrace{(K_s * X_j)}_{\text{spike train}}(t)$$

We said that the shape of K_s is approximately a double exponential. However, rise times can be fast, and it's often convenient to choose K_s as a single exponential.

$$K_s(t) = K_s^{(e)}(t)$$

Then we can write the synaptic current as

$$I_i(t) = \left(K_s^{(e)} * \left(\sum_{j=1}^N W_{ij} \Delta_j + \sum_{j=1}^M u_{ij} X_j \right) \right)(t)$$

and recognize it as the solution to

$$\tau_s \frac{dI_i}{dt} = -I_i + \sum_{j=1}^N W_{ij} \Delta_j + \sum_{j=1}^M u_{ij} X_j$$

where τ_s is the synaptic time constant. Our spiking neural network thus corresponds to $2N$ coupled differential equations

$$C \frac{dV_i}{dt} = -G_L (V_i - E_L) + I_i$$

$$\tau_s \frac{dI_i}{dt} = -I_i + \sum_{j=1}^N W_{ij} \Delta_j + \sum_{j=1}^M u_{ij} X_j$$

plus an integrate-and-fire mechanism that couples V_i and Δ_i in the usual way.

Original-note anchor. [Source: Lecture9-NeuralNetworks2.pdf, p. 2]

Clean reconstruction. Page 2: exponential synapse; synaptic-current ODE; spiking network of the $2N$ coupled equations.

What the note is saying. 本页的中心对象是 synaptic-current ODE 与 spike averaging。原笔记将它们放进以下链条: exponential synapse; synaptic-current ODE; spiking network 的 $2N$ coupled equations。

Why it follows. 把 spiking network 写成 voltage-current 两套 coupled ODE, 并说明 integrate-and-fire reset 如何额外耦合。其逻辑后果是: 证明 exponential convolution 可等价写成 first-order synaptic-current ODE, 并区分 membrane time constant、synaptic time constant、rate-response time constant。后面的正式推导会逐项写出 assumptions、shape/units、limiting cases 与 failure conditions。

Figure reading. 逐条追踪箭头方向、兴奋/抑制符号、状态变量与外部输入; 结构图说明允许的依赖关系, 不自动证明生物实现。

Stop & Predict

causal exponential kernel 在 $t < 0$ 的值?

4.3 Lecture9-NeuralNetworks2.pdf • p. 3

Firing Rate Models:

Poisson variability suggests that firing rates matter most to neural coding. Do we need to explicitly model spiking?

Let's average the current equation over Poisson variability and a small time interval Δt

$$\frac{1}{\Delta t} \int_t^{t+\Delta t} dt' \tau_s \frac{dI_i}{dt'} = \frac{1}{\Delta t} \int_t^{t+\Delta t} dt' (-I_i) + \sum_{j=1}^N W_{ij} \frac{1}{\Delta t} \left\langle \int_t^{t+\Delta t} dt' r_j(t') \right\rangle + \sum_{j=1}^M u_{ij} \frac{1}{\Delta t} \left\langle \int_t^{t+\Delta t} dt' x_j(t') \right\rangle$$

$$\frac{1}{\Delta t} \tau_s \frac{dI_i}{dt} \Delta t = -\frac{1}{\Delta t} I_i \Delta t + \sum_{j=1}^N W_{ij} \frac{1}{\Delta t} r_j \Delta t + \sum_{j=1}^M u_{ij} \frac{1}{\Delta t} x_j \Delta t$$


where r_j is the firing rate of the j^{th} input neuron, and we assumed that Δt is small enough that I_i and dI_i/dt do not change appreciably in t to $t+\Delta t$.

This becomes a complete firing rate model if we compute r_i from I_i with an f - I curve.

$$\tau_s \frac{dI_i}{dt} = -I_i + \sum_{j=1}^N W_{ij} r_j + \sum_{j=1}^M u_{ij} x_j \quad (I)$$

$$r_i = f(I_i)$$

Typical choices for f - I curves



Original-note anchor. [Source: Lecture9-NeuralNetworks2.pdf, p. 3]

Clean reconstruction. Page 3: 从 Poisson spike variability averaging 到 firing-rate model; f - I function choices.

What the note is saying. 本页的中心对象是 f - I nonlinearity 与 rate dynamics。原笔记将它们放进以下链条：从 Poisson spike variability averaging 到 firing-rate model; f - I function choices。

Why it follows. 解释 temporal averaging 如何从 spike counts 得到 rate equations; 明确 approximation 所需的 time-scale assumptions。其逻辑后果是：比较 threshold-linear、sigmoid、linear、tanh f - I functions 的范围、饱和、负值和生物解释。后面的正式推导会逐项写出 assumptions、shape/units、limiting cases 与 failure conditions。

Figure reading. 先明确横纵轴、单位、归一化与每条曲线改变的唯一参数；区分示意趋势、模型预测和真正测得的数据点。

Stop & Predict

kernel area 为 1 有什么意义?

4.4 Lecture9-NeuralNetworks2.pdf • p. 4

A more realistic model allows firing rate changes to take some time.

$$\left. \begin{aligned} \tau_s \frac{dI_i}{dt} &= -I_i + \sum_{j=1}^N W_{ij} r_j + \sum_{j=1}^M u_{ij} x_j \\ \tau_h \frac{dr_i}{dt} &= -r_i + f(I_i) \end{aligned} \right] \quad (\text{II})$$

where τ_h is the exponential time scale of the firing rate response.

If $\tau_s \ll \tau_h$, we can replace I_i with its steady-state

$$\tau_h \frac{dr_i}{dt} = -r_i + f\left(\sum_{j=1}^N W_{ij} r_j + \sum_{j=1}^M u_{ij} x_j\right) \quad (\text{III})$$

We thus have three versions of the firing rate equations. (II) is most general but rarely used in practice. (I) assumes fast firing rate changes. (III) assumes fast synapses and is most commonly used.

Original-note anchor. [Source: Lecture9-NeuralNetworks2.pdf, p. 4]

Clean reconstruction. Page 4: 加入 firing-rate response time; 三种 rate-model approximations.

What the note is saying. 本页的中心对象是 feedforward layers 与 integrating factor。原笔记将它们放进以下链条：加入 firing-rate response time; 三种 rate-model approximations。

Why it follows. 证明 exponential convolution 可等价写成 first-order synaptic-current ODE，并区分 membrane time constant、synaptic time constant、rate-response time constant。其逻辑后果是：逐项比较笔记中的三种 rate-model forms：最一般、fast rate/slow synapse、fast synapse 等近似。后面的正式推导会逐项写出 assumptions、shape/units、limiting cases 与 failure conditions。

Figure reading. 先识别图中对象、箭头、参数和坐标系，再问它表达的是定义、推导、模型预测还是经验观察；示意图不提供未标注的定量精度。

Stop & Predict

如何把 $K \cdot \text{input}$ 改写为 ODE?

4.5 Lecture9-NeuralNetworks2.pdf • p. 5


Feedforward networks:

If $W_{ij} = 0$, then the steady-state firing rates are simply

$$h_i = f\left(\sum_{j=1}^N u_{ij} x_j\right) \text{ or } \underline{h} = f(\underline{u} \underline{x})$$

vector form

This can be repeated many times to form layered architectures



This layering is the foundation of deep neural networks.

Original-note anchor. [Source: Lecture9-NeuralNetworks2.pdf, p. 5]

Clean reconstruction. Page 5: feedforward layered networks 与 deep neural-network foundation.

What the note is saying. 本页的中心对象是 causal exponential kernel 与 synaptic-current ODE。原笔记将它们放进以下链条: feedforward layered networks 与 deep neural-network foundation。

Why it follows. 从 $W=0$ steady state 引出 feedforward layer composition, 并连接 deep networks, 但不要提前进入 Lecture 11 的训练算法。其逻辑后果是: 比较 threshold-linear、sigmoid、linear、tanh F-I functions 的范围、饱和、负值和生物解释。后面的正式推导会逐项写出 assumptions、shape/units、limiting cases 与 failure conditions。

Figure reading. 逐条追踪箭头方向、兴奋/抑制符号、状态变量与外部输入; 结构图说明允许的依赖关系, 不自动证明生物实现。

Stop & Predict

N neurons 的 voltage+synaptic-current model 有多少连续 ODE states?

5 补全推导与数学支架 / Derivations

5.1 integrating factor 与 causal kernel

【必要前置】 求 $\tau \frac{dx}{dt} = -x + I(t)$ 的任意 time-varying input 解。

$$\frac{d}{dt} \left(x e^{t/\tau} \right) = \frac{1}{\tau} I(t) e^{t/\tau}$$

$$x(t) = x(t_0) e^{-(t-t_0)/\tau} + \int_{t_0}^t \frac{dt'}{\tau} e^{-(t-t')/\tau} I(t')$$

$$K_{\tau}(t) = \frac{1}{\tau} e^{-t/\tau} H(t)$$

1. 乘以 $e^{t/\tau}$, 使左侧成为 product derivative。
2. 从 t_0 积分到 t , 保留 initial-condition term。
3. 若把 $t_0 \rightarrow -\infty$ 且初始 transient 已消失, 得到纯 convolution。
4. kernel 权重随过去时间差指数衰减, 面积为 1。

Geometric/computational intuition. 当前 state 是所有过去输入的加权平均, 最近输入权重大。
Biological interpretation / failure condition. τ 或 coefficients 随时间/状态变化时, 不再是固定 linear convolution。

Micro-check

如何把 $K * \text{input}$ 改写为 ODE?

5.2 exponential convolution ↔ synaptic-current ODE

【补全推导】 把每个 spike 的 exponential current sum 改写为 state equation。

$$I_i(t) = K\tau_s * \left(\sum_j W_{ij}\Delta_j + \sum_j U_{ij}X_j \right)$$

$$\tau_s \dot{I}_i = -I_i + \sum_j W_{ij}\Delta_j + \sum_j U_{ij}X_j$$

1. $K\tau$ 是一阶低通系统的 impulse response。
2. 对 convolution 求导并利用 $\tau K' + K = \delta$ 。
3. 每个 network neuron 需要 voltage state V_i 和 synaptic-current state I_i , 共 $2N$ ODEs。
4. IF threshold/reset 作为事件规则额外耦合 spike train。

Geometric/computational intuition. 不必保存全部 spike history; 一个递归 state I_i 就压缩了指数加权过去。

Biological interpretation / failure condition. double-exponential、NMDA 或 short-term plasticity 需要更多 states。

Micro-check

N neurons 的 voltage+synaptic-current model 有多少连续 ODE states?

5.3 从 spike averages 到 rate model

【跨页连接】 何时可以把随机 spikes 替换为 smooth rate h_i ?

$$\tau_s \dot{I}_i = -I_i + \sum_j W_{ij} h_j + \sum_j U_{ij} \chi_j$$

$$h_i = \mathcal{F}(I_i)$$

$$\tau_r \dot{h}_i = -h_i + \mathcal{F}(I_i)$$

1. 在比 ISI 长、比 network changes 短的窗口平均 spike train。
2. 假设窗口内 I 与 rates 变化不大，将 expected spike count/ Δt 替换为 h 。
3. 最简模型假设 rate 瞬时等于 F-I curve；更一般模型赋予 rate response time τ_r 。
4. 若 $\tau_s \ll \tau_r$ 或 $\tau_r \ll \tau_s$ ，可消去 fast variable，得到不同 reduced forms。

Geometric/computational intuition. rate variable 是动力学状态，不只是事后 PSTH；它近似大量 spikes 的局部平均。

Biological interpretation / failure condition. 稀疏 spikes、精确 synchrony、快速 transient 或 multimodal variability 时 averaging 失效。

Micro-check

$h=F(I)$ 隐含什么时间尺度假设？

5.4 feedforward layer composition

【模型边界】 $W=0$ 、steady state 时如何形成深层网络？

$$\mathbf{h}^{(1)} = \mathcal{F}(U^{(1)}\mathbf{x})$$

$$\mathbf{h}^{(\ell)} = \mathcal{F}(U^{(\ell)}\mathbf{h}^{(\ell-1)})$$

1. 去掉 recurrence 后每层只依赖前一层。
2. fast steady-state approximation 将 dynamics 变成静态 nonlinear map。
3. 重复 composition 形成 deep feedforward architecture。
4. 这里仅建立表示结构，权重训练在 Lecture 11。

Geometric/computational intuition. 每层做 linear mixing + pointwise nonlinearity，逐级构造新 features。

Biological interpretation / failure condition. 真实 recurrent/sensory networks 可能没有清晰同步层或 steady-state separation。

Micro-check

$\tau_r \frac{dh}{dt} = -h + F(I)$ 增加了什么？

6 Cross-page synthesis / 跨页因果与数学链

一阶线性 ODE 的解是对过去输入的 causal exponential convolution; 反过来, exponential convolution 可用一个额外 state variable 的 ODE 实现。这一等价让 spiking network 变成 voltage+current 的 coupled system, 并在时间平均与 time-scale separation 下导出 rate models。不同 rate-model forms 对哪些变量被视为 fast/slow 有不同假设, 不能只凭外观互换。




Figure note: schematic reconstruction; it encodes qualitative relations from the lesson and does not invent precise empirical data points.

7 Worked examples and transfer

7.1 exponential kernel normalization

【原课/核心例题】 Prompt. $K(t) = e^{-t/\tau}/\tau$, $t \geq 0$.

Worked solution. $\int_0^\infty K(t) dt = 1$; 因此常输入 I_0 的稳态输出仍是 I_0 。

Check. 若遗漏 $1/\tau$, kernel area 会是 τ , 改变 gain 和单位。

7.2 选择 rate approximation

【跨课连接】 Prompt. synapse 很慢、rate relaxation 很快。

Worked solution. 设 $\tau_r dh/dt \approx 0$, 得到 $h \approx F(I)$, 保留 $\tau_s dI/dt$; 即 fast-rate/slow-synapse form。

Check. 近似必须明确被忽略的是哪一个 derivative, 而不是只说“快”。

Micro-check

Explain in your own words. 用不超过 120 字解释：本课从 source page 1 到最后一页，究竟把哪一个输入、状态、统计量或学习规则变成了可检验 prediction?

Self-reflection. 你最可能犯的是 concept、symbol、algebra、assumption 还是 causality error? 写出一个具体例子。

8 Formula and notation sheet

1. causal exponential kernel

$$K_\tau(t) = e^{-t/\tau} H(t) / \tau$$

Conditions / conventions: $\tau > 0$

2. linear low-pass solution

$$x = K_\tau * I$$

Conditions / conventions: transient 已处理

3. exponential synapse ODE

$$\tau_s \dot{I} = -I + u(t)$$

Conditions / conventions: 单指数 kernel

4. instantaneous F-I approximation

$$h = \mathcal{F}(I)$$

Conditions / conventions: rate fast

5. dynamic rate response

$$\tau_r \dot{h} = -h + \mathcal{F}(I)$$

Conditions / conventions: smooth population rate

6. feedforward layer

$$\mathbf{h}^{(\ell)} = \mathcal{F}(W^{(\ell)} \mathbf{h}^{(\ell-1)})$$

Conditions / conventions: shape-compatible weights

9 Bilingual glossary

中文	English / symbol	Operational meaning
积分因子	integrating factor	把一阶线性 ODE 左侧变成乘积导数的函数。
因果核	causal kernel	负时间为零、只依赖过去输入的 filter。
突触时间常数	synaptic time constant	synaptic current 衰减/积分的时间尺度。
rate response time	firing-rate response time	population rate 向 $\mathcal{F}(I)$ 调整的时间尺度。
时间尺度分离	time-scale separation	一个变量比另一个快得多，从而可近似消去。
F-I 函数	F-I function	input current 到 steady firing rate 的非线性。
阈值线性	threshold-linear	低于阈值为零，高于阈值线性增长。
sigmoid	sigmoid	平滑、有上下饱和的 S 形函数。
前馈网络	feedforward network	信息沿层次单向传播、无 recurrent loop 的架构。

10 Common traps, assumptions, and limitations

1. 遗漏 exponential kernel 的 $1/\tau$ normalization。
2. 把 membrane τ 、synaptic τ_s 、rate τ_r 混为一个时间常数。
3. 把统计 firing-rate estimate 自动等同于 dynamical rate variable。
4. 做 fast-variable approximation 却不写被设为零的 derivative。

5. 使用 tanh/linear F-I 时忽略 negative rates 的生物解释问题。
6. 把 feedforward architecture 与 backprop training 混为一谈。

Course-specific risk boundary. 必须区分 “spike-rate statistical description” 和 “dynamical firing-rate variable”；两者相关但并非自动相同。

11 Cumulative Knowledge Check

Do not turn to the Hint Bank until you have written a first attempt.

1. integrating factor 为什么选 $e^{t/\tau}$?

2. causal exponential kernel 在 $t < 0$ 的值?

3. kernel area 为 1 有什么意义?

4. 如何把 $K \cdot \text{input}$ 改写为 ODE?

5. N neurons 的 voltage+synaptic-current model 有多少连续 ODE states?

6. $h = F(I)$ 隐含什么时间尺度假设?

7. $\tau_r \frac{dh}{dt} = -h + F(I)$ 增加了什么?

8. 慢 synapse、快 rate 应保留哪个 dynamic variable?

9. threshold-linear 与 sigmoid 的主要差异?

10. 为什么 tanh 可能产生生物学问题?

11. rate model 何时会失败?

12. feedforward layer 的 shape check 是什么?

13. 公式表中的“causal exponential kernel”解决什么问题? 写出适用条件与一个 sanity check。

14. 公式表中的“linear low-pass solution”解决什么问题? 写出适用条件与一个 sanity check。

12 Hint Bank

1. **Hint 1.** 先识别对象、变量与假设。
Hint 2. 写出最相关的定义或方程，再代入。
Hint 3. 检查单位、shape、符号与极限情况。
2. **Hint 1.** 先识别对象、变量与假设。
Hint 2. 写出最相关的定义或方程，再代入。
Hint 3. 检查单位、shape、符号与极限情况。
3. **Hint 1.** 先识别对象、变量与假设。
Hint 2. 写出最相关的定义或方程，再代入。
Hint 3. 检查单位、shape、符号与极限情况。
4. **Hint 1.** 先识别对象、变量与假设。
Hint 2. 写出最相关的定义或方程，再代入。
Hint 3. 检查单位、shape、符号与极限情况。
5. **Hint 1.** 先识别对象、变量与假设。
Hint 2. 写出最相关的定义或方程，再代入。
Hint 3. 检查单位、shape、符号与极限情况。
6. **Hint 1.** 先识别对象、变量与假设。
Hint 2. 写出最相关的定义或方程，再代入。
Hint 3. 检查单位、shape、符号与极限情况。
7. **Hint 1.** 先识别对象、变量与假设。
Hint 2. 写出最相关的定义或方程，再代入。
Hint 3. 检查单位、shape、符号与极限情况。
8. **Hint 1.** 先识别对象、变量与假设。
Hint 2. 写出最相关的定义或方程，再代入。
Hint 3. 检查单位、shape、符号与极限情况。
9. **Hint 1.** 先识别对象、变量与假设。
Hint 2. 写出最相关的定义或方程，再代入。
Hint 3. 检查单位、shape、符号与极限情况。
10. **Hint 1.** 先识别对象、变量与假设。
Hint 2. 写出最相关的定义或方程，再代入。
Hint 3. 检查单位、shape、符号与极限情况。
11. **Hint 1.** 先识别对象、变量与假设。
Hint 2. 写出最相关的定义或方程，再代入。
Hint 3. 检查单位、shape、符号与极限情况。
12. **Hint 1.** 先识别对象、变量与假设。
Hint 2. 写出最相关的定义或方程，再代入。
Hint 3. 检查单位、shape、符号与极限情况。
13. **Hint 1.** 先从“causal exponential kernel”对应的变量关系入手。
Hint 2. 把条件“ $\tau > 0$ ”逐字转换为 assumption。
Hint 3. 写公式，再检查至少一种极端参数或单位。
14. **Hint 1.** 先从“linear low-pass solution”对应的变量关系入手。
Hint 2. 把条件“transient 已处理”逐字转换为 assumption。
Hint 3. 写公式，再检查至少一种极端参数或单位。

13 Complete Answer Key with reasoning

1. 它使 $\tau x' + x$ 组合成 $\tau e^{-t/\tau}$ 的 product derivative; 具体有 $d(xe^{t/\tau})/dt = e^{t/\tau}(x' + x/\tau)$ 。
2. 0。
3. 对 constant input 的 DC gain 为 1。
4. $\tau_s dI/dt = -I + \text{input}$ 。
5. $2N$, 另有 spike/reset events。
6. rate adjustment 相对 synaptic/input changes 很快。
7. rate 本身的 finite response time/smoothing。
8. 保留 I dynamics, 令 $h \approx F(I)$ 。
9. sigmoid 平滑并饱和; threshold-linear 有硬阈值且高输入不饱和。
10. 输出可为负, 需解释为相对 baseline 的 signed activity 而非 absolute firing rate。
11. 精确 spike timing、synchrony、少量 neurons 或快速 transient 关键时。
12. 若 $W^{(l)}$ 为 $n_l \times n_{l-1}$, 输入 $h^{(l-1)}$ 为 $n_{l-1} \times 1$, 输出为 $n_l \times 1$ 。
13. 适用条件/约定: $\tau > 0$ 。sanity check 应检查单位、符号、极限或 shape 是否与定义一致。

$$K_\tau(t) = e^{-t/\tau} H(t) / \tau$$

14. 适用条件/约定: transient 已处理。sanity check 应检查单位、符号、极限或 shape 是否与定义一致。

$$x = K_\tau * I$$

14 Source-page concordance and coverage audit

Source file	Page	Coverage status
Lecture9-NeuralNetworks2.pdf	1	Main source-page unit: thumbnail, reconstruction, explanation, prediction question.
Lecture9-NeuralNetworks2.pdf	2	Main source-page unit: thumbnail, reconstruction, explanation, prediction question.
Lecture9-NeuralNetworks2.pdf	3	Main source-page unit: thumbnail, reconstruction, explanation, prediction question.
Lecture9-NeuralNetworks2.pdf	4	Main source-page unit: thumbnail, reconstruction, explanation, prediction question.
Lecture9-NeuralNetworks2.pdf	5	Main source-page unit: thumbnail, reconstruction, explanation, prediction question.

15 Errata, uncertainty log, and external endnotes

15.1 Errata / source cautions

1. Page 2 指出真实 synaptic kernel 常为 double exponential; 单指数是为了得到一阶 ODE 的课程近似。
2. Page 3 的 temporal averaging 需要合适窗口和 stationarity 假设。
3. Page 5 只建立 deep network architecture, 不包含权重学习算法。

15.2 Uncertainty log

No unresolved handwriting uncertainty changes a core definition, equation, figure interpretation, or answer in this companion. Where handwriting was potentially ambiguous, the source-page image is preserved and the reconstruction avoids claiming unverified detail.

15.3 External endnotes

No external web or textbook source was used to replace the uploaded notes. Added material is limited to necessary mathematical scaffolding, explicit assumptions, standard sanity checks, and clearly labeled transfer examples.

15.4 Final self-audit

All source pages listed above were visually inspected. Equations were checked for symbol definitions, units/shapes, assumptions, algebraic transitions, limiting cases, and failure conditions. The PDF is static and contains no interactive form fields or scripts.