

NEUROSCI 366

Lecture 11

机器学习——Regression, Gradient Descent, and Backpropagation

Source-aligned · Static · Searchable · Printable

Source files

- Lecture11-MachineLearning.pdf

Production version: 2026-08-22

Reader profile: neuroscience undergraduate education; mathematics scaffolded from high-school algebra/trigonometry to the formal computational-neuroscience level.

This companion preserves source-page order, distinguishes source material from necessary scaffolding and extensions, and places hints/answers after the lesson. It is a static PDF: no forms, JavaScript, hidden-answer widgets, passwords, or DRM.

Contents

1	How to use this companion	2
2	Learning objectives and prerequisite dependency map	2
3	Five-minute prerequisite diagnostic	2
4	Source-aligned lesson / 按原笔记页序	3
4.1	Lecture11-MachineLearning.pdf · p. 1	3
4.2	Lecture11-MachineLearning.pdf · p. 2	4
4.3	Lecture11-MachineLearning.pdf · p. 3	5
4.4	Lecture11-MachineLearning.pdf · p. 4	6
4.5	Lecture11-MachineLearning.pdf · p. 5	7
4.6	Lecture11-MachineLearning.pdf · p. 6	8
5	补全推导与数学支架 / Derivations	9
5.1	Taylor expansion 到 gradient descent	9
5.2	linear regression gradient 与 closed form	10
5.3	deep linear network 的参数化	11
5.4	backpropagation 的 local chain rule	11
6	Cross-page synthesis / 跨页因果与数学链	12
7	Worked examples and transfer	12
7.1	一次 gradient step	12
7.2	backprop shape	12
8	Formula and notation sheet	14
9	Bilingual glossary	14
10	Common traps, assumptions, and limitations	14
11	Cumulative Knowledge Check	16
12	Hint Bank	18
13	Complete Answer Key with reasoning	20
14	Source-page concordance and coverage audit	21

15 Errata, uncertainty log, and external endnotes	21
15.1 Errata / source cautions	21
15.2 Uncertainty log	21
15.3 External endnotes	21
15.4 Final self-audit	22

1 How to use this companion

1. 先用 5-minute diagnostic 暴露前置缺口；不要立即翻答案。
2. 按原笔记页序阅读 source-page units：先看原页，再读 clean reconstruction 与补全逻辑。
3. 遇到公式按“问题 → 符号/shape/units → assumptions → 一行一步推导 → intuition → biological meaning → sanity check → failure”阅读。
4. 完成 Cumulative Knowledge Check；只在需要时依次打开 Hint 1、2、3。
5. 至少隔一个 page break 后再核对 Answer Key，并记录错误类型：concept、symbol、algebra、assumption、correlation/causation。

Source hierarchy. 原笔记是内容权威；本书中的“【必要前置】/【补全推导】/【跨课连接】/【延伸】”是为了补齐数学或迁移，不替代源材料。无法确认的内容必须进入 Uncertainty Log。

2 Learning objectives and prerequisite dependency map

- 定义并区分：dataset (x,y) 。
- 从第一原则推导：architecture。
- 解释几何/计算直觉：loss。
- 连接生物学解释：gradient descent。
- 诊断 assumptions 与 failure modes：linear regression。
- 把概念迁移到新神经科学问题：closed form。

Dependency map

dataset (x,y) → architecture → loss → gradient descent → linear regression → closed form

Core question

supervised learning 如何由 architecture、loss 与 gradient-based learning rule 组成，并用 chain rule 高效训练多层网络？


3 Five-minute prerequisite diagnostic

1. supervised algorithm 的三个设计元素？（卡住时先看 Source-page unit 1，再看补全推导。）
2. gradient 指向哪个方向？（卡住时先看 Source-page unit 2，再看补全推导。）
3. 为什么更新用 $-\eta \nabla L$ ？（卡住时先看 Source-page unit 3，再看补全推导。）
4. linear regression gradient 中 Hebbian-like term 是什么？（卡住时先看 Source-page unit 4，再看补全推导。）
5. XX^T singular 时怎么办？（卡住时先看 Source-page unit 5，再看补全推导。）

Scoring guide: 4–5 confident answers → proceed; 2–3 → use the prerequisite labels; 0–1 → read the formula/notation sheet once before the source-aligned lesson.

4 Source-aligned lesson / 按原笔记页序

4.1 Lecture11-MachineLearning.pdf • p. 1



Original-note anchor. [Source: Lecture11-MachineLearning.pdf, p. 1]

Clean reconstruction. Page 1: supervised learning, classification/regression, architecture/loss/learning rule, deep network notation.

What the note is saying. 本页的中心对象是 dataset (x, y) 与 architecture。原笔记将它们放进以下链条: supervised learning、classification/regression、architecture/loss/learning rule、deep network notation。

Why it follows. 用 digit classification 与 optic-flow regression 解释 supervised dataset (x, y) ; 区分 architecture、loss、optimization/learning rule。其逻辑后果是: 解释 deep linear network 的整体映射仍线性但 parameterization/learning dynamics 非线性。后面的正式推导会逐项写出 assumptions、shape/units、limiting cases 与 failure conditions。

Figure reading. 逐条追踪箭头方向、兴奋/抑制符号、状态变量与外部输入; 结构图说明允许的依赖关系, 不自动证明生物实现。


Stop & Predict

supervised algorithm 的三个设计元素?

4.2 Lecture11-MachineLearning.pdf • p. 2

Linear regression:


Architecture:



Loss function:

$$\begin{aligned} \mathcal{L}(W) &= \frac{1}{P} \sum_{\mu=1}^P (y_{\mu} - \hat{y}_{\mu})^2 \\ &= \frac{1}{P} \sum_{\mu=1}^P (y_{\mu} - \sum_{i=1}^N w_i x_{i\mu})^2 \end{aligned}$$

Quadratic function of W



Gradient descent learning:

$$\mathcal{L}(W + \Delta W) = \underbrace{\mathcal{L}(W) + \sum_{i=1}^N \frac{\partial \mathcal{L}(W)}{\partial w_i} \Delta w_i}_{\text{Leading Taylor series expansion}} + \underbrace{O((\Delta W)^2)}_{\text{Small / Ignore}}$$

$$\Delta \mathcal{L} = \underbrace{\nabla_W \mathcal{L}}_{\text{Gradient}} \cdot \Delta W = \underbrace{\|\nabla_W \mathcal{L}\|}_{\text{Fixed}} \underbrace{\|\Delta W\| \cos \Theta}_{\text{minimize}}$$

$$\Delta W = \underbrace{-\eta}_{\text{Learning rate}} \nabla_W \mathcal{L}$$

Learning rule:

$$\begin{aligned} \Delta w_i &= -\eta \frac{\partial \mathcal{L}}{\partial w_i} = -\eta \frac{1}{P} \sum_{\mu=1}^P 2(y_{\mu} - \hat{y}_{\mu})(-x_{i\mu}) \\ &= \frac{2\eta}{P} \sum_{\mu=1}^P e_{\mu} x_{i\mu} \quad (\text{Three-factor form}) \end{aligned}$$

Original-note anchor. [Source: Lecture11-MachineLearning.pdf, p. 2]**Clean reconstruction.** Page 2: linear regression, squared loss, Taylor expansion, gradient descent, learning rule.**What the note is saying.** 本页的中心对象是 loss 与 gradient descent。原笔记将它们放进以下链条: linear regression、squared loss、Taylor expansion、gradient descent、learning rule。**Why it follows.** 从 squared-error loss 和 first-order Taylor expansion 推导 gradient descent; 解释 gradient、learning rate、loss contours。其逻辑后果是: 用 digit classification 与 optic-flow regression 解释 supervised dataset (x, y) ; 区分 architecture、loss、optimization/learning rule。后面的正式推导会逐项写出 assumptions、shape/units、limiting cases 与 failure conditions。**Figure reading.** 先识别图中对象、箭头、参数和坐标系, 再问它表达的是定义、推导、模型预测还是经验观察; 示意图不提供未标注的定量精度。**Stop & Predict**

gradient 指向哪个方向?

4.3 Lecture11-MachineLearning.pdf • p. 3

Equivalently:

$$\Delta W_i = \frac{\partial \mathcal{L}}{\partial p} \sum_{\mu=1}^p \left(\underbrace{y_{\mu} x_{i\mu}}_{\text{Hebbian}} - \underbrace{\sum_{j=1}^N W_j x_j x_{i\mu}}_{\text{stabilization}} \right)$$

Classic linear regression formula

$$\Delta W = 0 \Rightarrow \frac{\partial \mathcal{L}}{\partial p} (X Y - X X^T W) = 0$$

$$\Rightarrow \underbrace{W}_{N \times 1} = \underbrace{(X X^T)^{-1}}_{N \times N} \underbrace{X Y}_{N \times 1}$$

Original-note anchor. [Source: Lecture11-MachineLearning.pdf, p. 3]

Clean reconstruction. Page 3: Hebbian/stabilization decomposition; closed-form regression solution.

What the note is saying. 本页的中心对象是 linear regression 与 closed form。原笔记将它们放进以下链条：Hebbian/stabilization decomposition; closed-form regression solution。

Why it follows. 用 digit classification 与 optic-flow regression 解释 supervised dataset (x, y) ; 区分 architecture、loss、optimization/learning rule。其逻辑后果是：推导 normal-equation/closed-form least-squares solution, 说明 invertibility、pseudoinverse/regularization 作为必要背景但不要偏离笔记。后面的正式推导会逐项写出 assumptions、shape/units、limiting cases 与 failure conditions。

Figure reading. 先识别图中对象、箭头、参数和坐标系，再问它表达的是定义、推导、模型预测还是经验观察；示意图不提供未标注的定量精度。


Stop & Predict

为什么更新用 $-\eta \nabla L$?

4.4 Lecture11-MachineLearning.pdf • p. 4

Backpropagation algorithm:

We return to the deep network architecture.



Deep linear regression:

Suppose $g(x) = S(x) = x$. Then

$$\hat{y} = W^{(L)} z^{(L)} = W^{(L)} W^{(L-1)} z^{(L-1)} = W^{(L)} W^{(L-1)} \dots W^{(0)} x$$

Input-output mapping is linear

$$\hat{y} = Mx; M = \prod_{l=0}^L W^{(l)}$$

Learning rule and learning dynamics are complex.

For regression

$$\mathcal{L} = \frac{1}{P} \sum_{\mu=1}^P \mathcal{L}_{\mu}$$

$$\mathcal{L}_{\mu} = (y_{\mu} - \hat{y}_{\mu})^2 = e_{\mu}^2$$

As before, we consider gradient-descent learning

$$\Delta W_{ij}^{(l)} = -\eta \frac{\partial \mathcal{L}}{\partial W_{ij}^{(l)}}$$

Original-note anchor. [Source: Lecture11-MachineLearning.pdf, p. 4]

Clean reconstruction. Page 4: deep linear regression 与 backprop setup.

What the note is saying. 本页的中心对象是 backprop chain rule 与 dataset (x, y) 。原笔记将它们放进以下链条: deep linear regression 与 backprop setup。

Why it follows. 解释 deep linear network 的整体映射仍线性但 parameterization/learning dynamics 非线性。其逻辑后果是: 用 digit classification 与 optic-flow regression 解释 supervised dataset (x, y) ; 区分 architecture、loss、optimization/learning rule。后面的正式推导会逐项写出 assumptions、shape/units、limiting cases 与 failure conditions。

Figure reading. 先识别图中对象、箭头、参数和坐标系, 再问它表达的是定义、推导、模型预测还是经验观察; 示意图不提供未标注的定量精度。

Stop & Predict

linear regression gradient 中 Hebbian-like term 是什么?

4.5 Lecture11-MachineLearning.pdf • p. 5

We derive the derivative by repeatedly applying the chain rule from calculus.

$$\begin{aligned}
 \frac{\partial \mathcal{L}}{\partial W_{ij}^{(L)}} &= \frac{1}{P} \sum_{\mu} \frac{\partial \mathcal{L}_{\mu}}{\partial W_{ij}^{(L)}} \\
 &= \frac{1}{P} \sum_{\mu} \frac{\partial \mathcal{L}_{\mu}}{\partial \hat{y}_{\mu}} \frac{\partial \hat{y}_{\mu}}{\partial W_{ij}^{(L)}} \\
 &= \frac{1}{P} \sum_{\mu} \underbrace{\frac{\partial \mathcal{L}_{\mu}}{\partial \hat{y}_{\mu}}}_{-2e_{\mu}} \sum_{k_L=1}^{N_L} \underbrace{\frac{\partial \hat{y}_{\mu}}{\partial z_{k_L \mu}}}_{\frac{1}{W_{k_L}^{(L)}}} \sum_{k_{L-1}=1}^{N_{L-1}} \underbrace{\frac{\partial z_{k_L \mu}}{\partial z_{k_{L-1} \mu}}}_{\frac{1}{W_{k_L, k_{L-1}}^{(L-1)}}} \\
 &\quad \dots \sum_{k_{L+1}=1}^{N_{L+1}} \underbrace{\frac{\partial z_{k_{L+2} \mu}}{\partial z_{k_{L+1} \mu}}}_{\frac{1}{W_{k_{L+2}, k_{L+1}}^{(L+1)}}} \underbrace{\frac{\partial z_{k_{L+1} \mu}}{\partial W_{ij}^{(L)}}}_{\delta_{i, k_{L+1}} z_{j \mu}^{(L)}}
 \end{aligned}$$

The top equation is general and will be reused soon. The linearity of the network and regression loss lead to the lower expression and simple final result.

$$\frac{\partial \mathcal{L}}{\partial W_{ij}^{(L)}} = \frac{2}{P} \sum_{\mu} \left(W^{(L+1)T} W^{(L+2)T} \dots W^{(L)T} e_{\mu} \right)_i z_{j \mu}^{(L)}$$

This is similar to linear regression, but the post-synaptic error becomes a "backpropagated" error.

Deep nonlinear regression:

Next suppose that $f(x) \neq x$, $g(x) = x$, $\mathcal{L}_{\mu} = e_{\mu}^2$.

Most of the above analysis still holds.

Original-note anchor. [Source: Lecture11-MachineLearning.pdf, p. 5]

Clean reconstruction. Page 5: repeated chain-rule derivation, backpropagated error.

What the note is saying. 本页的中心对象是 architecture 与 loss。原笔记将它们放进以下链条: repeated chain-rule derivation, backpropagated error。

Why it follows. 逐索引推导 backprop chain rule; 明确 local derivative、weight transpose、error signal、activation derivative 的作用。其逻辑后果是: 推导 normal-equation/closed-form least-squares solution, 说明 invertibility、pseudoinverse/regularization 作为必要背景但不要偏离笔记。后面的正式推导会逐项写出 assumptions、shape/units、limiting cases 与 failure conditions。

Figure reading. 先识别图中对象、箭头、参数和坐标系, 再问它表达的是定义、推导、模型预测还是经验观察; 示意图不提供未标注的定量精度。

Stop & Predict

XX^T singular 时怎么办?

4.6 Lecture11-MachineLearning.pdf • p. 6

However, we apply the chain rule another time in each layer to account for the nonlinearity.

$$\frac{\partial z_{k_{n+1}, \mu}^{(n+1)}}{\partial z_{k_n, \mu}^{(n)}} = \frac{\partial z_{k_{n+1}, \mu}^{(n+1)}}{\partial h_{k_{n+1}, \mu}^{(n+1)}} \frac{\partial h_{k_{n+1}, \mu}^{(n+1)}}{\partial z_{k_n, \mu}^{(n)}} = \mathcal{S}'(h_{k_{n+1}, \mu}^{(n+1)}) W_{k_{n+1}, k_n}^{(n)}$$

The $\mathcal{S}'$ terms make the formulae ugly, but the basic concept is the same. An error signal is backpropagated with $W^{(L)\top}$, multiplied with the derivative of the activation function at the L^{th} layer, backpropagated with $W^{(L-1)\top}$, and so on.

(Lots of data) + (Lots of layers) = (Revolution in machine learning, circa 2012)

Hinton, Krizvsky, Sutskever
 Founded Gatsby Computational Neuroscience Unit
 Invented ChatGPT a decade later

Original-note anchor. [Source: Lecture11-MachineLearning.pdf, p. 6]

Clean reconstruction. Page 6: nonlinear activation derivative 与 backprop summary.

What the note is saying. 本页的中心对象是 gradient descent 与 linear regression。原笔记将它们放进以下链条：nonlinear activation derivative 与 backprop summary。

Why it follows. 逐索引推导 backprop chain rule; 明确 local derivative、weight transpose、error signal、activation derivative 的作用。其逻辑后果是：解释 deep linear network 的整体映射仍线性但 parameterization/learning dynamics 非线性。后面的正式推导会逐项写出 assumptions、shape/units、limiting cases 与 failure conditions。

Figure reading. 先识别图中对象、箭头、参数和坐标系，再问它表达的是定义、推导、模型预测还是经验观察；示意图不提供未标注的定量精度。

Stop & Predict

deep linear network 的 input-output map 为什么仍 linear?

5 补全推导与数学支架 / Derivations

5.1 Taylor expansion 到 gradient descent

【必要前置】 如何选择小参数更新使 loss 下降？

$$\mathcal{L}(\mathbf{w} + \Delta \mathbf{w}) \approx \mathcal{L}(\mathbf{w}) + \nabla \mathcal{L}^T \Delta \mathbf{w}$$

$$\Delta \mathbf{w} = -\eta \nabla \mathcal{L}$$

1. gradient 指向 loss 增长最快方向。
2. 一阶近似中选择反梯度使内积为 $-\eta \|\nabla \mathcal{L}\|^2 \leq 0$ 。
3. η 太小收敛慢，太大可越过 valley 或发散。
4. 二阶 curvature 决定不同方向允许的安全步长。

Geometric/computational intuition. loss contour 上的 gradient 垂直于等高线，steepest descent 反向下坡。

Biological interpretation / failure condition. nonconvex loss 可有 saddle/local structure; 一阶近似只对足够小 step 可靠。

Micro-check

linear regression gradient 中 Hebbian-like term 是什么？

5.2 linear regression gradient 与 closed form

【补全推导】 对 P 个 examples 拟合 $y_\mu \approx \mathbf{w}^T \mathbf{x}_\mu$ 。

$$\mathcal{L} = \frac{1}{2P} \sum_{\mu=1}^P (y_\mu - \mathbf{w}^T \mathbf{x}_\mu)^2$$

$$\nabla_{\mathbf{w}} \mathcal{L} = -\frac{1}{P} X(\mathbf{y} - X^T \mathbf{w})$$

$$\hat{\mathbf{w}} = (X X^T)^{-1} X \mathbf{y}$$

1. 定义 $X=[\mathbf{x}_1, \dots, \mathbf{x}_P] \in \mathbb{R}^{N \times P}$, $\mathbf{y} \in \mathbb{R}^{P \times 1}$ 。
2. 对每个 residual 使用 chain rule, 得到 $-\text{error} \times \text{input}$ 。
3. gradient 可写为 $-X\mathbf{y}/P + X X^T \mathbf{w}/P$: 前者 Hebbian-like, 后者 stabilization。
4. 设 gradient=0 得 normal equation; 若 $X X^T$ singular 则用 pseudoinverse/regularization。

Geometric/computational intuition. 模型把 input directions 与 target 共变部分写入 weights, 同时抑制重复放大。

Biological interpretation / failure condition. 共线 features、 $P < N$ 、outliers 或 nonlinear target 会使 ordinary least squares 不稳定/偏差。

Micro-check

$X X^T$ singular 时怎么办?

5.3 deep linear network 的参数化

【跨页连接】 多层都是 linear 时为何整体仍 linear，但训练不简单？

$$\hat{\mathbf{y}} = W^{(L)}W^{(L-1)} \dots W^{(1)}\mathbf{x} = M\mathbf{x}$$

1. 矩阵 composition 仍是一个 matrix M ，所以 input-output map linear。
2. 但 M 被 factorized 成多层 matrices，参数之间乘法耦合。
3. 同一个 M 可有许多 factorization，因此 optimization geometry 非凸且有 scale symmetries。
4. 这说明 function class 与 learning dynamics 是不同问题。

Geometric/computational intuition. 深度未增加 linear function 的表达类型，却改变参数空间与隐式 bias。

Biological interpretation / failure condition. 把“整体 linear”误解为 loss 对每层 weight 仍是 convex。

Micro-check

deep linear network 的 input-output map 为什么仍 linear？

5.4 backpropagation 的 local chain rule

【模型边界】 计算每层 weight 的 gradient。

$$\mathbf{z}^{(\ell)} = \phi(\mathbf{h}^{(\ell)}), \quad \mathbf{h}^{(\ell)} = W^{(\ell)}\mathbf{z}^{(\ell-1)}$$

$$\delta^{(\ell)} = \left(W^{(\ell+1)T} \delta^{(\ell+1)} \right) \odot \phi'(\mathbf{h}^{(\ell)})$$

$$\frac{\partial \mathcal{L}}{\partial W^{(\ell)}} = \delta^{(\ell)} \mathbf{z}^{(\ell-1)T}$$

1. 先 forward 保存每层 pre-activation $\mathbf{h}$ 与 activation $\mathbf{z}$ 。
2. output layer 由 loss derivative 得 $\delta^{(L)}$ 。
3. error signal 经下一层 weight transpose 拉回，再乘 local derivative。
4. weight gradient 是 postsynaptic error 与 presynaptic activation 的 outer product。

Geometric/computational intuition. backprop 是高效 reuse 的 chain rule，不是 error 在生物神经元中按同一机制反向流动的证据。

Biological interpretation / failure condition. vanishing/exploding gradients、non-differentiable operations 或错误 shape 会破坏训练。

Micro-check

但其 training 为什么可非凸？

6 Cross-page synthesis / 跨页因果与数学链

机器学习问题必须同时指定 representation/architecture、objective/loss 和 optimization/learning rule。线性回归提供最透明的例子：squared error 的 gradient 可分成 data-dependent Hebbian-like term 与 weight-dependent stabilization term，并有 normal-equation closed form。在深层网络中，backprop 只是反复应用 chain rule，把 output error 经 weight transpose 与 local activation derivative 传回各层。




Figure note: schematic reconstruction; it encodes qualitative relations from the lesson and does not invent precise empirical data points.

7 Worked examples and transfer

7.1 一次 gradient step

【原课/核心例题】 Prompt. 单 example $x=(1,2)^T$, $y=5$, $w=(0,0)^T$, $\eta=0.1$, $\text{loss}=1/2(y-w^T x)^2$ 。

Worked solution. prediction=0, error=5, gradient= $-5x=(-5,-10)$, 更新 $w=(0.5,1.0)$, 新 prediction=2.5。

Check. gradient shape 与 w 相同；负梯度更新使 prediction 朝 y 增加。

7.2 backprop shape

【跨课连接】 Prompt. $W1: 4 \times 3$, $W2: 2 \times 4$, $x: 3 \times 1$ 。

Worked solution. $z_1: 4 \times 1$, $\text{output}: 2 \times 1$; $\delta_2: 2 \times 1$, $\delta_1 = W_2^T \delta_2 \odot \phi'$ 为 4×1 ; $\partial L / \partial W_1 = \delta_1 x^T$ 为 4×3 。

Check. 每个 weight gradient 必须与对应 matrix 同 shape。

Micro-check

Explain in your own words. 用不超过 120 字解释：本课从 source page 1 到最后一页，究竟把哪一个输入、状态、统计量或学习规则变成了可检验 prediction？

Self-reflection. 你最可能犯的是 concept、symbol、algebra、assumption 还是 causality error？写出一个具体例子。

8 Formula and notation sheet

1. gradient descent

$$\Delta w = -\eta \nabla_w \mathcal{L}$$

Conditions / conventions: $\eta > 0$ 、局部 step

2. linear-regression loss

$$\mathcal{L} = \frac{1}{2P} \|\mathbf{y} - X^T \mathbf{w}\|^2$$

Conditions / conventions: source orientation $X: N \times P$

3. least-squares gradient

$$\nabla_w \mathcal{L} = -X(\mathbf{y} - X^T \mathbf{w})/P$$

Conditions / conventions: differentiable squared loss

4. closed-form solution

$$\hat{w} = (X X^T)^{-1} X y$$

Conditions / conventions: $X X^T$ invertible

5. backprop error recurrence

$$\delta^{(\ell)} = (W^{(\ell+1)T} \delta^{(\ell+1)}) \odot \phi'$$

Conditions / conventions: compatible shapes

6. layer weight gradient

$$\partial \mathcal{L} / \partial W^{(\ell)} = \delta^{(\ell)} z^{(\ell-1)T}$$

Conditions / conventions: single example; batch averages later

9 Bilingual glossary

中文	English / symbol	Operational meaning
监督学习	supervised learning	由 input-target pairs 学习预测。
分类	classification	预测离散 label。
回归	regression	预测连续 target。
架构	architecture	模型变量如何连接与计算。
损失函数	loss function	量化 prediction 与 target 不一致的 objective。
梯度	gradient	各参数偏导数组成、指向最快上升方向的向量。
学习率	learning rate	每次 gradient step 的尺度。
正规方程	normal equation	least-squares optimum 的线性方程。
反向传播	backpropagation	高效计算多层 chain-rule gradients 的算法。
局部导数	local derivative	某一计算节点输出对输入的 derivative。

10 Common traps, assumptions, and limitations

1. 把 architecture、loss 与 optimizer 混成同一个概念。
2. 忘记 gradient 指向上升，更新应取负号。
3. matrix calculus 不标 shape，导致 transpose 错误。

4. 在 singular design matrix 上直接求 inverse。
5. 认为 deep linear network 的 optimization 也是线性/convex。
6. 把 backprop 当成已确立的生物突触机制。
7. 误把 source 页的历史性旁注当作严格技术结论。

Course-specific risk boundary. 不要把 backprop 描述成“误差直接传回神经元”的生物机制；清楚标为训练算法，并讨论与 three-factor plasticity 的形式联系和机制差异。

11 Cumulative Knowledge Check

Do not turn to the Hint Bank until you have written a first attempt.

1. supervised algorithm 的三个设计元素?

2. gradient 指向哪个方向?

3. 为什么更新用 $-\eta \nabla L$?

4. linear regression gradient 中 Hebbian-like term 是什么?

5. XX^T singular 时怎么办?

6. deep linear network 的 input-output map 为什么仍 linear?

7. 但其 training 为什么可非凸?

8. backprop 中 weight transpose 的作用?

9. activation derivative 的作用?

10. $\partial L / \partial W$ 为什么是 outer product?

11. backprop 是不是 biological mechanism?

12. learning rate 太大会发生什么?

13. 公式表中的 “gradient descent” 解决什么问题? 写出适用条件与一个 sanity check。

14. 公式表中的 “linear-regression loss” 解决什么问题? 写出适用条件与一个 sanity check。

15. 公式表中的 “least-squares gradient” 解决什么问题? 写出适用条件与一个 sanity check。

16. 公式表中的“closed-form solution” 解决什么问题？ 写出适用条件与一个 sanity check。

17. 公式表中的“backprop error recurrence” 解决什么问题？ 写出适用条件与一个 sanity check。

18. 公式表中的“layer weight gradient” 解决什么问题？ 写出适用条件与一个 sanity check。

12 Hint Bank

1. **Hint 1.** 先识别对象、变量与假设。
Hint 2. 写出最相关的定义或方程，再代入。
Hint 3. 检查单位、shape、符号与极限情况。
2. **Hint 1.** 先识别对象、变量与假设。
Hint 2. 写出最相关的定义或方程，再代入。
Hint 3. 检查单位、shape、符号与极限情况。
3. **Hint 1.** 先识别对象、变量与假设。
Hint 2. 写出最相关的定义或方程，再代入。
Hint 3. 检查单位、shape、符号与极限情况。
4. **Hint 1.** 先识别对象、变量与假设。
Hint 2. 写出最相关的定义或方程，再代入。
Hint 3. 检查单位、shape、符号与极限情况。
5. **Hint 1.** 先识别对象、变量与假设。
Hint 2. 写出最相关的定义或方程，再代入。
Hint 3. 检查单位、shape、符号与极限情况。
6. **Hint 1.** 先识别对象、变量与假设。
Hint 2. 写出最相关的定义或方程，再代入。
Hint 3. 检查单位、shape、符号与极限情况。
7. **Hint 1.** 先识别对象、变量与假设。
Hint 2. 写出最相关的定义或方程，再代入。
Hint 3. 检查单位、shape、符号与极限情况。
8. **Hint 1.** 先识别对象、变量与假设。
Hint 2. 写出最相关的定义或方程，再代入。
Hint 3. 检查单位、shape、符号与极限情况。
9. **Hint 1.** 先识别对象、变量与假设。
Hint 2. 写出最相关的定义或方程，再代入。
Hint 3. 检查单位、shape、符号与极限情况。
10. **Hint 1.** 先识别对象、变量与假设。
Hint 2. 写出最相关的定义或方程，再代入。
Hint 3. 检查单位、shape、符号与极限情况。
11. **Hint 1.** 先识别对象、变量与假设。
Hint 2. 写出最相关的定义或方程，再代入。
Hint 3. 检查单位、shape、符号与极限情况。
12. **Hint 1.** 先识别对象、变量与假设。
Hint 2. 写出最相关的定义或方程，再代入。
Hint 3. 检查单位、shape、符号与极限情况。
13. **Hint 1.** 先从“gradient descent”对应的变量关系入手。
Hint 2. 把条件“ $\eta > 0$ 、局部 step”逐字转换为 assumption。
Hint 3. 写公式，再检查至少一种极端参数或单位。
14. **Hint 1.** 先从“linear-regression loss”对应的变量关系入手。
Hint 2. 把条件“source orientation $X:N \times P$ ”逐字转换为 assumption。
Hint 3. 写公式，再检查至少一种极端参数或单位。

15. **Hint 1.** 先从 “least-squares gradient” 对应的变量关系入手。
Hint 2. 把条件 “differentiable squared loss” 逐字转换为 assumption。
Hint 3. 写公式, 再检查至少一种极端参数或单位。
16. **Hint 1.** 先从 “closed-form solution” 对应的变量关系入手。
Hint 2. 把条件 “ XX^T invertible” 逐字转换为 assumption。
Hint 3. 写公式, 再检查至少一种极端参数或单位。
17. **Hint 1.** 先从 “backprop error recurrence” 对应的变量关系入手。
Hint 2. 把条件 “compatible shapes” 逐字转换为 assumption。
Hint 3. 写公式, 再检查至少一种极端参数或单位。
18. **Hint 1.** 先从 “layer weight gradient” 对应的变量关系入手。
Hint 2. 把条件 “single example; batch averages later” 逐字转换为 assumption。
Hint 3. 写公式, 再检查至少一种极端参数或单位。

13 Complete Answer Key with reasoning

1. architecture、loss function、learning/optimization rule。
2. loss 增长最快方向。
3. 一阶 loss change 为 $-\eta \|\nabla L\|^2 \leq 0$ 。
4. Xy/P (在负 gradient update 中增强 input-target coactivity)。
5. 使用 pseudoinverse、ridge regularization 或移除共线 dimensions。
6. 矩阵乘积仍是一个矩阵 M 。
7. M 被多层 factors 相乘参数化, loss 对单层联合参数有乘法耦合和对称性。
8. 把下一层 error sensitivity 映射回当前层 units。
9. 按本层 nonlinearity 的局部 gain 调制反传 error。
10. 每个 weight 连接 presynaptic activation 与 postsynaptic error。
11. 它是训练算法; 可与 biological rules 比较形式, 但不能直接等同。
12. 越过 valley、oscillate 或 divergence。
13. 适用条件/约定: $\eta > 0$ 、局部 step。sanity check 应检查单位、符号、极限或 shape 是否与定义一致。

$$\Delta w = -\eta \nabla_w \mathcal{L}$$

14. 适用条件/约定: source orientation $X: N \times P$ 。sanity check 应检查单位、符号、极限或 shape 是否与定义一致。

$$\mathcal{L} = \frac{1}{2P} \|\mathbf{y} - X^T \mathbf{w}\|^2$$

15. 适用条件/约定: differentiable squared loss。sanity check 应检查单位、符号、极限或 shape 是否与定义一致。

$$\nabla_w \mathcal{L} = -X(\mathbf{y} - X^T \mathbf{w})/P$$

16. 适用条件/约定: XX^T invertible。sanity check 应检查单位、符号、极限或 shape 是否与定义一致。

$$\hat{w} = (XX^T)^{-1} Xy$$

17. 适用条件/约定: compatible shapes。sanity check 应检查单位、符号、极限或 shape 是否与定义一致。

$$\delta^{(\ell)} = (W^{(\ell+1)T} \delta^{(\ell+1)}) \odot \phi'$$

18. 适用条件/约定: single example; batch averages later。sanity check 应检查单位、符号、极限或 shape 是否与定义一致。

$$\partial \mathcal{L} / \partial W^{(\ell)} = \delta^{(\ell)} z^{(\ell-1)T}$$

14 Source-page concordance and coverage audit

Source file	Page	Coverage status
Lecture11-MachineLearning.pdf	1	Main source-page unit: thumbnail, reconstruction, explanation, prediction question.
Lecture11-MachineLearning.pdf	2	Main source-page unit: thumbnail, reconstruction, explanation, prediction question.
Lecture11-MachineLearning.pdf	3	Main source-page unit: thumbnail, reconstruction, explanation, prediction question.
Lecture11-MachineLearning.pdf	4	Main source-page unit: thumbnail, reconstruction, explanation, prediction question.
Lecture11-MachineLearning.pdf	5	Main source-page unit: thumbnail, reconstruction, explanation, prediction question.
Lecture11-MachineLearning.pdf	6	Main source-page unit: thumbnail, reconstruction, explanation, prediction question.

15 Errata, uncertainty log, and external endnotes

15.1 Errata / source cautions

1. Page 3 的 closed form 依赖 X 的 orientation; 本教材明确采用 $X \in \mathbb{R}^{N \times P}$ 、 $y \in \mathbb{R}^{P \times 1}$ 。
2. Page 6 关于 2012 deep learning 与后续 ChatGPT 的旁注属于非正式历史连接, 不应解释为 AlexNet authors 直接“发明 ChatGPT”。
3. backprop 与 three-factor plasticity 只在 outer-product/error-gating 形式上相似, biological transport/mechanism 不同。

15.2 Uncertainty log

No unresolved handwriting uncertainty changes a core definition, equation, figure interpretation, or answer in this companion. Where handwriting was potentially ambiguous, the source-page image is preserved and the reconstruction avoids claiming unverified detail.

15.3 External endnotes

No external web or textbook source was used to replace the uploaded notes. Added material is limited to necessary mathematical scaffolding, explicit assumptions, standard sanity checks, and clearly labeled transfer examples.

15.4 Final self-audit

All source pages listed above were visually inspected. Equations were checked for symbol definitions, units/shapes, assumptions, algebraic transitions, limiting cases, and failure conditions. The PDF is static and contains no interactive form fields or scripts.