

NEUROSCI 366

Lecture 13

Spike-Triggered Average 与 White-Noise System Identification

Source-aligned · Static · Searchable · Printable

Source files

- Lecture13-SpikeTriggeredAverage-UPDATE.pdf

Production version: 2026-08-22

Reader profile: neuroscience undergraduate education; mathematics scaffolded from high-school algebra/trigonometry to the formal computational-neuroscience level.

This companion preserves source-page order, distinguishes source material from necessary scaffolding and extensions, and places hints/answers after the lesson. It is a static PDF: no forms, JavaScript, hidden-answer widgets, passwords, or DRM.

Contents

1	How to use this companion	2
2	Learning objectives and prerequisite dependency map	2
3	Five-minute prerequisite diagnostic	2
4	Source-aligned lesson / 按原笔记页序	3
4.1	Lecture13-SpikeTriggeredAverage-UPDATE.pdf · p. 1	3
4.2	Lecture13-SpikeTriggeredAverage-UPDATE.pdf · p. 2	4
4.3	Lecture13-SpikeTriggeredAverage-UPDATE.pdf · p. 3	5
4.4	Lecture13-SpikeTriggeredAverage-UPDATE.pdf · p. 4	6
4.5	Lecture13-SpikeTriggeredAverage-UPDATE.pdf · p. 5	7
4.6	Lecture13-SpikeTriggeredAverage-UPDATE.pdf · p. 6	8
5	补全推导与数学支架 / Derivations	9
5.1	continuous、pixel 与 matrix notation 对齐	9
5.2	least-squares filter 与 Hessian	10
5.3	white noise 使 filter estimate $\propto$ STA	11
5.4	恢复 nonlinearity 与 failure modes	12
6	Cross-page synthesis / 跨页因果与数学链	13
7	Worked examples and transfer	13
7.1	STA scale 与方向	13
7.2	symmetric nonlinearity 反例	13
8	Formula and notation sheet	15
9	Bilingual glossary	15
10	Common traps, assumptions, and limitations	16
11	Cumulative Knowledge Check	17
12	Hint Bank	19
13	Complete Answer Key with reasoning	21
14	Source-page concordance and coverage audit	22

15 Errata, uncertainty log, and external endnotes	22
15.1 Errata / source cautions	22
15.2 Uncertainty log	22
15.3 External endnotes	22
15.4 Final self-audit	23

1 How to use this companion

1. 先用 5-minute diagnostic 暴露前置缺口；不要立即翻答案。
2. 按原笔记页序阅读 source-page units：先看原页，再读 clean reconstruction 与补全逻辑。
3. 遇到公式按“问题 → 符号/shape/units → assumptions → 一行一步推导 → intuition → biological meaning → sanity check → failure”阅读。
4. 完成 Cumulative Knowledge Check；只在需要时依次打开 Hint 1、2、3。
5. 至少隔一个 page break 后再核对 Answer Key，并记录错误类型：concept、symbol、algebra、assumption、correlation/causation。

Source hierarchy. 原笔记是内容权威；本书中的“【必要前置】/【补全推导】/【跨课连接】/【延伸】”是为了补齐数学或迁移，不替代源材料。无法确认的内容必须进入 Uncertainty Log。

2 Learning objectives and prerequisite dependency map

- 定义并区分：white-noise stimulus。
- 从第一原则推导：spike-triggered ensemble。
- 解释几何/计算直觉：matrix notation。
- 连接生物学解释：least squares/Hessian。
- 诊断 assumptions 与 failure modes：white covariance。
- 把概念迁移到新神经科学问题：STA proportionality。

Dependency map

white-noise stimulus → spike-triggered ensemble → matrix notation → least squares/Hessian → white covariance → STA proportionality

Core question

在 white-noise stimulation 下，为什么 spike-triggered average 能估计 LNP 的 linear filter，并在哪些条件下会灾难性失败？


3 Five-minute prerequisite diagnostic

1. S、K、L 的 shapes？（卡住时先看 Source-page unit 1，再看补全推导。）
2. least-squares normal equation 是什么？（卡住时先看 Source-page unit 2，再看补全推导。）
3. Hessian 由什么决定？（卡住时先看 Source-page unit 3，再看补全推导。）
4. white noise 为什么让 loss contours 近圆形？（卡住时先看 Source-page unit 4，再看补全推导。）
5. small-bin h_t 与 k_t 的关系？（卡住时先看 Source-page unit 5，再看补全推导。）

Scoring guide: 4–5 confident answers → proceed; 2–3 → use the prerequisite labels; 0–1 → read the formula/notation sheet once before the source-aligned lesson.

4 Source-aligned lesson / 按原笔记页序

4.1 Lecture13-SpikeTriggeredAverage-UPDATE.pdf • p. 1



Original-note anchor. [Source: Lecture13-SpikeTriggeredAverage-UPDATE.pdf, p. 1]

Clean reconstruction. Page 1: white-noise LNP system identification; STA experimental procedure.

What the note is saying. 本页的中心对象是 white-noise stimulus 与 spike-triggered ensemble。原笔记将它们放进以下链条: white-noise LNP system identification; STA experimental procedure.

Why it follows. 逐步解释 white-noise stimulus、spike-triggered ensemble、average preceding spike 和 STA 的实验意义。其逻辑后果是: 给出完整 LNP fitting workflow, 并深入解释 STA 可能 catastrophically fail 的条件: multiple relevant dimensions、symmetric nonlinearities、correlated/non-Gaussian stimuli、insufficient data 等。后面的正式推导会逐项写出 assumptions、shape/units、limiting cases 与 failure conditions。

Figure reading. 按时间线区分 stimulus/task、recording/manipulation、measured quantity 与 inferred model variable; 结果相关性不能直接替代机制检验。

Stop & Predict

S、K、L 的 shapes?

4.2 Lecture13-SpikeTriggeredAverage-UPDATE.pdf • p. 2

Alternate ways to write $L(s)$:

Continuous space and time:

$$L(s) = \int dx' \int dy' \int dt' K(x', y', t - t') s(x', y', t')$$

Redefinition that shifts and
Flips spatial coordinates

$$= \int dx' \int dy' \int dt' K(x', y', t') s(x', y', t - t')$$

Pixelated space and time:

$$L(s) = \sum_p K_p S_{pt} \quad \begin{array}{l} p: \text{pixel index for kernel} \\ x_p: \text{x-coordinate of pixel } p \\ y_p: \text{y-coordinate} \\ t_p: \text{t-coordinate (looks back in time)} \end{array}$$

$$= K S$$

The pixelated matrix form is tidy and simplifies the derivation. In this notation, the firing rate is

$$h_t = \mathcal{F}(\sum_p K_p S_{pt})$$

Original-note anchor. [Source: Lecture13-SpikeTriggeredAverage-UPDATE.pdf, p. 2]

Clean reconstruction. Page 2: continuous、pixelized 与 matrix notation.

What the note is saying. 本页的中心对象是 matrix notation 与 least squares/Hessian。原笔记将它们放进以下链条：continuous、pixelized 与 matrix notation。

Why it follows. 统一 continuous convolution、pixel index notation 和 matrix form；给出 S 、 K 、 h 的 shape。其逻辑后果是：逐步解释 white-noise stimulus、spike-triggered ensemble、average preceding spike 和 STA 的实验意义。后面的正式推导会逐项写出 assumptions、shape/units、limiting cases 与 failure conditions。

Figure reading. 把图与矩阵 shape 对齐：轴代表变量或 mode，椭圆方向对应 eigenvectors，轴长/曲率对应 eigenvalues；不要把统计轴自动解释为因果通路。

Stop & Predict

least-squares normal equation 是什么？

4.3 Lecture13-SpikeTriggeredAverage-UPDATE.pdf • p. 3

Linear neuron:

Suppose $S(x) = x$, so

$$h_t = \sum_p K_p s_{pt}$$

and the experimenter only needs to estimate K . "Linear system identification."


Choose K to minimize mean squared error

$$\mathcal{L}(K) = \frac{1}{T} \sum_{t=1}^T (h_t - \sum_p K_p s_{pt})^2$$

In machine learning lectures, we showed that the solution to this linear regression problem is

$$\hat{K} = \underbrace{(SS^T)^{-1}}_{p \times p} \underbrace{Sh}_{p \times 1}$$

We also explained that error contours are ellipses. To estimate each K_p equally well, want these ellipses to be circles



Equivalently, we want second derivative matrix to be isotropic, because this means that $\mathcal{L}(K)$ has equal curvature in all directions.

Original-note anchor. [Source: Lecture13-SpikeTriggeredAverage-UPDATE.pdf, p. 3]

Clean reconstruction. Page 3: linear neuron, least-squares system identification, loss contours/Hessian.

What the note is saying. 本页的中心对象是 white covariance 与 STA proportionality。原笔记将它们放进以下链条: linear neuron、least-squares system identification、loss contours/Hessian。

Why it follows. 从 linear neuron 的 mean-squared loss 推导 normal equations 与 Hessian; 解释 circular/elliptical loss geometry。其逻辑后果是: 从“已知 stimulus 和 spikes, 如何反推 linear filter 与 nonlinearity”定义 system-identification problem。后面的正式推导会逐项写出 assumptions、shape/units、limiting cases 与 failure conditions。

Figure reading. 把图与矩阵 shape 对齐: 轴代表变量或 mode, 椭圆方向对应 eigenvectors, 轴长/曲率对应 eigenvalues; 不要把统计轴自动解释为因果通路。

Stop & Predict

Hessian 由什么决定?

4.4 Lecture13-SpikeTriggeredAverage-UPDATE.pdf • p. 4

This matrix is

$$\begin{aligned}\frac{\partial^2 \mathcal{L}}{\partial K_{p_1} \partial K_{p_2}} &= \frac{\partial^2}{\partial K_{p_1} \partial K_{p_2}} \left(\frac{1}{T} \sum_{t=1}^T \left(h_t^2 - 2 \sum_p K_p s_{p,t} h_t \right. \right. \\ &\quad \left. \left. + \sum_p \sum_{p'} K_p s_{p,t} K_{p'} s_{p',t} \right) \right) \\ &= \frac{2}{T} \sum_{t=1}^T s_{p_1,t} s_{p_2,t} \\ &= \frac{2}{T} (S S^T)_{p_1, p_2}\end{aligned}$$

It's isotropic if

$$(S S^T)_{p_1, p_2} = A \delta_{p_1, p_2}, \quad A \text{ constant}$$

Stimuli with this property have completely uncorrelated pixels. It's termed "white noise", and typically taken to be Gaussian

$$S_{xyt} \sim \mathcal{N}(0, \sigma_s^2)$$

Thus

$$\begin{aligned}\langle (S S^T)_{p_1, p_2} \rangle &= \left\langle \sum_{t=1}^T s_{p_1,t} s_{p_2,t} \right\rangle = \sum_{t=1}^T \langle s_{x_{p_1}, y_{p_1}, t-t_0} s_{x_{p_2}, y_{p_2}, t-t_0} \rangle \\ s_{x_{p_1}, y_{p_1}, t-t_0} s_{x_{p_2}, y_{p_2}, t-t_0} &= \sum_{t=1}^T \sigma_s^2 \delta_{x_{p_1}, x_{p_2}} \delta_{y_{p_1}, y_{p_2}} \delta_{t_0, t_0} \\ &= T \sigma_s^2 \delta_{p_1, p_2}\end{aligned}$$

$$\frac{\partial^2 \mathcal{L}}{\partial K_{p_1} \partial K_{p_2}} \approx 2 \sigma_s^2 \delta_{p_1, p_2}$$

$$(S S^T)^{-1}_{p_1, p_2} \approx \frac{1}{2 T \sigma_s^2} \delta_{p_1, p_2}$$

For this reason, white noise stimuli are often used for system identification.

Original-note anchor. [Source: Lecture13-SpikeTriggeredAverage-UPDATE.pdf, p. 4]

Clean reconstruction. Page 4: white-noise covariance、isotropic Hessian。

What the note is saying. 本页的中心对象是 nonlinearity/failures 与 white-noise stimulus。原笔记将它们放进以下链条：white-noise covariance、isotropic Hessian。

Why it follows. 从 linear neuron 的 mean-squared loss 推导 normal equations 与 Hessian；解释 circular/elliptical loss geometry。其逻辑后果是：从 white Gaussian stimulus covariance 推导 $SS^T \approx T \sigma_s^2 \mathbf{I}$ ，再逐步推导 kernel estimate 与 STA 的 proportionality，包括 bin width 与 spike count scaling。后面的正式推导会逐项写出 assumptions、shape/units、limiting cases 与 failure conditions。

Figure reading. 把图与矩阵 shape 对齐：轴代表变量或 mode，椭圆方向对应 eigenvectors，轴长/曲率对应 eigenvalues；不要把统计轴自动解释为因果通路。

Stop & Predict

white noise 为什么让 loss contours 近圆形？

4.5 Lecture13-SpikeTriggeredAverage-UPDATE.pdf • p. 5

The Kernel estimate is simply

$$\hat{K} = (SS^T)^{-1} S h = \frac{1}{T\sigma_s^2} S h$$

h_t is the firing rate, but we measure spikes. We write

$$h_t = \frac{k_t}{\Delta t}; \quad k_t: \# \text{ spikes in bin } t; \quad \Delta t: \text{bin width}$$

For small Δt , k_t will be zero or one. Therefore,

$$\hat{K}_p = \frac{1}{T\sigma_s^2} \sum_t S_{pt} h_t = \frac{1}{T\sigma_s^2 \Delta t} \sum_{i=1}^{n_s} S_{pt_i}; \quad n_s: \# \text{ spikes}; \quad t_i: \text{spike times}$$

$$= \frac{1}{T\sigma_s^2 \Delta t} \sum_{i=1}^{n_s} S_{x_p, y_p, t_i - t_p}$$

$$\hat{K} = \underbrace{\frac{n_s}{T\sigma_s^2 \Delta t}}_{\text{constant}} \underbrace{\sum_{i=1}^{n_s} S_{x_p, y_p, t_i - t_p}}_{\text{"spike-triggered average," STA}}$$

Original-note anchor. [Source: Lecture13-SpikeTriggeredAverage-UPDATE.pdf, p. 5]

Clean reconstruction. Page 5: kernel estimator 到 spike-triggered average 的完整推导。

What the note is saying. 本页的中心对象是 spike-triggered ensemble 与 matrix notation。原笔记将它们放进以下链条：kernel estimator 到 spike-triggered average 的完整推导。

Why it follows. 逐步解释 white-noise stimulus、spike-triggered ensemble、average preceding spike 和 STA 的实验意义。其逻辑后果是：从 white Gaussian stimulus covariance 推导 $SS^T \approx T\sigma_s^2 I$ ，再逐步推导 kernel estimate 与 STA 的 proportionality，包括 bin width 与 spike count scaling。后面的正式推导会逐项写出 assumptions、shape/units、limiting cases 与 failure conditions。

Figure reading. 先识别图中对象、箭头、参数和坐标系，再问它表达的是定义、推导、模型预测还是经验观察；示意图不提供未标注的定量精度。

Stop & Predict

small-bin h_t 与 k_t 的关系？

4.6 Lecture13-SpikeTriggeredAverage-UPDATE.pdf • p. 6

Including nonlinearity:

We now return to the case where

$$h_t = S \left(\sum_p K_p s_{pt} \right)$$

and we want to infer both K and S . For small enough Δt , $\lambda = h \Delta t$ is small, and we can approximate the Poisson distribution as

$$P(k) = \begin{cases} 1 - \lambda, & k=0 \\ \lambda, & k=1 \end{cases}$$

Therefore, the probability that a neuron spikes is

$$P_{\text{spike}} = P_{\text{spike}}(L(s)) = \Delta t S(L(s))$$

If we knew $L(s)$, and plotted $P_{\text{spike}}(L(s))$, the resulting curve is proportional to S .

Standard procedure:

1. Show Gaussian white-noise stimuli and record spikes.
2. Evaluate $\hat{K} = \hat{L}$
3. Evaluate $\hat{L} = \hat{K} S$
4. $\hat{S}(\hat{L}) = \frac{1}{\Delta t} P_{\text{spike}}(\hat{L})$

You now have a model neuron to predict spiking responses to new stimuli.

$$P(k_t | s) = \text{Pois}(\hat{S}(\hat{K} s))$$

This procedure is heuristic, often works very well, but can sometimes fail, even catastrophically.

Original-note anchor. [Source: Lecture13-SpikeTriggeredAverage-UPDATE.pdf, p. 6]

Clean reconstruction. Page 6: 恢复 nonlinearity、标准 workflow、heuristic success/failure.

What the note is saying. 本页的中心对象是 least squares/Hessian 与 white covariance。原笔记将它们放进以下链条：恢复 nonlinearity、标准 workflow、heuristic success/failure.

Why it follows. 解释 small- Δt Poisson/Bernoulli approximation, 如何从 empirical spike probability 恢复 nonlinearity。其逻辑后果是：给出完整 LNP fitting workflow, 并深入解释 STA 可能 catastrophically fail 的条件: multiple relevant dimensions, symmetric nonlinearities, correlated/non-Gaussian stimuli、insufficient data 等。后面的正式推导会逐项写出 assumptions、shape/units、limiting cases 与 failure conditions.

Figure reading. 先识别图中对象、箭头、参数和坐标系, 再问它表达的是定义、推导、模型预测还是经验观察; 示意图不提供未标注的定量精度。

Stop & Predict

Khat 为什么与 STA 同方向?

5 补全推导与数学支架 / Derivations

5.1 continuous、pixel 与 matrix notation 对齐

【必要前置】 把 spatiotemporal convolution 写成可拟合的线性代数。

$$L_t = \sum_{p=1}^P K_p S_{pt}$$

$$\mathbf{L} = \mathbf{S}^T \mathbf{K}$$

$$\mathbf{S} \in \mathbb{R}^{P \times T}, \mathbf{K} \in \mathbb{R}^{P \times 1}, \mathbf{L} \in \mathbb{R}^{T \times 1}$$

1. p 可同时编码 x 、 y 与过去 time lag。
2. 每个 column $\mathbf{S}_{:t}$ 是 time t 前的 stimulus history vector。
3. $\mathbf{K}$ 与每个 stimulus vector 做 inner product, 产生 scalar drive L_t 。
4. 明确 shape 后, continuous convolution 与 matrix form 是同一运算的离散化。

Geometric/computational intuition. 系统辨识把每个 time bin 当作一个高维 stimulus example。

Biological interpretation / failure condition. time indexing/lag orientation 错一位会使估计 filter 在时间上翻转。

Micro-check

white noise 为什么让 loss contours 近圆形?

5.2 least-squares filter 与 Hessian

【补全推导】 在线性 neuron $\mathbf{h} \approx S^T \mathbf{K}$ 下估计 $\mathbf{K}$ 。

$$\mathcal{L}(\mathbf{K}) = \frac{1}{2T} \|\mathbf{h} - S^T \mathbf{K}\|^2$$

$$\hat{\mathbf{K}} = (SS^T)^{-1} S \mathbf{h}$$

$$H_K = \frac{1}{T} SS^T$$

1. gradient 为 $-S(\mathbf{h} - S^T \mathbf{K})/T$ 。
2. 设 gradient=0 得 normal equation $SS^T \mathbf{K} = S \mathbf{h}$ 。
3. Hessian/curvature 由 stimulus covariance 决定。
4. elliptical contours 表示不同 filter directions 的可辨识度不同。

Geometric/computational intuition. 若 stimulus 没有激发某方向，该方向 filter 无法从数据中估计。

Biological interpretation / failure condition. SS^T singular/ill-conditioned 时需 whitening、regularization 或更多刺激。

Micro-check

small-bin $\mathbf{h}_t$ 与 $\mathbf{k}_t$ 的关系？

5.3 white noise 使 filter estimate $\propto$ STA

【跨页连接】 从 normal equation 推导 STA。

$$SS^T \approx T\sigma_s^2 I$$

$$\hat{K} \approx \frac{1}{T\sigma_s^2} S\mathbf{h}$$

$$h_t = \frac{k_t}{\Delta t} \Rightarrow S\mathbf{h} = \frac{1}{\Delta t} \sum_{t \in \text{spikes}} \mathbf{s}_t = \frac{n_{sp}}{\Delta t} STA$$

1. independent zero-mean pixels/time bins 使 off-diagonal covariance 平均为 0。
2. 每个 dimension variance 相同, 使 Hessian isotropic。
3. small bin 下 $k_t \in \{0,1\}$, response vector 只在 spike bins 取非零。
4. 因此 Khat 与 spikes 前 stimulus average 同方向, scale 由 T 、 σ^2 、 Δt 、spike count 决定。

Geometric/computational intuition. white stimulus 不偏爱任何 feature direction, 所以 spike 前重复出现的 structure 指向 neuron 的 relevant filter。

Biological interpretation / failure condition. colored stimulus 需乘 stimulus covariance inverse; 直接 STA 会被 stimulus correlations 扭曲。

Micro-check

Khat 为什么与 STA 同方向?

5.4 恢复 nonlinearity 与 failure modes

【模型边界】 已估 K 后如何估 F，并判断 STA 何时失败？

$$P(k_t = 1 \mid L_t) \approx \Delta t \mathcal{F}(L_t)$$

$$\hat{\mathcal{F}}(L) = \frac{P(\text{spike} \mid L)}{\Delta t}$$

1. 把每个 time bin 投影到 $L = K^T s$ 。
2. 按 L 分 bin，估计 spike fraction，再除以 Δt 得 rate。
3. 若 response 依赖多个 filters，单一 L 丢失信息。
4. 若 $F(L) = F(-L)$ 为 even/symmetric，positive 与 negative features 在 STA 中抵消，STA 可为 0。

Geometric/computational intuition. filter 找“相关方向”，nonlinearity 描述沿该方向如何转成 spikes。

Biological interpretation / failure condition. multiple dimensions、symmetric nonlinearities、non-Gaussian/correlated stimuli、history effects 与 insufficient spikes。

Micro-check

colored stimulus 下应如何修正？

6 Cross-page synthesis / 跨页因果与数学链

STA 既是 descriptive average, 也是在线性、Gaussian white stimulus 与合适 nonlinearity 条件下的 filter estimator。matrix least squares 揭示其来源: white stimulus 使 design covariance 近似 scalar identity, normal equation 因而简化为 stimulus 与 response 的相关。恢复 nonlinearity 后得到可预测新刺激的 LNP model; 但多个 relevant dimensions、even-symmetric nonlinearities 或 correlated stimulus 会使 STA 为零或偏差。

Lecture 13 — key reconstruction (schematic)




Figure note: schematic reconstruction; it encodes qualitative relations from the lesson and does not invent precise empirical data points.

7 Worked examples and transfer

7.1 STA scale 与方向

【原课/核心例题】 Prompt. 两个实验 stimulus variance 不同, 但 neuron filter 相同。

Worked solution. raw STA amplitude 会随 σ_s^2 、rate/spike count 与 bin width 改变; 比较 filter direction/normalized shape 前需按 derivation scale 或标准化。

Check. STA 是 filter 的 proportional estimator, 不是无条件等幅度。

7.2 symmetric nonlinearity 反例

【跨课连接】 Prompt. neuron 对 $|K \wedge Ts|$ 大时都放电。

Worked solution. spikes 前既有 +K-like 也有 -K-like stimuli, 平均相消, $STA \approx 0$; STC 可找到 variance 增大的 K direction。

Check. $STA=0$ 不等于没有 stimulus selectivity。

Micro-check

Explain in your own words. 用不超过 120 字解释: 本课从 source page 1 到最后一页, 究竟把哪一个输入、状态、统计量或学习规则变成了可检验 prediction?

Self-reflection. 你最可能犯的是 concept、symbol、algebra、assumption 还是 causality error? 写出一个具体例子。

8 Formula and notation sheet

1. pixelized linear drive

$$L = S^T K$$

Conditions / conventions: $S: P \times T$

2. least-squares filter

$$\hat{K} = (SS^T)^{-1} Sh$$

Conditions / conventions: SS^T invertible

3. loss Hessian

$$H = SS^T / T$$

Conditions / conventions: linear squared loss

4. white-noise covariance

$$SS^T \approx T \sigma_s^2 I$$

Conditions / conventions: large T , independent equal-variance pixels

5. spike-triggered average

$$STA = \frac{1}{n_{sp}} \sum_{t \in spikes} s_t$$

Conditions / conventions: aligned stimulus histories

6. STA/filter relation

$$\hat{K} \propto STA$$

Conditions / conventions: white Gaussian single-filter assumptions

7. small-bin nonlinearity estimate

$$P(spike|L) \approx \Delta t F(L)$$

Conditions / conventions: $\Delta t \text{ rate} \ll 1$

9 Bilingual glossary

中文	English / symbol	Operational meaning
系统辨识 白噪声	system identification white noise	由输入和输出数据反推系统模型。 不同 dimensions/time bins 不相关且功率均匀的理想随机刺激。
脉冲触发集合 脉冲触发平均	spike-triggered ensemble spike-triggered average, STA	所有 spike 前 stimulus histories 的集合。 spike-triggered ensemble 的均值。
设计矩阵	design matrix	按 examples/time bins 组织 stimulus vectors 的矩阵。
Hessian 各向同性 白化	Hessian isotropic whitening	loss 对参数的二阶导数矩阵。 所有方向 curvature/variance 相同。 移除 covariance correlations、使变量近 unit covariance。
相关刺激	correlated stimulus	stimulus dimensions 具有非零 covariance。

中文	English / symbol	Operational meaning
相关维度	relevant dimension	response dependence 的 stimulus projection direction。

10 Common traps, assumptions, and limitations

1. 把 STA 仅当作图片平均，而不说明 time lag alignment。
2. matrix orientation 不标，混淆 $S^{\wedge}TK$ 与 KS。
3. 遗漏 white covariance 的 large-sample 与 equal-variance assumptions。
4. 把 STA amplitude 无条件等同于 physical filter gain。
5. STA=0 就断言 neuron 无 receptive field。
6. 恢复 F 时忘记除以 bin width。
7. 用 training fit 判断模型，不做 held-out prediction。

Course-specific risk boundary. 区分 STA 作为 descriptive average、linear-filter estimator 和 LNP model component；三者特定假设下联系，但不是无条件等价。

11 Cumulative Knowledge Check

Do not turn to the Hint Bank until you have written a first attempt.

1. S、K、L 的 shapes?

2. least-squares normal equation 是什么?

3. Hessian 由什么决定?

4. white noise 为什么让 loss contours 近圆形?

5. small-bin h_t 与 k_t 的关系?

6. Khat 为什么与 STA 同方向?

7. colored stimulus 下应如何修正?

8. even nonlinearity 为什么使 $STA \approx 0$?

9. multiple relevant dimensions 时单一 STA 缺什么?

10. 如何估计 nonlinearity?

11. 为什么必须 cross-validation?

12. STA 的 descriptive、estimator、model component 三种身份如何区分?

13. 公式表中的 “pixelized linear drive” 解决什么问题? 写出适用条件与一个 sanity check。

14. 公式表中的 “least-squares filter” 解决什么问题? 写出适用条件与一个 sanity check。

15. 公式表中的 “loss Hessian” 解决什么问题? 写出适用条件与一个 sanity check。

16. 公式表中的 “white-noise covariance” 解决什么问题？写出适用条件与一个 sanity check。

17. 公式表中的 “spike-triggered average” 解决什么问题？写出适用条件与一个 sanity check。

18. 公式表中的 “STA/filter relation” 解决什么问题？写出适用条件与一个 sanity check。

12 Hint Bank

1. **Hint 1.** 先识别对象、变量与假设。
Hint 2. 写出最相关的定义或方程，再代入。
Hint 3. 检查单位、shape、符号与极限情况。
2. **Hint 1.** 先识别对象、变量与假设。
Hint 2. 写出最相关的定义或方程，再代入。
Hint 3. 检查单位、shape、符号与极限情况。
3. **Hint 1.** 先识别对象、变量与假设。
Hint 2. 写出最相关的定义或方程，再代入。
Hint 3. 检查单位、shape、符号与极限情况。
4. **Hint 1.** 先识别对象、变量与假设。
Hint 2. 写出最相关的定义或方程，再代入。
Hint 3. 检查单位、shape、符号与极限情况。
5. **Hint 1.** 先识别对象、变量与假设。
Hint 2. 写出最相关的定义或方程，再代入。
Hint 3. 检查单位、shape、符号与极限情况。
6. **Hint 1.** 先识别对象、变量与假设。
Hint 2. 写出最相关的定义或方程，再代入。
Hint 3. 检查单位、shape、符号与极限情况。
7. **Hint 1.** 先识别对象、变量与假设。
Hint 2. 写出最相关的定义或方程，再代入。
Hint 3. 检查单位、shape、符号与极限情况。
8. **Hint 1.** 先识别对象、变量与假设。
Hint 2. 写出最相关的定义或方程，再代入。
Hint 3. 检查单位、shape、符号与极限情况。
9. **Hint 1.** 先识别对象、变量与假设。
Hint 2. 写出最相关的定义或方程，再代入。
Hint 3. 检查单位、shape、符号与极限情况。
10. **Hint 1.** 先识别对象、变量与假设。
Hint 2. 写出最相关的定义或方程，再代入。
Hint 3. 检查单位、shape、符号与极限情况。
11. **Hint 1.** 先识别对象、变量与假设。
Hint 2. 写出最相关的定义或方程，再代入。
Hint 3. 检查单位、shape、符号与极限情况。
12. **Hint 1.** 先识别对象、变量与假设。
Hint 2. 写出最相关的定义或方程，再代入。
Hint 3. 检查单位、shape、符号与极限情况。
13. **Hint 1.** 先从“pixelized linear drive”对应的变量关系入手。
Hint 2. 把条件“ $S:P \times T$ ”逐字转换为 assumption。
Hint 3. 写公式，再检查至少一种极端参数或单位。
14. **Hint 1.** 先从“least-squares filter”对应的变量关系入手。
Hint 2. 把条件“ SS^T invertible”逐字转换为 assumption。
Hint 3. 写公式，再检查至少一种极端参数或单位。

15. **Hint 1.** 先从 “loss Hessian” 对应的变量关系入手。
Hint 2. 把条件 “linear squared loss” 逐字转换为 assumption。
Hint 3. 写公式, 再检查至少一种极端参数或单位。
16. **Hint 1.** 先从 “white-noise covariance” 对应的变量关系入手。
Hint 2. 把条件 “large T、independent equal-variance pixels” 逐字转换为 assumption。
Hint 3. 写公式, 再检查至少一种极端参数或单位。
17. **Hint 1.** 先从 “spike-triggered average” 对应的变量关系入手。
Hint 2. 把条件 “aligned stimulus histories” 逐字转换为 assumption。
Hint 3. 写公式, 再检查至少一种极端参数或单位。
18. **Hint 1.** 先从 “STA/filter relation” 对应的变量关系入手。
Hint 2. 把条件 “white Gaussian single-filter assumptions” 逐字转换为 assumption。
Hint 3. 写公式, 再检查至少一种极端参数或单位。

13 Complete Answer Key with reasoning

1. $S:P \times T$, $K:P \times 1$, $L:T \times 1$ 。
2. $SS^T K = Sh$ 。
3. stimulus covariance/design SS^T/T 。
4. covariance $\approx \sigma^2 I$, 各方向 curvature 相同。
5. $h_t = k_t / \Delta t$, k_t 通常 0 或 1。
6. Sh 只累加 spike bins 的 stimulus; white covariance inverse 是 scalar identity。
7. 乘/求解 stimulus covariance inverse, 即 whitening/normal equation。
8. $+K$ 和 $-K$ stimulus 都触发 spikes, 均值抵消。
9. 只保留均值方向, 不能表示多维 subspace。
10. 投影 L , 估 $P(\text{spike}|L)$, 除以 Δt 。
11. 避免模型只拟合 stimulus/spike noise, 检验对新数据预测。
12. 描述是条件平均; estimator 需假设; model component 是 fitted LNP 的 filter。
13. 适用条件/约定: $S:P \times T$ 。sanity check 应检查单位、符号、极限或 shape 是否与定义一致。

$$L = S^T K$$

14. 适用条件/约定: SS^T invertible。sanity check 应检查单位、符号、极限或 shape 是否与定义一致。

$$\hat{K} = (SS^T)^{-1} Sh$$

15. 适用条件/约定: linear squared loss。sanity check 应检查单位、符号、极限或 shape 是否与定义一致。

$$H = SS^T / T$$

16. 适用条件/约定: large T 、independent equal-variance pixels。sanity check 应检查单位、符号、极限或 shape 是否与定义一致。

$$SS^T \approx T \sigma_s^2 I$$

17. 适用条件/约定: aligned stimulus histories。sanity check 应检查单位、符号、极限或 shape 是否与定义一致。

$$STA = \frac{1}{n_{sp}} \sum_{t \in \text{spikes}} s_t$$

18. 适用条件/约定: white Gaussian single-filter assumptions。sanity check 应检查单位、符号、极限或 shape 是否与定义一致。

$$\hat{K} \propto STA$$

14 Source-page concordance and coverage audit

Source file	Page	Coverage status
Lecture13-SpikeTriggeredAverage-UPDATE.pdf	1	Main source-page unit: thumbnail, reconstruction, explanation, prediction question.
Lecture13-SpikeTriggeredAverage-UPDATE.pdf	2	Main source-page unit: thumbnail, reconstruction, explanation, prediction question.
Lecture13-SpikeTriggeredAverage-UPDATE.pdf	3	Main source-page unit: thumbnail, reconstruction, explanation, prediction question.
Lecture13-SpikeTriggeredAverage-UPDATE.pdf	4	Main source-page unit: thumbnail, reconstruction, explanation, prediction question.
Lecture13-SpikeTriggeredAverage-UPDATE.pdf	5	Main source-page unit: thumbnail, reconstruction, explanation, prediction question.
Lecture13-SpikeTriggeredAverage-UPDATE.pdf	6	Main source-page unit: thumbnail, reconstruction, explanation, prediction question.

15 Errata, uncertainty log, and external endnotes

15.1 Errata / source cautions

1. Page 4 的 isotropic Hessian 是 large-sample approximation, 不是有限数据精确等式。
2. Page 5 的 proportionality constant 包含 T、stimulus variance、 Δt 与 spike count; 不能省略后比较绝对 gain。
3. Page 6 明确称 workflow heuristic; 本教材补充列出 catastrophic failure conditions。

15.2 Uncertainty log

No unresolved handwriting uncertainty changes a core definition, equation, figure interpretation, or answer in this companion. Where handwriting was potentially ambiguous, the source-page image is preserved and the reconstruction avoids claiming unverified detail.

15.3 External endnotes

No external web or textbook source was used to replace the uploaded notes. Added material is limited to necessary mathematical scaffolding, explicit assumptions, standard sanity checks, and clearly labeled transfer examples.

15.4 Final self-audit

All source pages listed above were visually inspected. Equations were checked for symbol definitions, units/shapes, assumptions, algebraic transitions, limiting cases, and failure conditions. The PDF is static and contains no interactive form fields or scripts.