

NEUROSCI 366

Lecture 14

Spike-Triggered Covariance 与 Generalized Linear Models

Source-aligned · Static · Searchable · Printable

Source files

- [Lecture14-STC-GLM.pdf](#)

Production version: 2026-08-22

Reader profile: neuroscience undergraduate education; mathematics scaffolded from high-school algebra/trigonometry to the formal computational-neuroscience level.

This companion preserves source-page order, distinguishes source material from necessary scaffolding and extensions, and places hints/answers after the lesson. It is a static PDF: no forms, JavaScript, hidden-answer widgets, passwords, or DRM.

Contents

1	How to use this companion	2
2	Learning objectives and prerequisite dependency map	2
3	Five-minute prerequisite diagnostic	2
4	Source-aligned lesson / 按原笔记页序	3
4.1	Lecture14-STC-GLM.pdf · p. 1	3
4.2	Lecture14-STC-GLM.pdf · p. 2	4
4.3	Lecture14-STC-GLM.pdf · p. 3	5
4.4	Lecture14-STC-GLM.pdf · p. 4	6
4.5	Lecture14-STC-GLM.pdf · p. 5	7
4.6	Lecture14-STC-GLM.pdf · p. 6	8
5	补全推导与数学支架 / Derivations	9
5.1	STC 与 multiple relevant dimensions	9
5.2	GLM 三要素与 canonical form	10
5.3	Gaussian、Poisson、Bernoulli 三种 likelihood	11
5.4	retinal population GLM 的 filters	12
6	Cross-page synthesis / 跨页因果与数学链	13
7	Worked examples and transfer	13
7.1	distribution/link matching	13
7.2	history filter prediction	13
8	Formula and notation sheet	15
9	Bilingual glossary	15
10	Common traps, assumptions, and limitations	16
11	Cumulative Knowledge Check	17
12	Hint Bank	19
13	Complete Answer Key with reasoning	21
14	Source-page concordance and coverage audit	22

15 Errata, uncertainty log, and external endnotes	22
15.1 Errata / source cautions	22
15.2 Uncertainty log	22
15.3 External endnotes	22
15.4 Final self-audit	23

1 How to use this companion

1. 先用 5-minute diagnostic 暴露前置缺口；不要立即翻答案。
2. 按原笔记页序阅读 source-page units：先看原页，再读 clean reconstruction 与补全逻辑。
3. 遇到公式按“问题 → 符号/shape/units → assumptions → 一行一步推导 → intuition → biological meaning → sanity check → failure”阅读。
4. 完成 Cumulative Knowledge Check；只在需要时依次打开 Hint 1、2、3。
5. 至少隔一个 page break 后再核对 Answer Key，并记录错误类型：concept、symbol、algebra、assumption、correlation/causation。

Source hierarchy. 原笔记是内容权威；本书中的“【必要前置】/【补全推导】/【跨课连接】/【延伸】”是为了补齐数学或迁移，不替代源材料。无法确认的内容必须进入 Uncertainty Log。

2 Learning objectives and prerequisite dependency map

- 定义并区分：multiple features。
- 从第一原则推导：STC eigenspace。
- 解释几何/计算直觉：stimulus correction。
- 连接生物学解释：GLM distribution。
- 诊断 assumptions 与 failure modes：linear predictor。
- 把概念迁移到新神经科学问题：link。

Dependency map

multiple features → STC eigenspace → stimulus correction → GLM distribution → linear predictor → link

Core question

当单一 linear feature 不够时，STC 如何发现多维 stimulus subspace；GLM 又如何统一 Gaussian、Poisson 与 Bernoulli response models？

3 Five-minute prerequisite diagnostic

1. STC 比 STA 多检查什么？（卡住时先看 Source-page unit 1，再看补全推导。）
2. even energy nonlinearity 下 STA 为什么可为零？（卡住时先看 Source-page unit 2，再看补全推导。）
3. colored stimulus 下 STC 应如何修正？（卡住时先看 Source-page unit 3，再看补全推导。）
4. GLM 的三个元素？（卡住时先看 Source-page unit 4，再看补全推导。）
5. GLM 中 linear 指什么？（卡住时先看 Source-page unit 5，再看补全推导。）

Scoring guide: 4–5 confident answers → proceed; 2–3 → use the prerequisite labels; 0–1 → read the formula/notation sheet once before the source-aligned lesson.

4 Source-aligned lesson / 按原笔记页序

4.1 Lecture14-STC-GLM.pdf • p. 1

Beyond light signals and single linear features:

The stimulus, s , need not be a spatiotemporal pattern of light.

Ex: For the H1 neuron in the blowfly,

$$s(t) = v(t)$$

is the velocity of image motion in typical models. The firing rate is then a temporal convolution followed by nonlinearity:

$$r = f(K * s(t)).$$

This neuron is "widefield," rather than having a narrow receptive field. More accurate models permit multiple linear features:

$$r = f\left(\underbrace{K_1 * s(t)}_{\text{Feature 1}}, \underbrace{K_2 * s(t)}_{\text{Feature 2}}, \dots, \underbrace{K_n * s(t)}_{\text{Feature n}}\right)$$

nonlinearity

For H1, 4 significant temporal features have been identified.

Compute additional features through "spike-triggered covariance" (STC). Features are eigenvectors.

$$C_{P,P_2} = \frac{1}{n_s} \sum_{i=1}^{n_s} (s_{P_1, t_i} - \bar{s}_{P_1})(s_{P_2, t_i} - \bar{s}_{P_2})$$

When there are stimulus correlations (i.e.: it's not perfectly white), instead compute eigenvectors of $C - C^{(s)}$. Like STA, s is estimated by plotting $P_{\text{spike}}(\hat{L}_1, \hat{L}_2, \dots, \hat{L}_n)$.

stimulus correlations

Original-note anchor. [Source: Lecture14-STC-GLM.pdf, p. 1]

Clean reconstruction. Page 1: H1 blowfly motion example, multiple linear features, STC, stimulus-correlation correction.

What the note is saying. 本页的中心对象是 multiple features 与 STC eigenspace。原笔记将它们放进以下链条：H1 blowfly motion example、multiple linear features、STC、stimulus-correlation correction。

Why it follows. 说明 stimulus 不必是光强图像；用 H1 velocity model 引出 wide-field feature 与 multiple relevant filters。其逻辑后果是：系统讲 GLM 的 response distribution、linear predictor、link function，并在不压垮读者的前提下解释 exponential family/canonical parameter。后面的正式推导会逐项写出 assumptions、shape/units、limiting cases 与 failure conditions。

Figure reading. 按时间线区分 stimulus/task、recording/manipulation、measured quantity 与 inferred model variable；结果相关性不能直接替代机制检验。

Stop & Predict

STC 比 STA 多检查什么？

4.2 Lecture14-STC-GLM.pdf • p. 2

Generalized linear models:

Three elements of GLM, canonical form

1. Probabilistic model of data, $\prod_{\mu=1}^P \mathcal{P}(y_{\mu} | \theta_{\mu})$

Exponential family:

$$\mathcal{P}(y | \theta) = \prod_{\mu=1}^P \exp \left(\underbrace{y_{\mu} \theta_{\mu}}_{\text{independent samples}} + \underbrace{H(y_{\mu})}_{\text{"canonical parameter"}} - \underbrace{\mathcal{D}(\theta_{\mu})}_{\text{arbitrary functions}} \right)$$

Examples: Normal distribution, Poisson, Bernoulli

2. A linear predictor of canonical parameter

$$\theta_{\mu} = \sum_{n=1}^N \xi_n x_{n\mu}, \quad \xi_n: \text{weighting coefficients}, \quad x_{n\mu}: \text{independent variables}$$

3. A "link function" relating the distribution's mean and canonical parameter

$$\theta_{\mu} = \underbrace{g}_{\text{link function, mean}}(m_{\mu}), \quad m_{\mu} = g^{-1}(\theta_{\mu})$$

Given a GLM, the weighting coefficients, ξ , are chosen to maximize the likelihood of the data.

$$\hat{\xi} = \arg \max_{\xi} \ell(\xi) = \arg \max_{\xi} \log \mathcal{P}(y | \theta(\xi))$$

In practice, it's easy to ~~optimize~~ optimize GLMs in canonical form numerically. Very popular method in neuro!

Original-note anchor. [Source: Lecture14-STC-GLM.pdf, p. 2]

Clean reconstruction. Page 2: GLM 三要素与 exponential-family canonical form.

What the note is saying. 本页的中心对象是 stimulus correction 与 GLM distribution。原笔记将它们放进以下链条: GLM 三要素与 exponential-family canonical form。

Why it follows. 系统讲 GLM 的 response distribution、linear predictor、link function, 并在不压垮读者的前提下解释 exponential family/canonical parameter。其逻辑后果是: 逐项重构 Pillow retinal GLM: stimulus filters、self-history refractory/burst filters、cross-neuron coupling filters, 以及 simultaneous fitting。后面的正式推导会逐项写出 assumptions、shape/units、limiting cases 与 failure conditions。

Figure reading. 先识别图中对象、箭头、参数和坐标系, 再问它表达的是定义、推导、模型预测还是经验观察; 示意图不提供未标注的定量精度。

Stop & Predict

even energy nonlinearity 下 STA 为什么可为零?

4.3 Lecture14-STC-GLM.pdf • p. 3

Unit normal GLM: ordinary linear regression

$$1. P(y|m) = \prod_{\mu=1}^P \frac{1}{\sqrt{2\pi}} e^{-(y_{\mu} - m_{\mu})^2/2}$$

$$= \prod_{\mu=1}^P \exp \left(\underbrace{y_{\mu} m_{\mu}}_{\theta_{\mu}} - \underbrace{\frac{1}{2} y_{\mu}^2}_{H(y_{\mu})} - \underbrace{\log \sqrt{2\pi}}_{-D(\theta_{\mu})} - \underbrace{\frac{1}{2} m_{\mu}^2}_{-D(\theta_{\mu})} \right)$$

The canonical parameter is the mean.

$$2. \theta_{\mu} = \sum_{n=1}^N \beta_n X_{n\mu}$$

3. The canonical link function is the identity

$$g(x) = x \Rightarrow \theta_{\mu} = m_{\mu}$$

$$m_{\mu} = \sum_{n=1}^N \beta_n X_{n\mu}$$

The resulting log-likelihood function is

$$\ell(\beta) = - \sum_{\mu=1}^P \left(\underbrace{\frac{1}{2} (y_{\mu} - \sum_{n=1}^N \beta_n X_{n\mu})^2}_{\text{Proportional to mean squared error}} + \underbrace{\log \sqrt{2\pi}}_{\text{independent of } \beta} \right)$$

Maximizing the log-likelihood is equivalent to minimizing the mean squared error.

Poisson GLM: Poisson regression

$$1. P(y|\lambda) = \prod_{\mu=1}^P \frac{\lambda_{\mu}^{y_{\mu}} e^{-\lambda_{\mu}}}{y_{\mu}!}$$

$$= \prod_{\mu=1}^P \exp \left(y_{\mu} \log \lambda_{\mu} - \log y_{\mu}! - \lambda_{\mu} \right)$$

$$P(y|\theta) = \prod_{\mu=1}^P \exp \left(y_{\mu} \underbrace{\log \lambda_{\mu}}_{\theta_{\mu}} - \log y_{\mu}! - e^{\theta_{\mu}} \right)$$

$$= \prod_{\mu=1}^P \exp \left(y_{\mu} \theta_{\mu} - \log y_{\mu}! - e^{\theta_{\mu}} \right)$$

$$2. \theta_{\mu} = \sum_{n=1}^N \beta_n X_{n\mu}$$

Original-note anchor. [Source: Lecture14-STC-GLM.pdf, p. 3]**Clean reconstruction.** Page 3: unit-normal Gaussian GLM / ordinary linear regression; Poisson GLM 开始。**What the note is saying.** 本页的中心对象是 linear predictor 与 link。原笔记将它们放进以下链条：unit-normal Gaussian GLM / ordinary linear regression; Poisson GLM 开始。**Why it follows.** 解释 maximizing Gaussian log likelihood 等价于 minimizing MSE; Poisson regression 的 exp 保证非负 rate; logistic sigmoid 产生 probability。其逻辑后果是：系统讲 GLM 的 response distribution、linear predictor、link function，并在不压垮读者的前提下解释 exponential family/canonical parameter。后面的正式推导会逐项写出 assumptions、shape/units、limiting cases 与 failure conditions。**Figure reading.** 把图与矩阵 shape 对齐：轴代表变量或 mode，椭圆方向对应 eigenvectors，轴长/曲率对应 eigenvalues；不要把统计轴自动解释为因果通路。**Stop & Predict**

colored stimulus 下 STC 应如何修正？

4.4 Lecture14-STC-GLM.pdf • p. 4

3. Since the mean is λ_μ , and $\Theta_\mu = \log \lambda_\mu$, the canonical link function is

$$g(x) = \log(x) \Rightarrow \lambda_\mu = e^{\Theta_\mu}$$

$$\lambda_\mu = e^{\sum_n \xi_n x_{n\mu}}$$

The resulting log-likelihood function is

$$\ell(\xi) = \sum_{\mu=1}^P \left(y_\mu \sum_{n=1}^N \xi_n x_{n\mu} - \underbrace{e^{\sum_n \xi_n x_{n\mu}}}_{\text{independent of } \xi} - \log y_\mu! \right)$$

Original-note anchor. [Source: Lecture14-STC-GLM.pdf, p. 4]

Clean reconstruction. Page 4: Poisson log link 与 log likelihood.

What the note is saying. 本页的中心对象是 population history/coupling 与 multiple features。原笔记将它们放进以下链条：Poisson log link 与 log likelihood。

Why it follows. 解释 maximizing Gaussian log likelihood 等价于 minimizing MSE; Poisson regression 的 exp 保证非负 rate; logistic sigmoid 产生 probability。其逻辑后果是：分别推导 Gaussian/identity-link、Poisson/log-link、Bernoulli/logit-link 的 likelihood 与 log likelihood。后面的正式推导会逐项写出 assumptions、shape/units、limiting cases 与 failure conditions。

Figure reading. 先明确横纵轴、单位、归一化与每条曲线改变的唯一参数；区分示意趋势、模型预测和真正测得的数据点。

Stop & Predict

GLM 的三个元素？

4.5 Lecture14-STC-GLM.pdf • p. 5

GLM model of RGCs:

In 2008, Jonathan Pillow and Eero Simoncelli popularized GLM modeling in neuroscience by fitting spiking data from many RGCs with a neural network instantiation of the Poisson GLM.

Comparison of GLM to LNP model:

Take $\mu = t$,


$$R_t \sim \text{Pois} \left(\underbrace{\exp}_{\text{P}} \left(\underbrace{\sum_{n=1}^N}_{\text{N}} \underbrace{g_n}_{\text{L}} X_{nt} \right) \right)$$

Rather than X being white noise stimuli, X can be anything. Rather than fitting N , it's defined as $g'(x) = e^x$.

Note that N is 1D.

Pillow model:

X comprised: binary white noise stimuli, past spikes of neuron, past spikes of other neurons.



All these linear filters fit at once directly to data.
Actual model had 27 RGCs, not 2.

Original-note anchor. [Source: Lecture14-STC-GLM.pdf, p. 5]

Clean reconstruction. Page 5: Pillow–Simoncelli retinal population GLM、stimulus/history/-coupling filters.

What the note is saying. 本页的中心对象是 STC eigenspace 与 stimulus correction。原笔记将它们放进以下链条：Pillow–Simoncelli retinal population GLM、stimulus/history/coupling filters。

Why it follows. 逐项重构 Pillow retinal GLM：stimulus filters、self-history refractory/burst filters、cross-neuron coupling filters，以及 simultaneous fitting。其逻辑后果是：系统讲 GLM 的 response distribution、linear predictor、link function，并在不压垮读者的前提下解释 exponential family/canonical parameter。后面的正式推导会逐项写出 assumptions、shape/units、limiting cases 与 failure conditions。

Figure reading. 按时间线区分 stimulus/task、recording/manipulation、measured quantity 与 inferred model variable；结果相关性不能直接替代机制检验。

Stop & Predict

GLM 中 linear 指什么？

4.6 Lecture14-STC-GLM.pdf • p. 6

Bernoulli GLM: logistic regression

$$1. P(Y|q) = \prod_{\mu=1}^P q_{\mu}^{Y_{\mu}} (1-q_{\mu})^{1-Y_{\mu}}, \quad Y_{\mu} \in \{0,1\}, q_{\mu} = P(Y_{\mu}=1)$$

$$\Theta_{\mu} = \log \frac{q_{\mu}}{1-q_{\mu}}, \quad \text{"log odds ratio"}$$

$$P(Y|\Theta) = \prod_{\mu=1}^P \exp \left(Y_{\mu} \Theta_{\mu} - \log(1 + e^{\Theta_{\mu}}) \right)$$

$$2. \Theta_{\mu} = \sum_{n=1}^N \beta_n X_{n\mu}$$

3. Since the mean is q_{μ}

$$\Theta_{\mu} = \log \frac{q_{\mu}}{1-q_{\mu}} \Rightarrow g(x) = \log \frac{x}{1-x} \Rightarrow q_{\mu} = \frac{e^{\Theta_{\mu}}}{1 + e^{\Theta_{\mu}}}$$

$$q_{\mu} = \frac{e^{\sum_n \beta_n X_{n\mu}}}{1 + e^{\sum_n \beta_n X_{n\mu}}}, \quad 1 - q_{\mu} = \frac{1}{1 + e^{\sum_n \beta_n X_{n\mu}}}$$

The resulting log-likelihood function is

$$\ell(\beta) = \sum_{\mu=1}^P \left(Y_{\mu} \log q_{\mu}(\beta) + (1-Y_{\mu}) \log (1-q_{\mu}(\beta)) \right)$$

Negative of cross-entropy loss mentioned
in machine learning lecture (classification)

Neuroscience applications common when studying binary behaviors (e.g.: choose A or B; Go or No/Go; Attack or not; etc.)

Original-note anchor. [Source: Lecture14-STC-GLM.pdf, p. 6]

Clean reconstruction. Page 6: Bernoulli GLM, logistic regression, log odds, cross-entropy.

What the note is saying. 本页的中心对象是 GLM distribution 与 linear predictor。原笔记将它们放进以下链条: Bernoulli GLM、logistic regression、log odds、cross-entropy。

Why it follows. 解释 maximizing Gaussian log likelihood 等价于 minimizing MSE; Poisson regression 的 exp 保证非负 rate; logistic sigmoid 产生 probability。其逻辑后果是: 严格区分 Poisson count model、Bernoulli small-bin model 和 logistic classification。后面的正式推导会逐项写出 assumptions、shape/units、limiting cases 与 failure conditions。

Figure reading. 先识别图中对象、箭头、参数和坐标系, 再问它表达的是定义、推导、模型预测还是经验观察; 示意图不提供未标注的定量精度。

Stop & Predict

Gaussian identity-link MLE 与什么等价?

5 补全推导与数学支架 / Derivations

5.1 STC 与 multiple relevant dimensions

【必要前置】 STA 为零或 neuron 依赖多个 projections 时如何找 features?

$$C_{sp} = E[(s - \mu_{sp})(s - \mu_{sp})^T \mid spike]$$

$$\Delta C = C_{sp} - C_s$$

$$\Delta C \mathbf{v}_k = \lambda_k \mathbf{v}_k$$

1. STA 检查 conditional mean shift; STC 检查 conditional covariance shift。
2. large positive/negative eigenvalues 表示 spike-triggered variance 相对 baseline 增/减的 directions。
3. energy model 的 $\pm$ feature stimuli 平均为零但 covariance 沿 feature direction 增大。
4. 若 $C_s \neq I$, 应先 whiten 或解 generalized eigenproblem。

Geometric/computational intuition. STC 找的是 “spike 前 stimulus cloud 形状改变” 的轴。
Biological interpretation / failure condition. 高维 covariance 需要大量 spikes; 有限样本 eigenvectors 易过拟合。

Micro-check

GLM 的三个元素?

5.2 GLM 三要素与 canonical form

【补全推导】 如何把不同 response types 放进统一建模语言？

$$\eta_\mu = \beta_0 + \sum_n \beta_n x_{n\mu}$$

$$g(m_\mu) = \eta_\mu$$

$$P(y_\mu | \eta_\mu) = \exp\{y_\mu \eta_\mu - H(y_\mu) - D(\eta_\mu)\}$$

1. 选择 response distribution 决定 noise/variance structure。
2. linear predictor η 是 features 的 weighted sum。
3. link g 把 conditional mean m 映射到 η 。
4. maximum likelihood 估计 β ，而不是统一最小化 MSE。

Geometric/computational intuition. GLM 的 “linear” 指 predictor，对 mean 的关系可通过 nonlinear link。

Biological interpretation / failure condition. distribution/link 选择错误会导致 negative rates、probability 越界或 variance mismatch。

Micro-check

GLM 中 linear 指什么？

5.3 Gaussian、Poisson、Bernoulli 三种 likelihood

【跨页连接】 推导常用 GLMs。

$$\text{Gaussian: } m = \eta, \ell = -\frac{1}{2} \sum (y - m)^2 + \text{const}$$

$$\text{Poisson: } \lambda = e^\eta, \ell = \sum [y\eta - e^\eta - \log(y!)]$$

$$\text{Bernoulli: } q = \frac{e^\eta}{1 + e^\eta}, \ell = \sum [y \log q + (1 - y) \log(1 - q)]$$

1. unit-variance Gaussian + identity link 使 MLE 等价于 least squares。
2. Poisson canonical log link 保证 $\lambda > 0$ 。
3. Bernoulli logit link 令 $\eta = \log(q/(1-q))$, inverse 是 sigmoid。
4. negative Bernoulli log-likelihood 即 binary cross-entropy。

Geometric/computational intuition. link 把 unrestricted linear score 转成 response mean 的合法范围。

Biological interpretation / failure condition. Poisson overdispersion、zero inflation 或 temporal dependence 需扩展。

Micro-check

Gaussian identity-link MLE 与什么等价？

5.4 retinal population GLM 的 filters

【模型边界】 如何同时建模 stimulus、refractory/history 与 neuron interactions?

$$\lambda_i(t) = \exp\{k_i * s + h_i * y_i + \sum_{j \neq i} c_{ij} * y_j + b_i\}$$

1. stimulus filter k_i 提取外界 drive。
2. self-history h_i 可表示 refractory suppression 或 bursting facilitation。
3. coupling filters c_{ij} 捕捉其他 neurons' past spikes 对 conditional rate 的预测。
4. 全部 filters 可在 joint likelihood 中同时优化, 减少逐步拟合造成的 confounding。

Geometric/computational intuition. GLM 把多种历史变量都放进同一个 linear predictor, 再用 exp 生成 positive rate。

Biological interpretation / failure condition. coupling coefficient 可能反映 shared input 或 unobserved neurons, 不自动证明 direct synapse。

Micro-check

Poisson 为什么常用 log link?

6 Cross-page synthesis / 跨页因果与数学链

STC 比较 spike-triggered 与 raw stimulus covariance, 寻找 spikes 前 variance 被放大或压缩的 directions; colored stimuli 需 whitening/correction。GLM 则用 response distribution、linear predictor 与 link function 统一多种 regression。retinal population GLM 可同时拟合 stimulus filters、self-history 与 cross-neuron couplings, 但它仍是统计模型, coupling filter 不自动等于直接 synapse。




Figure note: schematic reconstruction; it encodes qualitative relations from the lesson and does not invent precise empirical data points.

7 Worked examples and transfer

7.1 distribution/link matching

【原课/核心例题】 Prompt. 200 ms 窗口 spike count、单 bin spike/no-spike、连续 eye velocity。

Worked solution. count 可用 Poisson/log; small-bin binary 可用 Bernoulli/logit; 连续近 Gaussian residual 可用 Gaussian/identity。

Check. response support 必须匹配: count ≥ 0 , probability $\in [0,1]$, continuous 可正可负。

7.2 history filter prediction

【跨课连接】 Prompt. self-history filter 在 spike 后 5 ms 强负、20–50 ms 正。

Worked solution. 模型预测立即 refractory suppression, 随后短暂 increased conditional rate/burst tendency。

Check. 这是 conditional statistical effect, 不一定对应单一 ion channel。

Micro-check

Explain in your own words. 用不超过 120 字解释: 本课从 source page 1 到最后一页, 究竟把哪一个输入、状态、统计量或学习规则变成了可检验 prediction?

Self-reflection. 你最可能犯的是 concept、symbol、algebra、assumption 还是 causality error? 写出一个具体例子。

8 Formula and notation sheet

1. STC covariance change

$$\Delta C = C_{spike} - C_{stim}$$

Conditions / conventions: centered ensembles

2. GLM linear predictor

$$\eta = X\beta$$

Conditions / conventions: shape-compatible design

3. link function

$$g(E[y|x]) = \eta$$

Conditions / conventions: chosen response family

4. Poisson log-link inverse

$$\lambda = e^\eta$$

Conditions / conventions: positive mean

5. logistic inverse link

$$q = (1 + e^{-\eta})^{-1}$$

Conditions / conventions: $0 < q < 1$

6. Poisson log-likelihood

$$\ell_{Pois} = \sum (y\eta - e^\eta - \log y!)$$

Conditions / conventions: conditionally independent bins/counts

7. logistic loss

$$-\ell_{Bern} = \text{cross-entropy}$$

Conditions / conventions: Bernoulli outcomes

9 Bilingual glossary

中文	English / symbol	Operational meaning
脉冲触发协方差	spike-triggered covariance, STC	spike-triggered ensemble covariance 的分析。
相关子空间	relevant subspace	多个 stimulus filters 张成的 response-sensitive subspace。
指数族	exponential family	可写成特定 canonical statistic/parameter 形式的分布族。
线性预测子	linear predictor	$\eta = X\beta$ 。
链接函数	link function	conditional mean 与 η 之间的映射。
Poisson 回归	Poisson regression	count/rate 的 log-link GLM。
逻辑回归	logistic regression	Bernoulli outcome 的 logit-link GLM。
对数几率	log odds	$\log[q/(1-q)]$ 。
历史滤波器	history filter	过去 spikes 对当前 conditional response 的线性影响。
耦合滤波器	coupling filter	其他 units' histories 的 predictive filter。

10 Common traps, assumptions, and limitations

1. STA=0 就认为没有 relevant feature。
2. colored stimulus 下直接对 ΔC 做普通 eigendecomposition。
3. 把 GLM 的 linear 理解为 response mean 必须线性。
4. Poisson link 使用 identity 导致 negative rate。
5. 把 Bernoulli logistic classification 与 Poisson small-count model 混同。
6. 把 fitted coupling filters 当作直接 anatomical synapses。
7. 忽略 history dependence 导致 apparent stimulus filter 偏差。

Course-specific risk boundary. 不要把 GLM 的“linear”理解成 response mean 必须线性; linear 指 predictor, 对 mean 的关系由 link 决定。

11 Cumulative Knowledge Check

Do not turn to the Hint Bank until you have written a first attempt.

1. STC 比 STA 多检查什么？

2. even energy nonlinearity 下 STA 为什么可为零？

3. colored stimulus 下 STC 应如何修正？

4. GLM 的三个元素？

5. GLM 中 linear 指什么？

6. Gaussian identity-link MLE 与什么等价？

7. Poisson 为什么常用 log link？

8. logit 的 inverse 是什么？

9. cross-entropy 从哪里来？

10. self-history 负 lobe 可代表什么？

11. coupling filter 非零能证明 direct synapse 吗？

12. Poisson count 与 Bernoulli small-bin 的选择差异？

13. 公式表中的“STC covariance change”解决什么问题？写出适用条件与一个 sanity check。

14. 公式表中的“GLM linear predictor”解决什么问题？写出适用条件与一个 sanity check。

15. 公式表中的“link function”解决什么问题？写出适用条件与一个 sanity check。

16. 公式表中的 “Poisson log-link inverse” 解决什么问题？写出适用条件与一个 sanity check。

17. 公式表中的 “logistic inverse link” 解决什么问题？写出适用条件与一个 sanity check。

18. 公式表中的 “Poisson log-likelihood” 解决什么问题？写出适用条件与一个 sanity check。

19. 公式表中的 “logistic loss” 解决什么问题？写出适用条件与一个 sanity check。

20. 诊断并修正下面的说法：STA=0 就认为没有 relevant feature。

12 Hint Bank

1. **Hint 1.** 先识别对象、变量与假设。
Hint 2. 写出最相关的定义或方程，再代入。
Hint 3. 检查单位、shape、符号与极限情况。
2. **Hint 1.** 先识别对象、变量与假设。
Hint 2. 写出最相关的定义或方程，再代入。
Hint 3. 检查单位、shape、符号与极限情况。
3. **Hint 1.** 先识别对象、变量与假设。
Hint 2. 写出最相关的定义或方程，再代入。
Hint 3. 检查单位、shape、符号与极限情况。
4. **Hint 1.** 先识别对象、变量与假设。
Hint 2. 写出最相关的定义或方程，再代入。
Hint 3. 检查单位、shape、符号与极限情况。
5. **Hint 1.** 先识别对象、变量与假设。
Hint 2. 写出最相关的定义或方程，再代入。
Hint 3. 检查单位、shape、符号与极限情况。
6. **Hint 1.** 先识别对象、变量与假设。
Hint 2. 写出最相关的定义或方程，再代入。
Hint 3. 检查单位、shape、符号与极限情况。
7. **Hint 1.** 先识别对象、变量与假设。
Hint 2. 写出最相关的定义或方程，再代入。
Hint 3. 检查单位、shape、符号与极限情况。
8. **Hint 1.** 先识别对象、变量与假设。
Hint 2. 写出最相关的定义或方程，再代入。
Hint 3. 检查单位、shape、符号与极限情况。
9. **Hint 1.** 先识别对象、变量与假设。
Hint 2. 写出最相关的定义或方程，再代入。
Hint 3. 检查单位、shape、符号与极限情况。
10. **Hint 1.** 先识别对象、变量与假设。
Hint 2. 写出最相关的定义或方程，再代入。
Hint 3. 检查单位、shape、符号与极限情况。
11. **Hint 1.** 先识别对象、变量与假设。
Hint 2. 写出最相关的定义或方程，再代入。
Hint 3. 检查单位、shape、符号与极限情况。
12. **Hint 1.** 先识别对象、变量与假设。
Hint 2. 写出最相关的定义或方程，再代入。
Hint 3. 检查单位、shape、符号与极限情况。
13. **Hint 1.** 先从“STC covariance change”对应的变量关系入手。
Hint 2. 把条件“centered ensembles”逐字转换为 assumption。
Hint 3. 写公式，再检查至少一种极端参数或单位。
14. **Hint 1.** 先从“GLM linear predictor”对应的变量关系入手。
Hint 2. 把条件“shape-compatible design”逐字转换为 assumption。
Hint 3. 写公式，再检查至少一种极端参数或单位。

15. **Hint 1.** 先从 “link function” 对应的变量关系入手。
Hint 2. 把条件 “chosen response family” 逐字转换为 assumption。
Hint 3. 写公式, 再检查至少一种极端参数或单位。
16. **Hint 1.** 先从 “Poisson log-link inverse” 对应的变量关系入手。
Hint 2. 把条件 “positive mean” 逐字转换为 assumption。
Hint 3. 写公式, 再检查至少一种极端参数或单位。
17. **Hint 1.** 先从 “logistic inverse link” 对应的变量关系入手。
Hint 2. 把条件 “ $0 < q < 1$ ” 逐字转换为 assumption。
Hint 3. 写公式, 再检查至少一种极端参数或单位。
18. **Hint 1.** 先从 “Poisson log-likelihood” 对应的变量关系入手。
Hint 2. 把条件 “conditionally independent bins/counts” 逐字转换为 assumption。
Hint 3. 写公式, 再检查至少一种极端参数或单位。
19. **Hint 1.** 先从 “logistic loss” 对应的变量关系入手。
Hint 2. 把条件 “Bernoulli outcomes” 逐字转换为 assumption。
Hint 3. 写公式, 再检查至少一种极端参数或单位。
20. **Hint 1.** 先问: 混淆的是定义、统计估计、模型变量还是生物机制?
Hint 2. 指出一个缺失 assumption 或反例。
Hint 3. 用 “在……条件下……; 否则……” 改写。

13 Complete Answer Key with reasoning

1. spike-triggered covariance/variance structure, 而不只是 mean。
2. +feature 与 -feature 都触发, mean 相消。
3. whiten stimulus 或使用 generalized eigen/covariance correction。
4. response distribution、linear predictor、link function。
5. η 对 predictors linear。
6. minimize mean squared error。
7. inverse exp 保证 rate/count mean 非负, 并是 canonical link。
8. sigmoid $q=1/(1+e^{-\eta})$ 。
9. Bernoulli negative log-likelihood。
10. refractory effect。
11. 不能, 可能来自 shared/unobserved input。
12. 前者允许 0,1,2...counts; 后者每 bin 只允许 spike/no-spike。
13. 适用条件/约定: centered ensembles。sanity check 应检查单位、符号、极限或 shape 是否与定义一致。

$$\Delta C = C_{spike} - C_{stim}$$

14. 适用条件/约定: shape-compatible design。sanity check 应检查单位、符号、极限或 shape 是否与定义一致。

$$\eta = X\beta$$

15. 适用条件/约定: chosen response family。sanity check 应检查单位、符号、极限或 shape 是否与定义一致。

$$g(E[y|x]) = \eta$$

16. 适用条件/约定: positive mean。sanity check 应检查单位、符号、极限或 shape 是否与定义一致。

$$\lambda = e^{\eta}$$

17. 适用条件/约定: $0 < q < 1$ 。sanity check 应检查单位、符号、极限或 shape 是否与定义一致。

$$q = (1 + e^{-\eta})^{-1}$$

18. 适用条件/约定: conditionally independent bins/counts。sanity check 应检查单位、符号、极限或 shape 是否与定义一致。

$$\ell_{Pois} = \sum (y\eta - e^{\eta} - \log y!)$$

19. 适用条件/约定: Bernoulli outcomes。sanity check 应检查单位、符号、极限或 shape 是否与定义一致。

$$-\ell_{Bern} = \text{cross-entropy}$$

20. 该说法省略了关键定义或 assumption。正确做法是先区分对象层级, 并依据本课公式/实验设计说明成立条件; 原说法不能无条件成立。

14 Source-page concordance and coverage audit

Source file	Page	Coverage status
Lecture14-STC-GLM.pdf	1	Main source-page unit: thumbnail, reconstruction, explanation, prediction question.
Lecture14-STC-GLM.pdf	2	Main source-page unit: thumbnail, reconstruction, explanation, prediction question.
Lecture14-STC-GLM.pdf	3	Main source-page unit: thumbnail, reconstruction, explanation, prediction question.
Lecture14-STC-GLM.pdf	4	Main source-page unit: thumbnail, reconstruction, explanation, prediction question.
Lecture14-STC-GLM.pdf	5	Main source-page unit: thumbnail, reconstruction, explanation, prediction question.
Lecture14-STC-GLM.pdf	6	Main source-page unit: thumbnail, reconstruction, explanation, prediction question.

15 Errata, uncertainty log, and external endnotes

15.1 Errata / source cautions

1. Page 1 中 H1 的 4 significant temporal features 是课程实例；具体 filter 数量依数据与模型选择。
2. Page 2 的 canonical exponential-family notation 为概念框架，不要求所有常数项逐字对应同一教材 convention。
3. Page 5 的 retinal GLM coupling 应解释为 conditional statistical dependence，不自动证明 causal synaptic connection。

15.2 Uncertainty log

No unresolved handwriting uncertainty changes a core definition, equation, figure interpretation, or answer in this companion. Where handwriting was potentially ambiguous, the source-page image is preserved and the reconstruction avoids claiming unverified detail.

15.3 External endnotes

No external web or textbook source was used to replace the uploaded notes. Added material is limited to necessary mathematical scaffolding, explicit assumptions, standard sanity checks, and clearly labeled transfer examples.

15.4 Final self-audit

All source pages listed above were visually inspected. Equations were checked for symbol definitions, units/shapes, assumptions, algebraic transitions, limiting cases, and failure conditions. The PDF is static and contains no interactive form fields or scripts.