NEUROSCI 366

Lecture 19

群体活动与主成分分析 / Population Activity and PCA

Source-aligned ·Static ·Searchable ·Printable

Source files

- Lecture19-PopulationActivity-PCA-UPDATE.pdf
- Lecture19-PopulationActivity-PCA.pdf

Production version: 2026-08-22
Reader profile: neuroscience undergraduate education; mathematics scaffolded from high-school algebra/trigonometry to the formal computational-neuroscience level.

This companion preserves source-page order, distinguishes source material from necessary scaffolding and extensions, and places hints/answers after the lesson. It is a static PDF: no forms, JavaScript, hidden-answer widgets, passwords, or DRM.

Contents

1 How to use this companion 3

2 Learning objectives and prerequisite dependency map 3

3 Five-minute prerequisite diagnostic 3

4 Source-aligned lesson / 按原笔记页序 4

4.1 Lecture19-PopulationActivity-PCA-UPDATE.pdf ·p. 1 . . . 4

4.2 Lecture19-PopulationActivity-PCA-UPDATE.pdf ·p. 2 . . . 5

4.3 Lecture19-PopulationActivity-PCA-UPDATE.pdf ·p. 3 . . . 6

4.4 Lecture19-PopulationActivity-PCA-UPDATE.pdf ·p. 4 . . . 7

4.5 Lecture19-PopulationActivity-PCA-UPDATE.pdf ·p. 5 . . . 8

4.6 Lecture19-PopulationActivity-PCA-UPDATE.pdf ·p. 6 . . . 9

5 Version comparison / 新旧版本审计 10

6 补全推导与数学支架 / Derivations 11

6.1 对称 two-neuron eigensystem . . . 11

6.2 mode time constants 与 dynamical regimes . . . 12

6.3 approximate one-dimensional activity . . . 13

6.4 PCA variance maximization 与 top-K reconstruction . . . 13

7 Cross-page synthesis / 跨页因果与数学链 14

8 Worked examples and transfer 14

8.1 two-neuron transform . . . 14

8.2 PCA denoising . . . 14

9 Formula and notation sheet 16

10 Bilingual glossary 16

11 Common traps, assumptions, and limitations 17

12 Cumulative Knowledge Check 18

13 Hint Bank 20

14 Complete Answer Key with reasoning 22

15 Source-page concordance and coverage audit 23

16 Errata, uncertainty log, and external endnotes **23**
16.1 Errata / source cautions 23
16.2 Uncertainty log 24
16.3 External endnotes 24
16.4 Final self-audit 24

1 How to use this companion

1. 先用 5-minute diagnostic 暴露前置缺口；不要立即翻答案。
2. 按原笔记页序阅读 source-page units：先看原页，再读 clean reconstruction 与补全逻辑。
3. 遇到公式按“问题 → 符号/shape/units → assumptions → 一行一步推导 → intuition → biological meaning → sanity check → failure”阅读。
4. 完成 Cumulative Knowledge Check；只在需要时依次打开 Hint 1、2、3。
5. 至少隔一个 page break 后再核对 Answer Key，并记录错误类型：concept、symbol、algebra、assumption、correlation/causation。

Source hierarchy. 原笔记是内容权威；本书中的“【必要前置】/【补全推导】/【跨课连接】/【延伸】”是为了补齐数学或迁移，不替代源材料。无法确认的内容必须进入 Uncertainty Log。

2 Learning objectives and prerequisite dependency map

- 定义并区分：two-neuron W。
- 从第一原则推导：common/difference modes。
- 解释几何/计算直觉：mode regimes。
- 连接生物学解释：activity-space trajectory。
- 诊断 assumptions 与 failure modes：covariance。
- 把概念迁移到新神经科学问题：PCA top-K。

Dependency map
two-neuron W → common/difference modes → mode regimes → activity-space trajectory → covariance → PCA top-K
Core question
two-neuron recurrent modes 如何产生近一维 population trajectories，而 PCA 又如何仅从 activity covariance 找到最大 variance dimensions?

3 Five-minute prerequisite diagnostic

1. W=[[0,w],[w,0]] 的 eigenvalues?（卡住时先看 Source-page unit 1，再看补全推导。）
2. common mode vector?（卡住时先看 Source-page unit 2，再看补全推导。）
3. difference mode vector?（卡住时先看 Source-page unit 3，再看补全推导。）
4. w=0.8 时 τ+ 与 τ-?（卡住时先看 Source-page unit 4，再看补全推导。）
5. w=1 时哪个 mode perfect integrator?（卡住时先看 Source-page unit 5，再看补全推导。）

Scoring guide: 4–5 confident answers → proceed; 2–3 → use the prerequisite labels; 0–1 → read the formula/notation sheet once before the source-aligned lesson.

4 Source-aligned lesson / 按原笔记页序

4.1 Lecture19-PopulationActivity-PCA-UPDATE.pdf ・p. 1

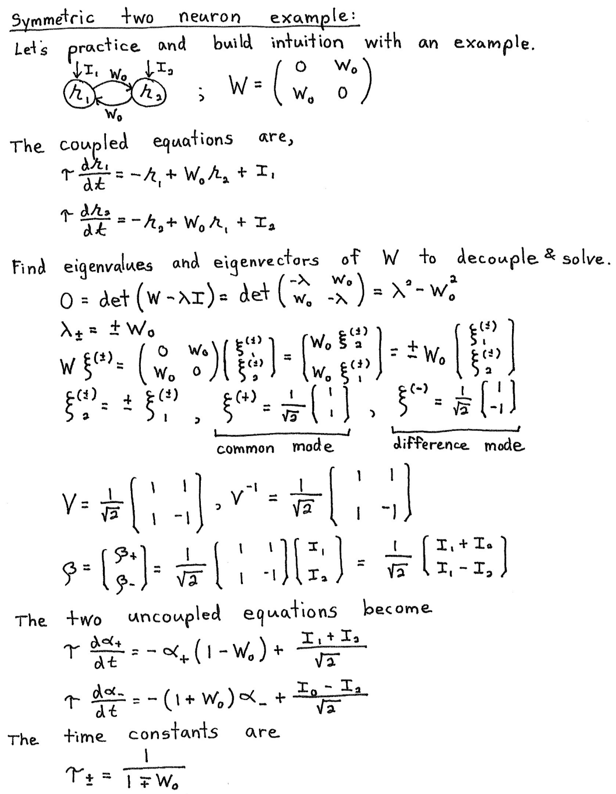

Symmetric two neuron example:

Let's practice and build intuition with an example.

I_1, I_2, W_0, W_0, r_1, r_2 ; $W = \begin{pmatrix} 0 & W_0 \\ W_0 & 0 \end{pmatrix}$

The coupled equations are,

$$\tau \frac{dr_1}{dt} = -r_1 + W_0 r_2 + I_1$$

$$\tau \frac{dr_2}{dt} = -r_2 + W_0 r_1 + I_2$$

Find eigenvalues and eigenvectors of W to decouple & solve.

$$0 = \det(W - \lambda I) = \det\begin{pmatrix} -\lambda & W_0 \\ W_0 & -\lambda \end{pmatrix} = \lambda^2 - W_0^2$$

$$\lambda_\pm = \pm W_0$$

$$W \xi^{(\pm)} = \begin{pmatrix} 0 & W_0 \\ W_0 & 0 \end{pmatrix}\begin{pmatrix} \xi_1^{(\pm)} \\ \xi_2^{(\pm)} \end{pmatrix} = \begin{pmatrix} W_0 \xi_2^{(\pm)} \\ W_0 \xi_1^{(\pm)} \end{pmatrix} = \pm W_0 \begin{pmatrix} \xi_1^{(\pm)} \\ \xi_2^{(\pm)} \end{pmatrix}$$

$$\xi_2^{(\pm)} = \pm \xi_1^{(\pm)}, \quad \underbrace{\xi^{(+)} = \frac{1}{\sqrt{2}}\begin{pmatrix} 1 \\ 1 \end{pmatrix}}_{\text{common mode}}, \quad \underbrace{\xi^{(-)} = \frac{1}{\sqrt{2}}\begin{pmatrix} 1 \\ -1 \end{pmatrix}}_{\text{difference mode}}$$

$$V = \frac{1}{\sqrt{2}}\begin{pmatrix} 1 & 1 \\ 1 & -1 \end{pmatrix}, \quad V^{-1} = \frac{1}{\sqrt{2}}\begin{pmatrix} 1 & 1 \\ 1 & -1 \end{pmatrix}$$

$$\beta = \begin{pmatrix} \beta_+ \\ \beta_- \end{pmatrix} = \frac{1}{\sqrt{2}}\begin{pmatrix} 1 & 1 \\ 1 & -1 \end{pmatrix}\begin{pmatrix} I_1 \\ I_2 \end{pmatrix} = \frac{1}{\sqrt{2}}\begin{pmatrix} I_1 + I_2 \\ I_1 - I_2 \end{pmatrix}$$

The two uncoupled equations become

$$\tau \frac{d\alpha_+}{dt} = -\alpha_+(1 - W_0) + \frac{I_1 + I_2}{\sqrt{2}}$$

$$\tau \frac{d\alpha_-}{dt} = -(1 + W_0)\alpha_- + \frac{I_0 - I_2}{\sqrt{2}}$$

The time constants are

$$\tau_\pm = \frac{1}{1 \mp W_0}$$

Original-note anchor. [Source: Lecture19-PopulationActivity-PCA-UPDATE.pdf, p. 1]
Clean reconstruction. UPDATE Page 1：symmetric two-neuron network、eigenvalues/eigenvectors、common/difference modes。
What the note is saying. 本页的中心对象是 two-neuron W 与 common/difference modes。原笔记将它们放进以下链条：symmetric two-neuron network、eigenvalues/eigenvectors、common/difference modes。
Why it follows. 完整求解 two-neuron weight matrix 的 eigenvalues/eigenvectors，规范化 common/difference modes, 并变换输入。其逻辑后果是: 必须明确区分 eigenvectors of recurrent weight matrix W（dynamical modes）与 eigenvectors of covariance C（principal components）；它们不一般相同。后面的正式推导会逐项写出 assumptions、shape/units、limiting cases 与 failure conditions。
Figure reading. 把图与矩阵 shape 对齐：轴代表变量或 mode，椭圆方向对应 eigenvectors，轴长/曲率对应 eigenvalues；不要把统计轴自动解释为因果通路。

Stop & Predict

W=[[0,w],[w,0]] 的 eigenvalues?

4.2 Lecture19-PopulationActivity-PCA-UPDATE.pdf · p. 2

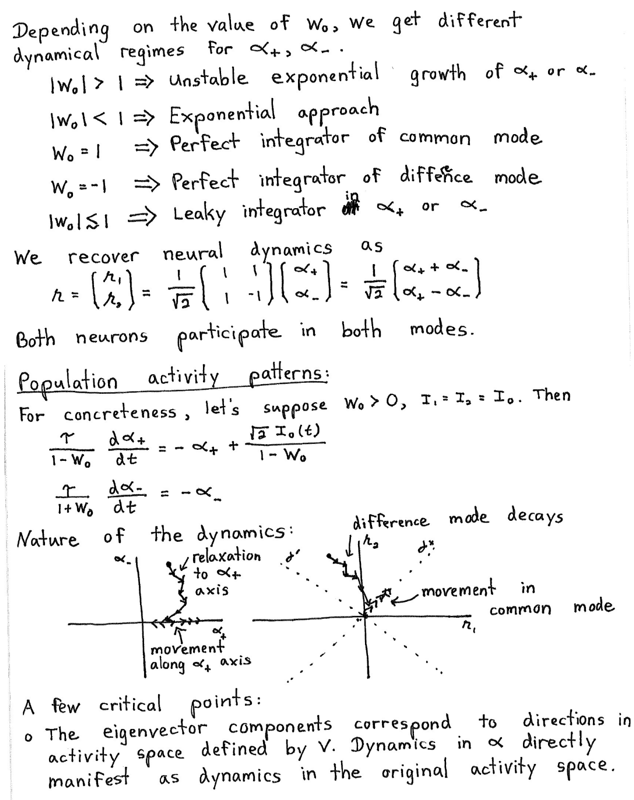

Depending on the value of w_0, we get different dynamical regimes for α_+, α_-.

$|w_0| > 1 \Rightarrow$ Unstable exponential growth of α_+ or α_-

$|w_0| < 1 \Rightarrow$ Exponential approach

$w_0 = 1 \Rightarrow$ Perfect integrator of common mode

$w_0 = -1 \Rightarrow$ Perfect integrator of difference mode

$|w_0| \lesssim 1 \Rightarrow$ Leaky integrator in α_+ or α_-

We recover neural dynamics as

$$r = \begin{pmatrix} r_1 \\ r_2 \end{pmatrix} = \frac{1}{\sqrt{2}} \begin{pmatrix} 1 & 1 \\ 1 & -1 \end{pmatrix} \begin{pmatrix} \alpha_+ \\ \alpha_- \end{pmatrix} = \frac{1}{\sqrt{2}} \begin{pmatrix} \alpha_+ + \alpha_- \\ \alpha_+ - \alpha_- \end{pmatrix}$$

Both neurons participate in both modes.

Population activity patterns:

For concreteness, let's suppose $w_0 > 0$, $I_1 = I_2 = I_0$. Then

$$\frac{\tau}{1-w_0} \frac{d\alpha_+}{dt} = -\alpha_+ + \frac{\sqrt{2}\, I_0(t)}{1-w_0}$$

$$\frac{\tau}{1+w_0} \frac{d\alpha_-}{dt} = -\alpha_-$$

Nature of the dynamics:

A few critical points:

- The eigenvector components correspond to directions in activity space defined by V. Dynamics in α directly manifest as dynamics in the original activity space.

Original-note anchor. [Source: Lecture19-PopulationActivity-PCA-UPDATE.pdf, p. 2]
Clean reconstruction. UPDATE Page 2：coupling regimes、mode time constants、population trajectories。
What the note is saying. 本页的中心对象是 mode regimes 与 activity-space trajectory。原笔记将它们放进以下链条：coupling regimes、mode time constants、population trajectories。
Why it follows. 按 `w0` 的符号/大小分析 stable、unstable、perfect/leaky integrator regimes。其逻辑后果是: 解释 neural activity space 与 mode-coordinate space 的同一轨迹表示; 说明 approximate one-dimensionality 如何来自 difference mode decay。后面的正式推导会逐项写出 assumptions、shape/units、limiting cases 与 failure conditions。
Figure reading. 先识别图中对象、箭头、参数和坐标系，再问它表达的是定义、推导、模型预测还是经验观察；示意图不提供未标注的定量精度。

Stop & Predict

common mode vector?

4.3 Lecture19-PopulationActivity-PCA-UPDATE.pdf • p. 3

- V and V^{-1} correspond to basis transformation matrices. (r_1, r_2) and (α_+, α_-) are coordinates for the same underlying activity space. r-coordinates are especially meaningful for biological mechanisms; α-coordinates for dynamics.
- The dynamics are approximately one-dimensional, because the difference mode decays to zero and stays there. Ongoing dynamics are confined to the common mode.

The first two points generally hold.

The third implies that we can reduce the dimensionality of the system

$$\begin{bmatrix} r_1(t) \\ r_2(t) \end{bmatrix} = V \begin{bmatrix} \alpha_1(t) \\ \alpha_2(t) \end{bmatrix} = \frac{1}{\sqrt{2}} \begin{bmatrix} 1 & 1 \\ 1 & -1 \end{bmatrix} \begin{bmatrix} \alpha_1(t) \\ \alpha_2(t) \end{bmatrix}$$

$$= \frac{1}{\sqrt{2}} \begin{bmatrix} \alpha_1(t) + \alpha_2(t) \\ \alpha_1(t) - \alpha_2(t) \end{bmatrix} = \underbrace{\frac{\alpha_1(t)}{\sqrt{2}} \begin{bmatrix} 1 \\ 1 \end{bmatrix}}_{\text{Very important}} + \underbrace{\frac{\alpha_2(t)}{\sqrt{2}} \begin{bmatrix} 1 \\ -1 \end{bmatrix}}_{\text{Negligible}}$$

$$\approx \underbrace{\frac{\alpha_1(t)}{\sqrt{2}} \begin{bmatrix} 1 \\ 1 \end{bmatrix}}_{\text{One-dimensional activity}}$$

This point applies to many other neural networks. However this is an impractical approach to dimensionality reduction, because we typically only know r, not W and I.

Original-note anchor. [Source: Lecture19-PopulationActivity-PCA-UPDATE.pdf, p. 3]
Clean reconstruction. UPDATE Page 3：activity-space/mode-space basis、approximately one-dimensional dynamics。
What the note is saying. 本页的中心对象是 covariance 与 PCA top-K。原笔记将它们放进以下链条：activity-space/mode-space basis、approximately one-dimensional dynamics。
Why it follows. 解释 neural activity space 与 mode-coordinate space 的同一轨迹表示；说明 approximate one-dimensionality 如何来自 difference mode decay。其逻辑后果是：按 `w0` 的符号/大小分析 stable、unstable、perfect/leaky integrator regimes。后面的正式推导会逐项写出 assumptions、shape/units、limiting cases 与 failure conditions。
Figure reading. 先识别图中对象、箭头、参数和坐标系，再问它表达的是定义、推导、模型预测还是经验观察；示意图不提供未标注的定量精度。

Stop & Predict

difference mode vector?

4.4 Lecture19-PopulationActivity-PCA-UPDATE.pdf • p. 4

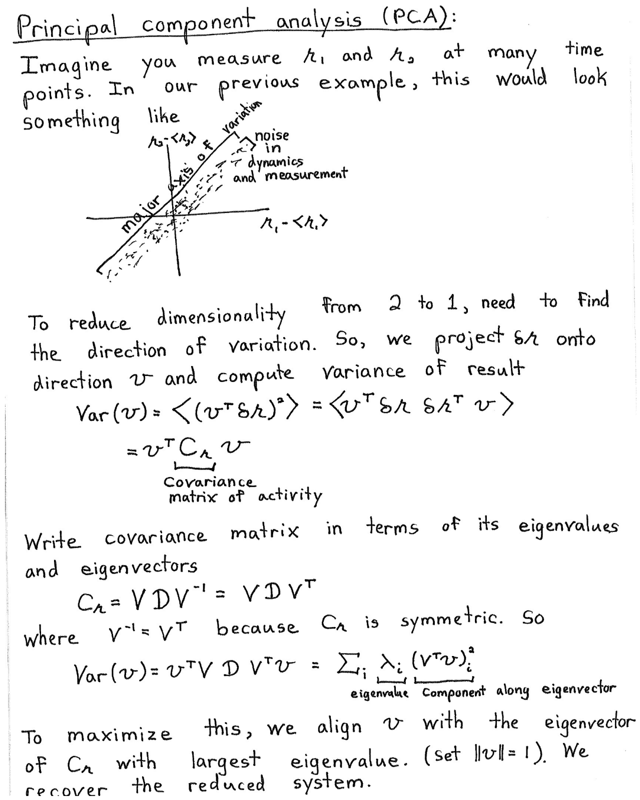

Principal component analysis (PCA):

Imagine you measure r_1 and r_2 at many time points. In our previous example, this would look something like

To reduce dimensionality from 2 to 1, need to find the direction of variation. So, we project δr onto direction v and compute variance of result

$$\mathrm{Var}(v) = \langle (v^T \delta r)^2 \rangle = \langle v^T \delta r \, \delta r^T v \rangle$$

$$= v^T \underbrace{C_r}_{\text{Covariance matrix of activity}} v$$

Write covariance matrix in terms of its eigenvalues and eigenvectors

$$C_r = V D V^{-1} = V D V^T$$

where $V^{-1} = V^T$ because C_r is symmetric. So

$$\mathrm{Var}(v) = v^T V D V^T v = \sum_i \underbrace{\lambda_i}_{\text{eigenvalue}} \underbrace{(V^T v)_i^2}_{\text{Component along eigenvector}}$$

To maximize this, we align v with the eigenvector of C_r with largest eigenvalue. (set $\|v\| = 1$). We recover the reduced system.

Original-note anchor. [Source: Lecture19-PopulationActivity-PCA-UPDATE.pdf, p. 4]
Clean reconstruction. UPDATE Page 4：PCA motivation、projected variance、covariance eigenvectors。
What the note is saying. 本页的中心对象是 scree/cumulative variance 与 two-neuron W。原笔记将它们放进以下链条：PCA motivation、projected variance、covariance eigenvectors。
Why it follows. 从 centered activity covariance 和 projection variance 推导 PC1 是最大 eigenvalue eigenvector；再推广到 orthogonal top-K PCs。其逻辑后果是：必须明确区分 eigenvectors of recurrent weight matrix W（dynamical modes）与 eigenvectors of covariance C（principal components）；它们不一般相同。后面的正式推导会逐项写出 assumptions、shape/units、limiting cases 与 failure conditions。
Figure reading. 把图与矩阵 shape 对齐：轴代表变量或 mode，椭圆方向对应 eigenvectors，轴长/曲率对应 eigenvalues；不要把统计轴自动解释为因果通路。

Stop & Predict

w=0.8 时 τ+ 与 τ-?

4.5 Lecture19-PopulationActivity-PCA-UPDATE.pdf • p. 5

More generally want to reduce N-dimensional system to $K < N$ dimensions. Second PC is vector orthogonal to first PC that maximizes variance. Since first PC is largest eigenvector of C_r, the previous equation becomes

$$\mathrm{Var}(w) = \underbrace{\sum_{i=2}^{N}}_{\text{skip PC1}} \lambda_i (V^T w)_i^2,$$

Eigenvectors of C_r are orthogonal

$$V^{-1} = V^T \Rightarrow \begin{bmatrix} \xi^{(1)T} \\ \vdots \\ \xi^{(N)T} \end{bmatrix} \begin{bmatrix} \xi^{(1)} & \xi^{(2)} & \cdots & \xi^{(N)} \end{bmatrix} = \begin{bmatrix} 1 & 0 & & 0 \\ 0 & 1 & & \\ 0 & & \ddots & 1 \end{bmatrix} \Rightarrow \xi^{(i)T} \xi^{(j)} = \delta_{ij}$$

So solution is to align PC2 to eigenvector of C_r with second largest eigenvalue. And so on...

General PCA algorithm:

- Compute neural covariance matrix, C_r.
- Find its eigenvalues and eigenvectors.
- Reduce data to K dimensions by projecting it onto the K eigenvectors with largest eigenvalues.
  $$P_i = \xi^{(i)T} r$$
- Discard $N-K$ low-variance dimensions
- Can reconstruct "denoised" neural activity as
  $$r \approx V \begin{bmatrix} P_1 \\ \vdots \\ P_K \\ 0 \end{bmatrix} = \sum_{i=1}^{K} P_i \, \xi^{(i)}$$

Original-note anchor. [Source: Lecture19-PopulationActivity-PCA-UPDATE.pdf, p. 5]
Clean reconstruction. UPDATE Page 5：top-K PCA、orthogonality、algorithm、denoised reconstruction。
What the note is saying. 本页的中心对象是 common/difference modes 与 mode regimes。原笔记将它们放进以下链条：top-K PCA、orthogonality、algorithm、denoised reconstruction。
Why it follows. 解释 projection、discarded dimensions 和 denoised reconstruction，给出 shape 与数值小例子。其逻辑后果是：从 centered activity covariance 和 projection variance 推导 PC1 是最大 eigenvalue eigenvector；再推广到 orthogonal top-K PCs。后面的正式推导会逐项写出 assumptions、shape/units、limiting cases 与 failure conditions。
Figure reading. 把图与矩阵 shape 对齐：轴代表变量或 mode，椭圆方向对应 eigenvectors，轴长/曲率对应 eigenvalues；不要把统计轴自动解释为因果通路。

Stop & Predict

w=1 时哪个 mode perfect integrator?

4.6 Lecture19-PopulationActivity-PCA-UPDATE.pdf · p. 6

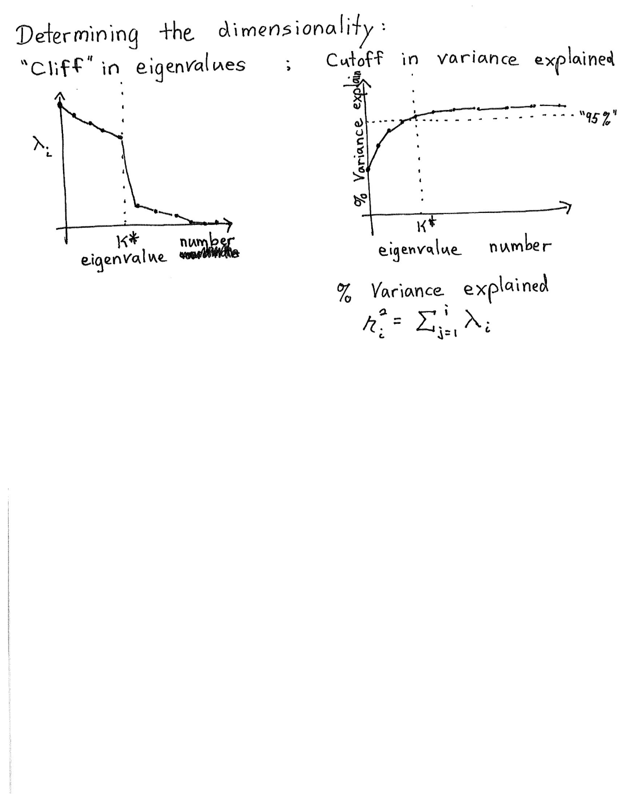

Original-note anchor. [Source: Lecture19-PopulationActivity-PCA-UPDATE.pdf, p. 6]
Clean reconstruction. UPDATE Page 6：eigenvalue cliff、cumulative variance explained、dimension cutoff。
What the note is saying. 本页的中心对象是 activity-space trajectory 与 covariance。原笔记将它们放进以下链条：eigenvalue cliff、cumulative variance explained、dimension cutoff。
Why it follows. 讲解 scree/eigenvalue cliff、cumulative variance explained 和 cutoff arbitrariness/limitations。其逻辑后果是：从 centered activity covariance 和 projection variance 推导 PC1 是最大 eigenvalue eigenvector；再推广到 orthogonal top-K PCs。后面的正式推导会逐项写出 assumptions、shape/units、limiting cases 与 failure conditions。
Figure reading. 把图与矩阵 shape 对齐：轴代表变量或 mode，椭圆方向对应 eigenvectors，轴长/曲率对应 eigenvalues；不要把统计轴自动解释为因果通路。

Stop & Predict

为什么 trajectory 近一维?

5 Version comparison / 新旧版本审计

逐页视觉比较显示，旧版 Pages 1–5 与 UPDATE Pages 1–5 在核心学术内容上实质重复；UPDATE 新增 Page 6：eigenvalue cliff、cumulative variance explained 与 dimension cutoff。旧版未发现需要单独保留的独有公式或论点。

6 补全推导与数学支架 / Derivations

6.1 对称 two-neuron eigensystem

【必要前置】 求 W=[[0,w0],[w0,0]] 的 modes。

$$\lambda_+ = w_0, \quad \xi_+ = \frac{1}{\sqrt{2}}(1,1)^T$$

$$\lambda_- = -w_0, \quad \xi_- = \frac{1}{\sqrt{2}}(1,-1)^T$$

$$V = V^{-1} = \frac{1}{\sqrt{2}}\begin{bmatrix}1 & 1\\ 1 & -1\end{bmatrix}$$

1. characteristic polynomial det(W−λI)=λ^2−$w0^2$。
2. λ=+w0 对应 h1=h2 的 common mode。
3. λ=−w0 对应 h1=−h2 的 difference mode。
4. orthonormal V 同时把 activity 与 input 变到 α±、β±。

Geometric/computational intuition. 网络的自然坐标不是两个 neurons，而是“共同变化”和“相反变化”。
Biological interpretation / failure condition. 非对称 W 的 eigenvectors 不一定 orthogonal，V^{-1} 不再等于 V^T。

Micro-check

w=0.8 时 τ+ 与 τ-?

6.2 mode time constants 与 dynamical regimes

【补全推导】 w0 如何决定 stability/integration?

$$\tau\dot{\alpha}_+ = -(1-w_0)\alpha_+ + \frac{I_1+I_2}{\sqrt{2}}$$

$$\tau\dot{\alpha}_- = -(1+w_0)\alpha_- + \frac{I_1-I_2}{\sqrt{2}}$$

$$\tau_+ = \frac{\tau}{1-w_0}, \quad \tau_- \frac{\tau}{1+w_0}$$

1. |w0|<1 时两个 modes stable。
2. w0→1^- 时 common mode 变慢，w0=1 为 common perfect integrator。
3. w0→−1^+ 时 difference mode 变慢，w0=−1 为 difference integrator。
4. |w0|>1 至少一个 mode unstable。

Geometric/computational intuition. 同一个 coupling 参数对两个正交 patterns 提供相反 feedback。
Biological interpretation / failure condition. 笔记 time-constant formula 需保留 mode sign；不能都写成 τ/(1−w0)。

Micro-check

w=1 时哪个 mode perfect integrator?

6.3 approximate one-dimensional activity

【跨页连接】 为什么 h-space trajectory 很快靠近一条 line?

$$\mathbf{h} = \alpha_+\xi_+ + \alpha_-\xi_-$$

$$\alpha_-(t) \to 0 \Rightarrow \mathbf{h}(t) \approx \alpha_+(t)\frac{(1,1)^T}{\sqrt{2}}$$

1. 初始 state 可分解为 common 与 difference components。
2. 若 τ_-≪τ_+，difference transient 快速消失。
3. 之后 trajectory 仍在 two-neuron space，却几乎局限于 common axis。
4. 低维是 activity trajectory 的性质，不代表只剩一个 active neuron。

Geometric/computational intuition. fast modes collapse，slow modes 支配长时间行为。
Biological interpretation / failure condition. 不同 inputs/trials 若持续驱动 fast modes，trajectory 不一定始终低维。

Micro-check

为什么 trajectory 近一维?

6.4 PCA variance maximization 与 top-K reconstruction

【模型边界】 仅由数据找最大 variance direction。

$$C_h = E[(h - Eh)(h - Eh)^T]$$

$$\mathrm{Var}(v^T\delta h) = v^T C_h v, \quad \|v\| = 1$$

$$C_h v_k = \lambda_k v_k$$

$$\hat{h} = \bar{h} + \sum_{k=1}^{K} v_k v_k^T (h - \bar{h})$$

1. Lagrange multiplier 对 v^TCv−λ(v^Tv−1) 求导得到 eigenproblem。
2. PC1 是最大 eigenvalue eigenvector。
3. 后续 PCs 在与前面 orthogonal 的子空间中继续最大化 variance。
4. discarded dimensions 的 variance 被视作不需要/噪声的 approximation，但这不是 causal guarantee。

Geometric/computational intuition. PCA 旋转坐标轴，使 covariance diagonal，并按 variance 排序。
Biological interpretation / failure condition. low-variance dimension 仍可能对 behavior/decoding 很重要；cutoff 有任意性。

Micro-check

PCA 前为什么 center?

7 Cross-page synthesis / 跨页因果与数学链

对称 two-neuron network 的 common 与 difference eigenmodes 可以完全手算：一个 mode 的反馈为 +w0，另一个为 −w0。若 difference mode 快速衰减，neural trajectory 便落到 common-mode line，产生 approximate one-dimensional dynamics。PCA 不需要知道 W，只从 centered activity covariance 找最大 projected variance；因此 W 的 dynamical eigenvectors 与 C 的 principal components 可能相关但一般不相同。

Lecture 19 — key reconstruction (schematic)

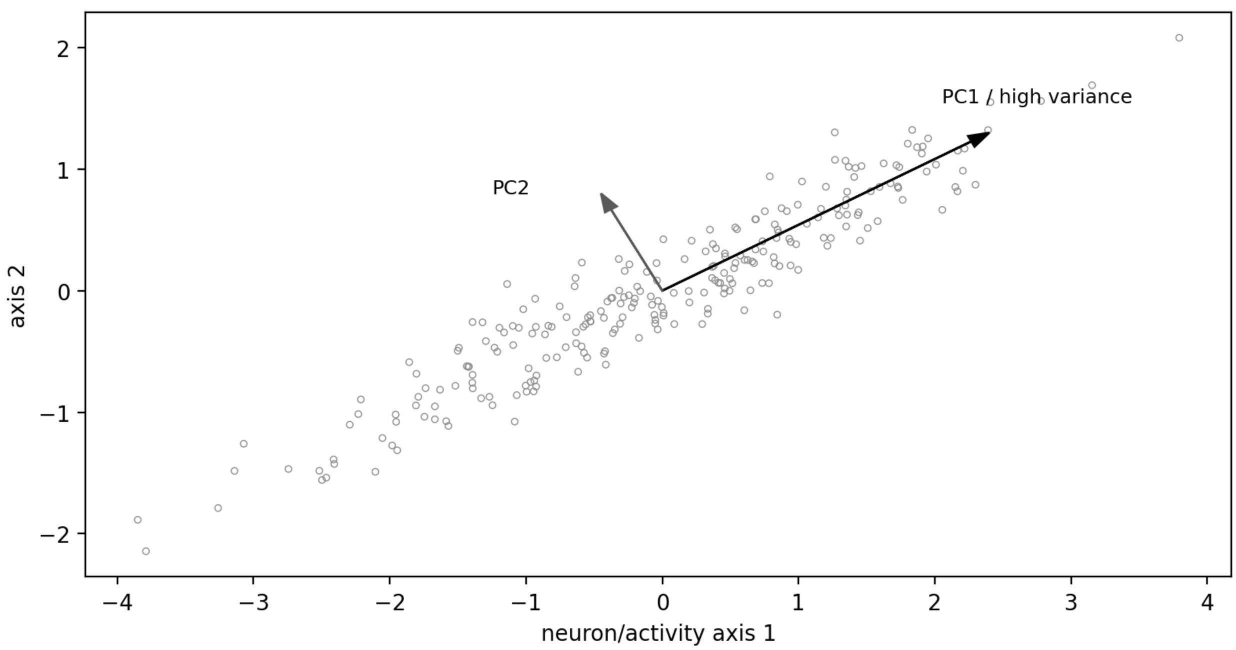

Figure note: schematic reconstruction; it encodes qualitative relations from the lesson and does not invent precise empirical data points.

8 Worked examples and transfer

8.1 two-neuron transform

【原课/核心例题】 **Prompt.** h=(3,1)^T。

Worked solution. α+=(3+1)/√2=2√2，α-=(3−1)/√2=√2；重构为 α+ξ++α-ξ-=(3,1)。
Check. basis change 不丢 information，除非主动 discard dimensions。

8.2 PCA denoising

【跨课连接】 **Prompt.** eigenvalues 为 9、1，保留 K=1。

Worked solution. 保留 90% total variance；reconstruction 投影到 PC1 line，去掉 PC2 component。
Check. 称其 denoising 需要额外假设：低 variance dimension 主要是 noise。

Micro-check

Explain in your own words. 用不超过 120 字解释：本课从 source page 1 到最后一页，究竟把哪一个输入、状态、统计量或学习规则变成了可检验 prediction?

Self-reflection. 你最可能犯的是 concept、symbol、algebra、assumption 还是 causality error? 写出一个具体例子。

9 Formula and notation sheet

1. common/difference modes

$$\xi_{\pm} = (1, \pm 1)^T/\sqrt{2}$$

Conditions / conventions: symmetric two-neuron W

2. orthonormal mode coordinates

$$\alpha = V^T h$$

Conditions / conventions: V^TV=I

3. mode time constants

$$\tau_{\pm} = \tau/(1 \mp w_0)$$

Conditions / conventions: |w0|<1 for both stable

4. activity covariance

$$C = E[\delta h \delta h^T]$$

Conditions / conventions: centered data

5. PC1

$$v_1 = \arg\max_{\|v\|=1} v^T C v$$

Conditions / conventions: C symmetric PSD

6. PC score/projection

$$p_k = v_k^T(h - \bar{h})$$

Conditions / conventions: orthonormal PCs

7. cumulative variance explained

$$\mathrm{VarFrac}(K) = \sum_{k \le K} \lambda_k / \sum_j \lambda_j$$

Conditions / conventions: eigenvalues sorted

10 Bilingual glossary

中文	English / symbol	Operational meaning
共同模态	common mode	两个 neurons 同向变化的 eigenmode。
差分模态	difference mode	两个 neurons 反向变化的 eigenmode。
神经活动空间	neural activity space	以各 neuron activity 为坐标的空间。
模态空间	mode space	以 dynamical eigenmode amplitudes 为坐标。
主成分分析	principal component analysis, PCA	按 covariance variance 排序的线性正交降维。
主成分	principal component	covariance eigenvector 与对应 score。
投影	projection	取 vector 在某 basis direction 上的 component。
重构	reconstruction	由保留 components 近似恢复原 data。
碎石图	scree plot	eigenvalue 随 component index 的曲线。
方差解释率	variance explained	保留 eigenvalues 占总和的比例。

11 Common traps, assumptions, and limitations

1. 把 W eigenvectors 与 covariance PCs 无条件等同。
2. common/difference mode normalization 漏掉 $1/\sqrt{2}$。
3. mode time constants 的 $\pm$ sign 写错。
4. 低维 trajectory 误解为只有少数 neurons active。
5. PCA 前不 center data。
6. 把 variance 最大当作 causal/behavioral relevance 最大。
7. 把 eigenvalue cliff 当作客观唯一 dimension cutoff。

Course-specific risk boundary. 以 UPDATE 为主并明确记录它新增 Page 6。不要把 PCA 说成自动发现 causal dynamics；它只按 variance 排序，可能混合 signal、noise、condition structure。

12 Cumulative Knowledge Check

Do not turn to the Hint Bank until you have written a first attempt.

1. W=[[0,w],[w,0]] 的 eigenvalues?
2. common mode vector?
3. difference mode vector?
4. w=0.8 时 τ+ 与 τ-?
5. w=1 时哪个 mode perfect integrator?
6. 为什么 trajectory 近一维?
7. PCA 前为什么 center?
8. PC1 解决什么优化?
9. top-K reconstruction 公式的含义?
10. W eigenmode 与 PCA axis 何时可能一致?
11. eigenvalue cliff 是否保证真实 intrinsic dimension?
12. 低 variance dimension 能否携带 task information?
13. 公式表中的“common/difference modes”解决什么问题？写出适用条件与一个 sanity check。
14. 公式表中的“orthonormal mode coordinates”解决什么问题？写出适用条件与一个 sanity check。
15. 公式表中的“mode time constants”解决什么问题？写出适用条件与一个 sanity check。

16. 公式表中的“activity covariance”解决什么问题？写出适用条件与一个 sanity check。

17. 公式表中的“PC1”解决什么问题？写出适用条件与一个 sanity check。

18. 公式表中的“PC score/projection”解决什么问题？写出适用条件与一个 sanity check。

13 Hint Bank

1. **Hint 1.** 先识别对象、变量与假设。
   Hint 2. 写出最相关的定义或方程，再代入。
   Hint 3. 检查单位、shape、符号与极限情况。
2. **Hint 1.** 先识别对象、变量与假设。
   Hint 2. 写出最相关的定义或方程，再代入。
   Hint 3. 检查单位、shape、符号与极限情况。
3. **Hint 1.** 先识别对象、变量与假设。
   Hint 2. 写出最相关的定义或方程，再代入。
   Hint 3. 检查单位、shape、符号与极限情况。
4. **Hint 1.** 先识别对象、变量与假设。
   Hint 2. 写出最相关的定义或方程，再代入。
   Hint 3. 检查单位、shape、符号与极限情况。
5. **Hint 1.** 先识别对象、变量与假设。
   Hint 2. 写出最相关的定义或方程，再代入。
   Hint 3. 检查单位、shape、符号与极限情况。
6. **Hint 1.** 先识别对象、变量与假设。
   Hint 2. 写出最相关的定义或方程，再代入。
   Hint 3. 检查单位、shape、符号与极限情况。
7. **Hint 1.** 先识别对象、变量与假设。
   Hint 2. 写出最相关的定义或方程，再代入。
   Hint 3. 检查单位、shape、符号与极限情况。
8. **Hint 1.** 先识别对象、变量与假设。
   Hint 2. 写出最相关的定义或方程，再代入。
   Hint 3. 检查单位、shape、符号与极限情况。
9. **Hint 1.** 先识别对象、变量与假设。
   Hint 2. 写出最相关的定义或方程，再代入。
   Hint 3. 检查单位、shape、符号与极限情况。
10. **Hint 1.** 先识别对象、变量与假设。
    Hint 2. 写出最相关的定义或方程，再代入。
    Hint 3. 检查单位、shape、符号与极限情况。
11. **Hint 1.** 先识别对象、变量与假设。
    Hint 2. 写出最相关的定义或方程，再代入。
    Hint 3. 检查单位、shape、符号与极限情况。
12. **Hint 1.** 先识别对象、变量与假设。
    Hint 2. 写出最相关的定义或方程，再代入。
    Hint 3. 检查单位、shape、符号与极限情况。
13. **Hint 1.** 先从“common/difference modes”对应的变量关系入手。
    Hint 2. 把条件“symmetric two-neuron W”逐字转换为 assumption。
    Hint 3. 写公式，再检查至少一种极端参数或单位。
14. **Hint 1.** 先从“orthonormal mode coordinates”对应的变量关系入手。
    Hint 2. 把条件“V^TV=I”逐字转换为 assumption。
    Hint 3. 写公式，再检查至少一种极端参数或单位。

15. **Hint 1.** 先从“mode time constants”对应的变量关系入手。
    Hint 2. 把条件“|w0|<1 for both stable”逐字转换为 assumption。
    Hint 3. 写公式，再检查至少一种极端参数或单位。
16. **Hint 1.** 先从“activity covariance”对应的变量关系入手。
    Hint 2. 把条件“centered data”逐字转换为 assumption。
    Hint 3. 写公式，再检查至少一种极端参数或单位。
17. **Hint 1.** 先从“PC1”对应的变量关系入手。
    Hint 2. 把条件“C symmetric PSD”逐字转换为 assumption。
    Hint 3. 写公式，再检查至少一种极端参数或单位。
18. **Hint 1.** 先从“PC score/projection”对应的变量关系入手。
    Hint 2. 把条件“orthonormal PCs”逐字转换为 assumption。
    Hint 3. 写公式，再检查至少一种极端参数或单位。

14 Complete Answer Key with reasoning

1. +w 与 −w。
2. (1,1)^T/√2。
3. (1,−1)^T/√2。
4. τ+=5τ，τ-=τ/1.8≈0.556τ。
5. common mode。
6. difference/fast mode 衰减，slow common component 保留。
7. 否则 mean offset 会主导 second moment，与 variance directions 混淆。
8. 单位向量中最大化 projected variance。
9. 保留前 K PC projections，discard 其余 orthogonal components。
10. 当 stationary dynamics/input covariance 使 activity covariance 与 W 共享 eigenvectors 等特定条件。
11. 不保证；noise、sampling 和 smooth spectrum 可使 cutoff 任意。
12. 可以，variance 与 information/relevance 不等同。
13. 适用条件/约定：symmetric two-neuron W。sanity check 应检查单位、符号、极限或 shape 是否与定义一致。
$$\xi_\pm = (1, \pm 1)^T / \sqrt{2}$$
14. 适用条件/约定：V^TV=I。sanity check 应检查单位、符号、极限或 shape 是否与定义一致。
$$\alpha = V^T h$$
15. 适用条件/约定：|w0|<1 for both stable。sanity check 应检查单位、符号、极限或 shape 是否与定义一致。
$$\tau_\pm = \tau / (1 \mp w_0)$$
16. 适用条件/约定：centered data。sanity check 应检查单位、符号、极限或 shape 是否与定义一致。
$$C = E[\delta h \delta h^T]$$
17. 适用条件/约定：C symmetric PSD。sanity check 应检查单位、符号、极限或 shape 是否与定义一致。
$$v_1 = \arg\max_{\|v\|=1} v^T C v$$
18. 适用条件/约定：orthonormal PCs。sanity check 应检查单位、符号、极限或 shape 是否与定义一致。
$$p_k = v_k^T (h - \bar{h})$$

15 Source-page concordance and coverage audit

Source file	Page	Coverage status
Lecture19-PopulationActivity-PCA-UPDATE.pdf	1	Main source-page unit: thumbnail, reconstruction, explanation, prediction question.
Lecture19-PopulationActivity-PCA-UPDATE.pdf	2	Main source-page unit: thumbnail, reconstruction, explanation, prediction question.
Lecture19-PopulationActivity-PCA-UPDATE.pdf	3	Main source-page unit: thumbnail, reconstruction, explanation, prediction question.
Lecture19-PopulationActivity-PCA-UPDATE.pdf	4	Main source-page unit: thumbnail, reconstruction, explanation, prediction question.
Lecture19-PopulationActivity-PCA-UPDATE.pdf	5	Main source-page unit: thumbnail, reconstruction, explanation, prediction question.
Lecture19-PopulationActivity-PCA-UPDATE.pdf	6	Main source-page unit: thumbnail, reconstruction, explanation, prediction question.
Lecture19-PopulationActivity-PCA.pdf	1	Old-version comparison: substantively duplicated by UPDATE; no unique academic statement found in visual comparison.
Lecture19-PopulationActivity-PCA.pdf	2	Old-version comparison: substantively duplicated by UPDATE; no unique academic statement found in visual comparison.
Lecture19-PopulationActivity-PCA.pdf	3	Old-version comparison: substantively duplicated by UPDATE; no unique academic statement found in visual comparison.
Lecture19-PopulationActivity-PCA.pdf	4	Old-version comparison: substantively duplicated by UPDATE; no unique academic statement found in visual comparison.
Lecture19-PopulationActivity-PCA.pdf	5	Old-version comparison: substantively duplicated by UPDATE; no unique academic statement found in visual comparison.

16 Errata, uncertainty log, and external endnotes

16.1 Errata / source cautions

1. UPDATE 版 Pages 1–5 与旧版实质相同；UPDATE 新增 Page 6 的 eigenvalue cliff 与 cumulative variance explained。
2. Page 1 的 τ_- 公式应按 λ_-=-w0 得 τ/(1+w0)；本教材明确保留 ±。
3. PCA 的’denoised’ reconstruction 需要低-variance dimensions 主要为 noise 的额外假设。

16.2 Uncertainty log

No unresolved handwriting uncertainty changes a core definition, equation, figure interpretation, or answer in this companion. Where handwriting was potentially ambiguous, the source-page image is preserved and the reconstruction avoids claiming unverified detail.

16.3 External endnotes

No external web or textbook source was used to replace the uploaded notes. Added material is limited to necessary mathematical scaffolding, explicit assumptions, standard sanity checks, and clearly labeled transfer examples.

16.4 Final self-audit

All source pages listed above were visually inspected. Equations were checked for symbol definitions, units/shapes, assumptions, algebraic transitions, limiting cases, and failure conditions. The PDF is static and contains no interactive form fields or scripts.