

NEUROSCI 366

Lecture 25

强 化 学 习 —MDP, Bellman Equations, and Q-Learning

Source-aligned · Static · Searchable · Printable

Source files

- Lecture25-ReinforcementLearning.pdf

Production version: 2026-08-22

Reader profile: neuroscience undergraduate education; mathematics scaffolded from high-school algebra/trigonometry to the formal computational-neuroscience level.

This companion preserves source-page order, distinguishes source material from necessary scaffolding and extensions, and places hints/answers after the lesson. It is a static PDF: no forms, JavaScript, hidden-answer widgets, passwords, or DRM.

Contents

1	How to use this companion	2
2	Learning objectives and prerequisite dependency map	2
3	Five-minute prerequisite diagnostic	2
4	Source-aligned lesson / 按原笔记页序	3
4.1	Lecture25-ReinforcementLearning.pdf · p. 1	3
4.2	Lecture25-ReinforcementLearning.pdf · p. 2	4
4.3	Lecture25-ReinforcementLearning.pdf · p. 3	5
4.4	Lecture25-ReinforcementLearning.pdf · p. 4	6
4.5	Lecture25-ReinforcementLearning.pdf · p. 5	7
4.6	Lecture25-ReinforcementLearning.pdf · p. 6	8
5	补全推导与数学支架 / Derivations	9
5.1	MDP 与 Markov property	9
5.2	return、 V 与 Q	10
5.3	Bellman optimality equation	11
5.4	Q -learning 与 exploration	12
5.5	model-based RL、planning 与 replay	12
6	Cross-page synthesis / 跨页因果与数学链	13
7	Worked examples and transfer	13
7.1	两状态 Bellman backup	13
7.2	Markov diagnosis	13
8	Formula and notation sheet	15
9	Bilingual glossary	15
10	Common traps, assumptions, and limitations	16
11	Cumulative Knowledge Check	17
12	Hint Bank	19
13	Complete Answer Key with reasoning	21
14	Source-page concordance and coverage audit	22

15 Errata, uncertainty log, and external endnotes	22
15.1 Errata / source cautions	22
15.2 Uncertainty log	22
15.3 External endnotes	22
15.4 Final self-audit	23

1 How to use this companion

1. 先用 5-minute diagnostic 暴露前置缺口；不要立即翻答案。
2. 按原笔记页序阅读 source-page units：先看原页，再读 clean reconstruction 与补全逻辑。
3. 遇到公式按“问题 → 符号/shape/units → assumptions → 一行一步推导 → intuition → biological meaning → sanity check → failure”阅读。
4. 完成 Cumulative Knowledge Check；只在需要时依次打开 Hint 1、2、3。
5. 至少隔一个 page break 后再核对 Answer Key，并记录错误类型：concept、symbol、algebra、assumption、correlation/causation。

Source hierarchy. 原笔记是内容权威；本书中的“【必要前置】/【补全推导】/【跨课连接】/【延伸】”是为了补齐数学或迁移，不替代源材料。无法确认的内容必须进入 Uncertainty Log。

2 Learning objectives and prerequisite dependency map

- 定义并区分：agent/state/action/reward。
- 从第一原则推导：Markov property。
- 解释几何/计算直觉：discounted return。
- 连接生物学解释：V/Q/policy。
- 诊断 assumptions 与 failure modes：Bellman backup。
- 把概念迁移到新神经科学问题：Q-learning/exploration。

Dependency map

agent/state/action/reward → Markov property → discounted return → V/Q/policy → Bellman backup → Q-learning/exploration

Core question

如何用 MDP formalize agent–environment interaction, 递归分解 discounted return 得到 Bellman equation, 并用 Q-learning 与 generative model 学习行动策略？


3 Five-minute prerequisite diagnostic

1. Markov property 是关于什么？（卡住时先看 Source-page unit 1，再看补全推导。）
2. policy 与 transition model 区别？（卡住时先看 Source-page unit 2，再看补全推导。）
3. $\gamma \rightarrow 0$ 的 agent？（卡住时先看 Source-page unit 3，再看补全推导。）
4. $V\pi$ 与 $Q\pi$ 区别？（卡住时先看 Source-page unit 4，再看补全推导。）
5. optimal policy 如何由 Q^* 得到？（卡住时先看 Source-page unit 5，再看补全推导。）

Scoring guide: 4–5 confident answers → proceed; 2–3 → use the prerequisite labels; 0–1 → read the formula/notation sheet once before the source-aligned lesson.

4 Source-aligned lesson / 按原笔记页序

4.1 Lecture25-ReinforcementLearning.pdf • p. 1



Original-note anchor. [Source: Lecture25-ReinforcementLearning.pdf, p. 1]

Clean reconstruction. Page 1: squirrel example、agent/environment/state/action/reward、Markov property、interaction loop.

What the note is saying. 本页的中心对象是 agent/state/action/reward 与 Markov property。原笔记将它们放进以下链条：squirrel example、agent/environment/state/action/reward、Markov property、interaction loop。

Why it follows. 解释 Markov property 是关于 state representation 的条件独立性，不等于环境“没有历史”。其逻辑后果是：从 squirrel environment 精确定义 agent、environment、state、action、reward、transition distribution 和 policy。后面的正式推导会逐项写出 assumptions、shape/units、limiting cases 与 failure conditions。

Figure reading. 逐条追踪箭头方向、兴奋/抑制符号、状态变量与外部输入；结构图说明允许的依赖关系，不自动证明生物实现。

Stop & Predict

Markov property 是关于什么？

4.2 Lecture25-ReinforcementLearning.pdf • p. 2

Goal: To maximize Expected discounted Return

$$R(t) = R(t+1) + \gamma R(t+2) + \gamma^2 R(t+3) + \dots$$

$0 < \gamma < 1$ if $\gamma = 0$ $R(t) = R(t+1)$ Myopic agent

if $\gamma = 1$ $R(t) = R(t+1) + R(t+2) + R(t+3) + \dots$ Far sighted agent.

Value function of State s under policy π

$$V_{\pi}(s) = E_{\pi}[R(t) | s(t)=s]$$

Policy π better than or equal to policy π' if and only if

$$V_{\pi}(s) \geq V_{\pi'}(s) \quad \forall s \in \mathcal{S}$$

Optimal policy π^*

$$V_{\pi^*}(s) = \max_{\pi} V_{\pi}(s) = E_{\pi^*}[R(t) | s(t)=s]$$

State - Action Value function

Expected return for starting at state s and taking action a , and then following policy π

$$Q_{\pi}(s,a) = E_{\pi}[R(t) | s(t)=s, a(t)=a]$$

Optimal policy π^*

$$Q_{\pi^*}(s,a) = E_{\pi^*}[R(t) | s(t)=s, a(t)=a] = \max_{\pi} Q_{\pi}(s,a)$$

Original-note anchor. [Source: Lecture25-ReinforcementLearning.pdf, p. 2]

Clean reconstruction. Page 2: discounted return, gamma, myopic/far-sighted, state value, policy, Q value, optimal policy.

What the note is saying. 本页的中心对象是 discounted return 与 V/Q/policy。原笔记将它们放进以下链条: discounted return、gamma、myopic/far-sighted、state value、policy、Q value、optimal policy。

Why it follows. 逐项推导 discounted return; 解释 $\gamma \rightarrow 0$ 与 $\gamma \rightarrow 1$ 的行为和 continuing/episodic caveats。其逻辑后果是: 从 squirrel environment 精确定义 agent、environment、state、action、reward、transition distribution 和 policy。后面的正式推导会逐项写出 assumptions、shape/units、limiting cases 与 failure conditions。

Figure reading. 先识别图中对象、箭头、参数和坐标系, 再问它表达的是定义、推导、模型预测还是经验观察; 示意图不提供未标注的定量精度。

Stop & Predict

policy 与 transition model 区别?

4.3 Lecture25-ReinforcementLearning.pdf • p. 3

Bellman Optimality Equation for $q_{\pi^*}(s, a)$

$$q_{\pi^*}(s, a) = E_{\pi^*}(Q(t) | s(t)=s, a(t)=a) \Rightarrow (1)$$

$$Q(t) = R(t+1) + \gamma Q(t+2) + \gamma^2 R(t+3) + \dots$$

$$Q(t+1) = R(t+2) + \gamma Q(t+3) + \dots$$

$$Q(t) = R(t+1) + \gamma Q(t+1) \Rightarrow (2)$$

Substituting (2) in (1).

$$q_{\pi^*}(s, a) = E_{\pi^*}(R(t+1) + \gamma Q(t+1) | s(t)=s, a(t)=a)$$

$$q_{\pi^*}(s, a) = \sum_{s', r} p(s', r | s, a) (r + \gamma E[Q(t+1) | s(t+1)=s'])$$

$$q_{\pi^*}(s, a) = \sum_{s', r} p(s', r | s, a) (r + \gamma V_{\pi^*}(s')) \Rightarrow (3)$$

$$V_{\pi^*}(s') = \max_{a'} q_{\pi^*}(s', a') \Rightarrow (4)$$

Under an optimal policy π^* , Expected return of state s' should be the expected return for the best action from that state.

Substituting (4) in (3).

$$q_{\pi^*}(s, a) = \sum_{s', r} p(s', r | s, a) (r + \gamma \max_{a'} q_{\pi^*}(s', a'))$$

$$q_{\pi^*}(s, a) = E[R(t+1) + \gamma \max_{a'} q_{\pi^*}(s(t+1), a')]$$

Bellman Optimality Equation for q_{π^*}

Satisfies recursive relationship

Given the dynamics of the environment $p(s', r | s, a)$, one can solve for $q_{\pi^*}(s, a)$.

Then we can find the next action that maximizes expected discounted return by

$$a^* = \arg \max_a q_{\pi^*}(s, a)$$

Original-note anchor. [Source: Lecture25-ReinforcementLearning.pdf, p. 3]

Clean reconstruction. Page 3: Bellman optimality equation 的逐步推导。

What the note is saying. 本页的中心对象是 Bellman backup 与 Q-learning/exploration。原笔记将它们放进以下链条：Bellman optimality equation 的逐步推导。

Why it follows. 按笔记步骤完整推导 Bellman optimality equation：当前 reward + next-state optimal value；保留 transition expectation。其逻辑后果是：从 Bellman error 推导 tabular Q-learning update；解释 learning rate、bootstrap、off-policy target 和 convergence assumptions 的适当背景。后面的正式推导会逐项写出 assumptions、shape/units、limiting cases 与 failure conditions。

Figure reading. 先识别图中对象、箭头、参数和坐标系，再问它表达的是定义、推导、模型预测还是经验观察；示意图不提供未标注的定量精度。

Stop & Predict

$\gamma \rightarrow 0$ 的 agent?

4.4 Lecture25-ReinforcementLearning.pdf • p. 4

Q-Learning

Learned action value function $Q(s, a)$

We want it to approximate $Q_{\pi^*}(s, a)$

$$Q_{\pi^*}(s, a) = E[R(t+1) + \gamma \max_{a'} Q_{\pi^*}(s(t+1), a')]$$

Bellman Error

$$R(t+1) + \gamma \max_{a'} Q(s(t+1), a') - Q(s, a)$$

Update $Q(s, a)$ to minimize Bellman Error

$$Q(s, a) \leftarrow Q(s, a) + \alpha [R(t+1) + \gamma \max_{a'} Q(s(t+1), a') - Q(s, a)]$$

α : learning rate

Q approximates Q_{π^*} independent of policy being followed.

Agent only updates Q for states and actions it visits
 $\Rightarrow$ Needs to explore new states, actions

Exploration	—	Exploitation	Tradeoff
$\Downarrow$		$\Downarrow$	
ϵ times		$1 - \epsilon$ times	
Pick suboptimal actions to visit new states and new actions		Choose action according to Q $a^* = \arg \max_a Q(s, a)$	
ϵ -greedy policy			

Original-note anchor. [Source: Lecture25-ReinforcementLearning.pdf, p. 4]

Clean reconstruction. Page 4: Q-learning, Bellman error, update, exploration–exploitation, epsilon-greedy.

What the note is saying. 本页的中心对象是 model-based/replay 与 agent/state/action/reward。原笔记将它们放进以下链条: Q-learning, Bellman error, update, exploration–exploitation, epsilon-greedy。


Why it follows. 从 Bellman error 推导 tabular Q-learning update; 解释 learning rate, bootstrap, off-policy target 和 convergence assumptions 的适当背景。其逻辑后果是: 分析 exploration–exploitation 与 epsilon-greedy 的优缺点。后面的正式推导会逐项写出 assumptions, shape/units, limiting cases 与 failure conditions。

Figure reading. 先识别图中对象、箭头、参数和坐标系, 再问它表达的是定义、推导、模型预测还是经验观察; 示意图不提供未标注的定量精度。

Stop & Predict

V_{π} 与 Q_{π} 区别?

4.5 Lecture25-ReinforcementLearning.pdf • p. 5



Original-note anchor. [Source: Lecture25-ReinforcementLearning.pdf, p. 5]

Clean reconstruction. Page 5: Tolman maze、generative model、hippocampal state representation、planning。

What the note is saying. 本页的中心对象是 Markov property 与 discounted return。原笔记将它们放进以下链条：Tolman maze、generative model、hippocampal state representation、planning。


Why it follows. 用 Tolman maze 解释 generative/model-based representation；连接 hippocampal place/state coding、planning、replay 与 simulated experience。其逻辑后果是：解释 Markov property 是关于 state representation 的条件独立性，不等于环境“没有历史”。后面的正式推导会逐项写出 assumptions、shape/units、limiting cases 与 failure conditions。

Figure reading. 先识别图中对象、箭头、参数和坐标系，再问它表达的是定义、推导、模型预测还是经验观察；示意图不提供未标注的定量精度。

Stop & Predict

optimal policy 如何由 Q^* 得到？

4.6 Lecture25-ReinforcementLearning.pdf • p. 6



Original-note anchor. [Source: Lecture25-ReinforcementLearning.pdf, p. 6]

Clean reconstruction. Page 6: model-based RL, simulated experience, hippocampal replay, sample efficiency.

What the note is saying. 本页的中心对象是 V/Q/policy 与 Bellman backup。原笔记将它们放进以下链条: model-based RL、simulated experience、hippocampal replay、sample efficiency。

Why it follows. 用 Tolman maze 解释 generative/model-based representation; 连接 hippocampal place/state coding、planning、replay 与 simulated experience。其逻辑后果是: 比较 model-free vs model-based RL 的 computation、sample efficiency、flexibility 和 failure modes。后面的正式推导会逐项写出 assumptions、shape/units、limiting cases 与 failure conditions。

Figure reading. 先识别图中对象、箭头、参数和坐标系, 再问它表达的是定义、推导、模型预测还是经验观察; 示意图不提供未标注的定量精度。

Stop & Predict

Bellman optimality equation 的 max 在哪里?

5 补全推导与数学支架 / Derivations

5.1 MDP 与 Markov property

【必要前置】 定义 squirrel foraging 的 formal components。

$$P(s_{t+1}, R_{t+1} \mid s_{0:t}, a_{0:t}) = P(s_{t+1}, R_{t+1} \mid s_t, a_t)$$

$$a_t \sim \pi(a \mid s_t)$$

1. agent 选择 action, environment 根据 transition distribution 产生 next state/reward。
2. state 必须包含预测 future 所需信息, 如位置、可见威胁、资源状态等。
3. 若 state 缺记忆变量, observations 可能非-Markov。
4. policy 是 state 到 action distribution, 不等于 transition model。

Geometric/computational intuition. Markov 性是 representation 的充分性条件, 而非世界真的无历史。

Biological interpretation / failure condition. partial observability 时需 belief state/recurrent memory。

Micro-check

$V\pi$ 与 $Q\pi$ 区别?

5.2 return、V 与 Q

【补全推导】 量化 long-term reward。

$$G_t = R_{t+1} + \gamma R_{t+2} + \gamma^2 R_{t+3} + \dots$$

$$V_\pi(s) = E_\pi[G_t \mid s_t = s]$$

$$Q_\pi(s, a) = E_\pi[G_t \mid s_t = s, a_t = a]$$

1. $0 \leq \gamma < 1$ 使远期 reward 权重几何衰减并帮助 continuing tasks 收敛。
2. V 在 policy π 下从 state 出发平均；Q 额外固定第一 action。
3. $V_\pi(s) = E_{a \sim \pi} Q_\pi(s, a)$ 。
4. optimal policy 选择最大 Q^* 的 action (ties 可多解)。

Geometric/computational intuition. Q 把“现在做什么”与未来 consequences 连接。

Biological interpretation / failure condition. episodic finite horizon 可允许 $\gamma=1$ ；reward scaling 与 termination 需明确。

Micro-check

optimal policy 如何由 Q^* 得到？

5.3 Bellman optimality equation

【跨页连接】 递归表示 Q^* 。

$$\begin{aligned} Q^*(s, a) &= E[R_{t+1} + \gamma \max_{a'} Q^*(s_{t+1}, a') \mid s_t = s, a_t = a] \\ &= \sum_{s', r} p(s', r \mid s, a) [r + \gamma \max_{a'} Q^*(s', a')] \end{aligned}$$

1. 将 G_t 拆成 $R_{t+1} + \gamma G_{t+1}$ 。
2. 第一步 action a 固定；下一 state 后采用 optimal future action。
3. 对 environment stochastic transition/reward 取 expectation。
4. equation 是 self-consistency relation；已知 model 时可用 dynamic programming 求解。

Geometric/computational intuition. 一个 state-action 的价值等于一步 reward 加最优 future 的折扣价值。

Biological interpretation / failure condition. 把 max 放到 expectation 外/内位置写错会改变 stochastic problem。

Micro-check

Bellman optimality equation 的 max 在哪里？

5.4 Q-learning 与 exploration

【模型边界】 未知 transition model 时如何从 experience 学 Q^* ?

$$\delta_t = R_{t+1} + \gamma \max_{a'} Q(s_{t+1}, a') - Q(s_t, a_t)$$

$$Q(s_t, a_t) \leftarrow Q(s_t, a_t) + \alpha \delta_t$$

1. sample transition 给 Bellman target 的 noisy sample。
2. update 只改 visited state-action entry。
3. target 使用 greedy max, 而 behavior 可以 ϵ -greedy, 因此 off-policy。
4. tabular convergence 需充分 exploration、适当 decaying learning rates 与 stationary finite MDP 等条件。

Geometric/computational intuition. 把当前 Q 向 one-step bootstrap target 移动。

Biological interpretation / failure condition. function approximation、off-policy 与 bootstrap 可共同引发 instability; state coverage 不足也失败。

Micro-check

Q-learning TD error?

5.5 model-based RL、planning 与 replay

【必要前置】 generative model 如何提高 sample efficiency?

$$\hat{p}(s', r \mid s, a)$$

real or simulated $(s, a, r, s') \rightarrow$ planning/update

1. agent 学 transition/reward model。
2. 可在不实际行动时模拟 trajectories、评估 detours/changed reward。
3. hippocampal state/place representations 与 replay 提供候选 biological substrate。
4. replay 与 exact Bellman backup 是层级推断, 不能直接等同。

Geometric/computational intuition. world model 把过去 experience 重组为未实际经历的 counterfactual updates。

Biological interpretation / failure condition. model bias 会在 planning 中累积; computational cost 也更高。


Micro-check

为什么 Q-learning off-policy?

6 Cross-page synthesis / 跨页因果与数学链

MDP 的核心不是“环境没有历史”，而是 chosen state representation 使 future 在给定 current state/action 后与更早历史条件独立。discounted return 可递归拆成 immediate reward + γ future return, 导出 Bellman optimality equation。Q-learning 用 sampled Bellman error 做 off-policy bootstrap update; model-based RL 另学习 transition/reward model, 并可通过 simulated experience/replay 提高 sample efficiency。

Lecture 25 — key reconstruction (schematic)



Bellman backup selects the larger expected branch

Figure note: schematic reconstruction; it encodes qualitative relations from the lesson and does not invent precise empirical data points.

7 Worked examples and transfer

7.1 两状态 Bellman backup

【原课/核心例题】 Prompt. s, a 立即 reward=1, 确定转到 terminal-like s' , $\max Q(s', \cdot)=4$, $\gamma=0.9$ 。

Worked solution. target= $1+0.9 \times 4=4.6$ 。若当前 $Q=3$, $\alpha=0.2$, 则新 $Q=3+0.2(1.6)=3.32$ 。

Check. update 不是直接设为 4.6, 除非 $\alpha=1$ 。

7.2 Markov diagnosis

【跨课连接】 Prompt. maze observation 只有当前位置, 但门是否已打开取决于之前踩过开关。

Worked solution. 当前位置 alone 非-Markov; state 应加入 switch/door status 或 belief/memory。
Check. 历史效应可通过扩充 state 恢复 Markov property。

Micro-check

Explain in your own words. 用不超过 120 字解释：本课从 source page 1 到最后一页，究竟把哪一个输入、状态、统计量或学习规则变成了可检验 prediction?

Self-reflection. 你最可能犯的是 concept、symbol、algebra、assumption 还是 causality error? 写出一个具体例子。

8 Formula and notation sheet

1. MDP transition/reward model

$$p(s', r | s, a)$$

Conditions / conventions: Markov state

2. discounted return

$$G_t = \sum_{k \geq 0} \gamma^k R_{t+k+1}$$

Conditions / conventions: $0 \leq \gamma < 1$ or finite episode

3. state value

$$V_\pi(s) = E_\pi[G_t | s_t = s]$$

Conditions / conventions: policy π

4. state-action value

$$Q_\pi(s, a) = E_\pi[G_t | s_t = s, a_t = a]$$

Conditions / conventions: first action fixed

5. Bellman optimality

$$Q^* = E[R + \gamma \max Q^*]$$

Conditions / conventions: optimal continuation

6. tabular Q-learning

$$Q \leftarrow Q + \alpha(R + \gamma \max Q' - Q)$$

Conditions / conventions: sampled transition

7. ϵ -greedy exploration

$$\pi_\epsilon = (1 - \epsilon)\text{greedy} + \epsilon\text{random}$$

Conditions / conventions: finite action set

9 Bilingual glossary

中文	English / symbol	Operational meaning
强化学习	reinforcement learning	通过 interaction 与 rewards 学 policy/value。
智能体	agent	选择 actions、更新内部 policy/model 的 learner。
状态	state	用于预测 future 与选择 action 的 environment representation。
马尔可夫性质	Markov property	given current state/action 后 future 与更早 history 条件独立。
策略	policy	state 到 action probability 的映射。
回报	return	未来 rewards 的 discounted sum。
Bellman 方程	Bellman equation	value 的 recursive self-consistency relation。
Q-learning	Q-learning	model-free off-policy TD control algorithm。
探索-利用	exploration-exploitation	收集新信息与选择当前最佳 action 的权衡。
基于模型的强化学习	model-based RL	学习/使用 environment model 进行 planning。

中文	English / symbol	Operational meaning
重放	replay	离线重现/模拟 state sequences 的 neural/computational process。

10 Common traps, assumptions, and limitations

1. Markov property 等于环境没有历史。
2. 混淆 V_π 、 Q_π 、 V^* 、 Q^* 。
3. Bellman equation 忘记 transition expectation。
4. Q-learning target 使用 behavior action 而误写成 SARSA。
5. ϵ -greedy 的 random branch 只在非 greedy actions 中选而不说明 convention。
6. 把 model-free 等同于无 internal representation。
7. 把 hippocampal replay 直接等同于精确 Bellman backup。

Course-specific risk boundary. 不要把 Q-learning 与所有 TD learning 同义化；不要把 hippocampal replay 直接等同于精确 Bellman backup，必须标明 evidence 与 inference 的层级。

11 Cumulative Knowledge Check

Do not turn to the Hint Bank until you have written a first attempt.

1. Markov property 是关于什么?

2. policy 与 transition model 区别?

3. $\gamma \rightarrow 0$ 的 agent?

4. V_π 与 Q_π 区别?

5. optimal policy 如何由 Q^* 得到?

6. Bellman optimality equation 的 max 在哪里?

7. Q-learning TD error?

8. 为什么 Q-learning off-policy?

9. α 的作用?

10. ϵ -greedy 的代价?

11. model-based 的优势与风险?

12. Tolman detour 支持什么?

13. 公式表中的 “MDP transition/reward model” 解决什么问题? 写出适用条件与一个 sanity check。

14. 公式表中的 “discounted return” 解决什么问题? 写出适用条件与一个 sanity check。

15. 公式表中的 “state value” 解决什么问题? 写出适用条件与一个 sanity check。

-
16. 公式表中的 “state-action value” 解决什么问题？写出适用条件与一个 sanity check。
-
17. 公式表中的 “Bellman optimality” 解决什么问题？写出适用条件与一个 sanity check。
-
18. 公式表中的 “tabular Q-learning” 解决什么问题？写出适用条件与一个 sanity check。
-
19. 公式表中的 “ ϵ -greedy exploration” 解决什么问题？写出适用条件与一个 sanity check。
-
20. 诊断并修正下面的说法：Markov property 等于环境没有历史。
-

12 Hint Bank

1. **Hint 1.** 先识别对象、变量与假设。
Hint 2. 写出最相关的定义或方程，再代入。
Hint 3. 检查单位、shape、符号与极限情况。
2. **Hint 1.** 先识别对象、变量与假设。
Hint 2. 写出最相关的定义或方程，再代入。
Hint 3. 检查单位、shape、符号与极限情况。
3. **Hint 1.** 先识别对象、变量与假设。
Hint 2. 写出最相关的定义或方程，再代入。
Hint 3. 检查单位、shape、符号与极限情况。
4. **Hint 1.** 先识别对象、变量与假设。
Hint 2. 写出最相关的定义或方程，再代入。
Hint 3. 检查单位、shape、符号与极限情况。
5. **Hint 1.** 先识别对象、变量与假设。
Hint 2. 写出最相关的定义或方程，再代入。
Hint 3. 检查单位、shape、符号与极限情况。
6. **Hint 1.** 先识别对象、变量与假设。
Hint 2. 写出最相关的定义或方程，再代入。
Hint 3. 检查单位、shape、符号与极限情况。
7. **Hint 1.** 先识别对象、变量与假设。
Hint 2. 写出最相关的定义或方程，再代入。
Hint 3. 检查单位、shape、符号与极限情况。
8. **Hint 1.** 先识别对象、变量与假设。
Hint 2. 写出最相关的定义或方程，再代入。
Hint 3. 检查单位、shape、符号与极限情况。
9. **Hint 1.** 先识别对象、变量与假设。
Hint 2. 写出最相关的定义或方程，再代入。
Hint 3. 检查单位、shape、符号与极限情况。
10. **Hint 1.** 先识别对象、变量与假设。
Hint 2. 写出最相关的定义或方程，再代入。
Hint 3. 检查单位、shape、符号与极限情况。
11. **Hint 1.** 先识别对象、变量与假设。
Hint 2. 写出最相关的定义或方程，再代入。
Hint 3. 检查单位、shape、符号与极限情况。
12. **Hint 1.** 先识别对象、变量与假设。
Hint 2. 写出最相关的定义或方程，再代入。
Hint 3. 检查单位、shape、符号与极限情况。
13. **Hint 1.** 先从“MDP transition/reward model”对应的变量关系入手。
Hint 2. 把条件“Markov state”逐字转换为 assumption。
Hint 3. 写公式，再检查至少一种极端参数或单位。
14. **Hint 1.** 先从“discounted return”对应的变量关系入手。
Hint 2. 把条件“ $0 \leq \gamma < 1$ or finite episode”逐字转换为 assumption。
Hint 3. 写公式，再检查至少一种极端参数或单位。

15. **Hint 1.** 先从 “state value” 对应的变量关系入手。
Hint 2. 把条件 “policy π ” 逐字转换为 assumption。
Hint 3. 写公式, 再检查至少一种极端参数或单位。
16. **Hint 1.** 先从 “state-action value” 对应的变量关系入手。
Hint 2. 把条件 “first action fixed” 逐字转换为 assumption。
Hint 3. 写公式, 再检查至少一种极端参数或单位。
17. **Hint 1.** 先从 “Bellman optimality” 对应的变量关系入手。
Hint 2. 把条件 “optimal continuation” 逐字转换为 assumption。
Hint 3. 写公式, 再检查至少一种极端参数或单位。
18. **Hint 1.** 先从 “tabular Q-learning” 对应的变量关系入手。
Hint 2. 把条件 “sampled transition” 逐字转换为 assumption。
Hint 3. 写公式, 再检查至少一种极端参数或单位。
19. **Hint 1.** 先从 “ ϵ -greedy exploration” 对应的变量关系入手。
Hint 2. 把条件 “finite action set” 逐字转换为 assumption。
Hint 3. 写公式, 再检查至少一种极端参数或单位。
20. **Hint 1.** 先问: 混淆的是定义、统计估计、模型变量还是生物机制?
Hint 2. 指出一个缺失 assumption 或反例。
Hint 3. 用 “在……条件下……; 否则……” 改写。

13 Complete Answer Key with reasoning

1. state representation 的 conditional sufficiency。
2. policy 由 agent 选 action; transition model 由 environment 给 next state/reward。
3. myopic, 主要重视 immediate reward。
4. Q additionally conditions on first action。
5. 选择 $\arg\max_a Q^*(s,a)$ 。
6. next state 的 future actions 上, 位于 transition expectation 内部的 bracket 中。
7. $R + \gamma \max_{a'} Q(s', a') - Q(s,a)$ 。
8. target 使用 greedy max, 而 behavior 可 exploratory。
9. 控制新 Bellman target 对现有 estimate 的更新幅度。
10. 持续随机 actions 降低 immediate reward, 且 uniform exploration 低效。
11. 更 sample-efficient/flexible planning; model bias 与 computation cost。
12. animals 可能学习 generative/cognitive map, 而非只缓存固定 action values。
13. 适用条件/约定: Markov state。sanity check 应检查单位、符号、极限或 shape 是否与定义一致。

$$p(s', r | s, a)$$

14. 适用条件/约定: $0 \leq \gamma < 1$ or finite episode。sanity check 应检查单位、符号、极限或 shape 是否与定义一致。

$$G_t = \sum_{k \geq 0} \gamma^k R_{t+k+1}$$

15. 适用条件/约定: policy π 。sanity check 应检查单位、符号、极限或 shape 是否与定义一致。

$$V_\pi(s) = E_\pi[G_t | s_t = s]$$

16. 适用条件/约定: first action fixed。sanity check 应检查单位、符号、极限或 shape 是否与定义一致。

$$Q_\pi(s, a) = E_\pi[G_t | s_t = s, a_t = a]$$

17. 适用条件/约定: optimal continuation。sanity check 应检查单位、符号、极限或 shape 是否与定义一致。

$$Q^* = E[R + \gamma \max Q^*]$$

18. 适用条件/约定: sampled transition。sanity check 应检查单位、符号、极限或 shape 是否与定义一致。

$$Q \leftarrow Q + \alpha(R + \gamma \max Q' - Q)$$

19. 适用条件/约定: finite action set。sanity check 应检查单位、符号、极限或 shape 是否与定义一致。

$$\pi_\epsilon = (1 - \epsilon)\text{greedy} + \epsilon\text{random}$$

20. 该说法省略了关键定义或 assumption。正确做法是先区分对象层级, 并依据本课公式/实验设计说明成立条件; 原说法不能无条件成立。

14 Source-page concordance and coverage audit

Source file	Page	Coverage status
Lecture25-ReinforcementLearning.pdf	1	Main source-page unit: thumbnail, reconstruction, explanation, prediction question.
Lecture25-ReinforcementLearning.pdf	2	Main source-page unit: thumbnail, reconstruction, explanation, prediction question.
Lecture25-ReinforcementLearning.pdf	3	Main source-page unit: thumbnail, reconstruction, explanation, prediction question.
Lecture25-ReinforcementLearning.pdf	4	Main source-page unit: thumbnail, reconstruction, explanation, prediction question.
Lecture25-ReinforcementLearning.pdf	5	Main source-page unit: thumbnail, reconstruction, explanation, prediction question.
Lecture25-ReinforcementLearning.pdf	6	Main source-page unit: thumbnail, reconstruction, explanation, prediction question.

15 Errata, uncertainty log, and external endnotes

15.1 Errata / source cautions

1. Page 2 的 γ 范围在 continuing tasks 常取 <1 ; episodic finite tasks 可使用 $\gamma=1$, 需说明。
2. Page 4 的 Q-learning 是 tabular form; function approximation/convergence issues 未在源页展开。
3. Pages 5–6 的 hippocampal planning/replay connection 是 evidence+inference bridge, 不是算法级一一对应。

15.2 Uncertainty log

No unresolved handwriting uncertainty changes a core definition, equation, figure interpretation, or answer in this companion. Where handwriting was potentially ambiguous, the source-page image is preserved and the reconstruction avoids claiming unverified detail.

15.3 External endnotes

No external web or textbook source was used to replace the uploaded notes. Added material is limited to necessary mathematical scaffolding, explicit assumptions, standard sanity checks, and clearly labeled transfer examples.

15.4 Final self-audit

All source pages listed above were visually inspected. Equations were checked for symbol definitions, units/shapes, assumptions, algebraic transitions, limiting cases, and failure conditions. The PDF is static and contains no interactive form fields or scripts.